中国图书分类号 TM30　　密级 公开
国际图书分类号 621.3　　单位代码 10613

西 南 交 通 大 学

硕 士 学 位 论 文

连续值与整值时间序列的稳健在线监测方法

学 科 专 业 统计学
学　　号 2022201648
作 者 姓 名 王洋
指 导 老 师 杨宝莹
学　　院 数学学院

2025 年 3 月 9 日

A Thesis Submitted to

Southwest Jiaotong University for Master Degree

Robust Online Monitoring Methods for Continuous-Valued and Integer-Valued Time Series

Discipline Statistics

Student ID 2022201648

Author Yang Wang

Supervisor Baoying Yang

School School of Mathematics

Mar. 9, 2025

西南交通大学
学位论文独创性声明

本人郑重声明：所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得西南交通大学或其它教育机构的学位或证书而使用过的材料。其他人员对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文的主要创新点如下：

作者签名：_____

日期：　　年　　月　　日

西南交通大学
学位论文使用授权

本学位论文作者完全了解西南交通大学有关保留、使用学位论文的规定，同意学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅。本人授权西南交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载，可以采用影印、缩印、扫描等复制手段保存、汇编本学位论文。

本学位论文属于

1．保密□，在　　年解密后适用本授权书；

2．不保密□，使用本授权书。

（请在以上方框内打“√”）

作者签名：_____　　导师签名：_____

日期：　　年　　月　　日

摘　要

在过去几十年里，变点问题一直是统计学中的重要研究课题。该问题最早起源于质量控制，随后扩展到结构健康监测、医疗监测和环境保护等领域。在线监测方法旨在快速检测数据流中随机性质的结构变化。本文分别研究了连续值时间序列和整值时间序列中的变点监测问题，并提出两种无分布假定的稳健在线监测方法。本文的主要研究成果如下：

（1）本文首先研究了连续值时间序列的分布变点监测问题。当观测值之间存在较强的时间依赖性时，现有非参数在线监测方法难以有效控制第一类错误率。为解决这一问题，本文提出一个基于经验特征函数的自正则监测统计量。从理论上研究了监测统计量在原假设和备择假设下的渐近性质。考虑到原假设下的渐近分布非常复杂，本文采用多元 Stationary Bootstrap 方法来估计检验的临界值。数值模拟和实际案例分析验证了自正则在线监测方法的有效性。

（2）在无分布假定的半参数框架下，本文研究了整值时间序列模型的参数变点监测问题。提出了一种基于泊松拟极大似然估计（Poisson Quasi Maximum Likelihood Estimator，PQMLE）的在线监测方法。该方法利用模型残差构造修正 CUSUM（Cumulative Sum）监测统计量，用于快速检测模型参数的结构变化。本文给出了修正 CUSUM 监测统计量在原假设下的渐近分布，并证明了其在备择假设下的一致性。数值模拟表明了修正 CUSUM 在线监测方法的有效性。

关键词：经验特征函数，自正则，拟似然，变点监测

ABSTRACT

The change point problem has been a popular topic in statistics over the past few decades. Beginning with quality control, this problem was subsequently extended to areas such as structural health monitoring, medical monitoring and environmental protection. Online monitoring methods aim to quickly detect structural changes in the stochastic properties of a data stream. This paper investigates the change point monitoring problem for continuous-valued time series and integer-valued time series, respectively, and proposes two robust online monitoring methods without distributional assumptions. The main results of this paper are as follows:

1. This paper first investigates the distributional change point monitoring problem for continuous-valued time series. When there is a strong temporal dependence between observations, existing nonparametric online monitoring methods are difficult to effectively control the Type I error. To address this issue, this paper proposes a self-normalized monitoring statistic based on the empirical characteristic function. The asymptotic properties of the self-normalized monitoring statistic under the null hypothesis and alternative hypothesis are theoretically investigated. Given that the asymptotic distribution under the null hypothesis is quite complex, the multivariate stationary bootstrap method is employed to estimate the critical value of the test. Numerical simulations and real case studies verified the effectiveness of the self-normalized online monitoring method.

2. This paper investigates the parameter change point monitoring problem for integer-valued time series models in a semiparametric framework without distributional assumption. An online monitoring method based on Poisson quasi maximum likelihood estimator (PQMLE) is proposed. This method uses the residuals to construct a modified CUSUM (Cumulative Sum) monitoring statistic for quickly detecting structural changes in model parameters. The asymptotic distribution of the modified CUSUM monitoring statistic is derived under the null hypothesis and its consistency is proved under the alternative hypothesis. Numerical simulations demonstrate the effectiveness of the modified CUSUM online monitoring method.

Keywords: Empirical characteristic function, Self-normalized, Quasi likelihood,Change point monitoring

目 录

第 1 章 绪论 2
1.1 研究背景及意义 2
1.2 研究现状 3
1.2.1 连续值时间序列的在线监测方法 3
1.2.2 整值时间序列模型及其参数变点监测问题 4
1.3 主要研究内容和文章结构 5
第 2 章 基于特征函数的自正则在线监测方法 7
2.1 自正则在线监测方法 7
2.2 渐近性质 9
2.3 数值模拟 11
2.3.1 原假设下的模拟结果 12
2.3.2 备择假设下的模拟结果 13
2.4 实例分析 17
2.4.1 #1 号风机 17
2.4.2 #5 号风机 19
2.5 本章定理证明 21
2.6 本章小节 30
第 3 章 基于 PQMLE 的整值时间序列模型参数变点监测 31
3.1 模型假设 31
3.2 整值时间序列模型参数变点监测 33
3.3 数值模拟 37
3.3.1 原假设下的模拟结果 39
3.3.2 备择假设下的模拟结果 44
3.4 本章定理证明 51
3.5 本章小节 58
第 4 章 总结与展望 59
4.1 主要研究结论 59
4.2 研究展望 59
致 谢 61
参考文献 65
攻读硕士学位期间取得的研究成果 66

第 1 章　绪论

1.1　研究背景及意义

在时间序列分析中，通常假设数据的生成机制是时移不变的。然而，对于长期收集的数据，这一假设可能过于严格，因为外部冲击可能导致数据的随机结构（概率分布或模型参数）发生变化[1]。通常，时间序列的统计特性或模型参数发生突然变化的时刻被称为变点[2]。忽视变点会严重影响统计推断的可靠性[3]。因此，研究时间序列中的变点问题具有重要的理论意义。

变点检测方法旨在识别时间序列中统计特性（如均值、方差和概率分布）或模型参数的结构变化。传统上，变点检测方法分为两类：离线变点检测（回顾性检验）和在线监测（序贯检验）。离线变点检测用于检测给定数据集中的结构变化，并估计变点的位置和个数[4,5]。与此不同，在线监测方法侧重于快速检测数据流中的结构变化，旨在解决变点监测问题[6]。技术进步推动了实时数据的发展和在线分析需求的增长。在医疗监测、环境保护等领域，及时检测数据流中的结构变化有助于人们快速做出决策。在线监测方法在这些领域中的应用日益广泛[7,8]。

在现实生活中，连续值时间序列和整数值时间序列十分常见。本研究主要研究了这两类时间序列中的变点监测问题。对于连续值时间序列，大多数在线监测方法侧重于检测其统计特性（如均值、方差、概率分布函数）或回归系数的结构变化。Na 等人[9] 详细介绍了针对特定参数变点监测问题的在线监测方法；Hušková 和 Hlávka[10] 则讨论了针对分布变点监测问题的非参数在线监测方法。非参数在线监测方法无需假定数据分布或建立统计模型，因此比参数方法更具稳健性[8]，且适用范围更广。然而，当观测值之间存在较强的时间依赖性时，现有非参数在线监测方法[11,12] 往往无法有效控制第一类错误率。为了解决这一问题，本文提出了一种基于经验特征函数的自正则在线监测方法。该方法引入了一个额外的自正则因子，能够较好地控制第一类错误率。

在整值时间序列分析中，整值自回归（Integer-Valued Autoregressive，INAR）模型[13,14] 和整值广义自回归条件异方差（Integer-Valued Generalized Autoregressive Conditional Heteroscedastic，INGARCH）模型[15] 最为流行。近年来，INAR 模型和 INGARCH 模型的参数变点监测问题受到了许多研究者的关注[16–18]。然而，这些在线监测方法通常依赖于特定的参数模型以及概率分布假设，这在实际应用中过于严格[19]。因此，Diop 和 Kengne[20] 建议在半参数框架下研究整值时间序列模型的参数变点监测问题[20]，并提出一个基于参数估计量的 CUSUM 在线监测方法。

半参数框架仅规定条件均值的回归模型，放宽了对概率分布的假设。在此框架下，可采用泊松拟极大似然估计（PQMLE）方法估计模型参数[21]。然而，由于参数估计过程中数值计算的不稳定性，基于参数估计量的在线监测方法难以有效控制第一类错误率。相比之下，基于模型残差的 CUSUM 方法更为稳定，能够较好地控制第一类错误率[22]。此外，目前大多数整值时间序列中的在线监测方法依赖于标准 CUSUM 统计量。当变点位置靠后时，标准 CUSUM 统计量的检测能力较弱[23]。为克服这一问题，受到 Gösmann 等人[24] 的启发，本文提出一个由模型残差构造的修正 CUSUM 监测统计量，其中模型残差定义为观测值与通过 PQMLE 方法获得的条件均值估计值之差。

1.2 研究现状

自 Page（1955）[25] 的开创性工作以来，时间序列的变点监测问题吸引了大量学者的关注。在连续值时间序列中，在线监测方法通常分为两类：参数化方法和非参数方法。参数化方法依赖于假设的概率分布或统计模型[9]。而非参数方法则不依赖这些假设[10]，因此在实际应用中有着更广泛的适用性。整值时间序列分析通常同时依赖于参数模型和概率分布假设。在整值时间序列的变点监测研究中，在线监测方法主要分为两类：参数化方法和半参数方法。参数化方法预先假设回归模型和概率分布，而半参数化方法则放宽了对概率分布的假设。

考虑到无分布假设的稳健在线监测方法具有广泛的适用性，本文主要研究了这类方法在连续值和整数值时间序列中的应用。本节结构安排如下：1.2.1 节将概述连续值时间序列中的参数化与非参数在线监测方法的研究进展；1.2.2 节将介绍整值时间序列模型中的参数变点监测问题及其研究现状。

1.2.1 连续值时间序列的在线监测方法

在变点监测问题的研究中，CUSUM 方法因其简单高效的特点而备受推崇[26]。基于 CUSUM 方法，学者们相继研究了均值、方差、回归系数等特定参数的变点监测问题。例如，Horváth 等人[27] 提出了基于模型残差的 CUSUM 在线监测方法，用于快速检测线性模型中回归系数的结构变化。Aue 等人[28] 讨论了用于检测均值变化的 CUSUM 方法，而 Horváth 等人[29] 则提出了用于识别方差变化的 CUSUM 方法。Berkes 等人[30] 提出了基于拟似然得分函数的 CUSUM 统计量，用于快速检测 GARCH 模型中参数的结构变化。Na 等人[9] 总结了用于监测时间序列模型中各类参数的在线监测方法。基于估计函数，Kirch 和 Kamgaing[17] 研究了一般时间序列模型中的参数变点监测问题。

对于长期收集的时间序列数据，错误指定的参数模型可能导致不可靠的统计推断[31]。此外，如果假定某一统计特征（如均值）发生变化，而实际上是另一特征（如方差）发生变化，那么仅监测单一统计特征的在线监测方法可能会得出误导性的结论[32]。相比之下，非参数在线监测方法更为稳健，它们侧重于快速检测概率分布的结构变化，而不依赖于数据建模和预设变点类型[8]。Hušková 和 Hlávka[10] 综述了早期的非参数在线监测方法。Hlávka 等人[1] 提出了一种基于经验特征函数的 CUSUM 统计量，用于快速检测配对多元时间序列中分布函数的结构变化。在研究多元时间序列的分布变点监测问题时，Kojadinovic 和 Verdier[11] 提出一种基于经验分布函数的在线监测方法。基于平稳性检验的概念[33]，Lee 等人[12] 提出基于联合特征函数的 CUSUM 统计量，用于检测单变量时间序列中的平稳性变化。

然而，当模型复杂或观测值之间存在较强的时间依赖性时，上述参数化和非参数 CUSUM 方法均存在经验水平扭曲的问题。例如，对于监测特定参数的 CUSUM 在线监测方法，长时方差（Long-Run Variance，LRV）的估计是一个难点。常用的 LRV 核估计对带宽参数高度敏感，而在实际应用中，选择合适的带宽参数往往极具挑战性[34]。这使得直接估计 LRV 的 CUSUM 方法常出现经验水平扭曲现象，尤其是在模型复杂且样本量较小时[9,30]。为解决这一问题，Shao 和 Zhang[34] 引入了一个自正则因子，避免直接估计长时方差（LRV）。该方法能够有效控制第一类错误率，进而促进了自正则 CUSUM 方法的发展。尽管该方法效果显著，但在变点监测领域，关于自正则 CUSUM 方法的研究较为有限。例如，Hoga[35] 提出了一种比率型（自正则）CUSUM 统计量，用于研究多元时间序列的均值变点监测问题。Dette 和 Gösmann[3] 提出了基于极大似然比的自正则 CUSUM 统计量，用于快速检测一类参数的结构变化。Chan 等人[36] 则提出了一种基于广义目标函数的自正则 CUSUM 方法，旨在快速检测一般时间序列模型参数的结构变化。

在分布函数变点监测问题的研究当中，当样本量较小且观测值之间的时间依赖性较强时，现有的非参数在线监测方法的经验水平扭曲严重[11,12]。为解决这一问题，受 Chan 等人[36] 的启发，本文提出了一种基于经验特征函数的自正则 CUSUM 在线监测方法。

1.2.2 整值时间序列模型及其参数变点监测问题

近年来，整值时间序列逐渐成为时间序列分析中的重要研究对象。自 McKenzie[13]、Alzaid 和 Al-Osh[14]、Du 和 Li[37]、Al-Osh 和 Aly[38] 以及 Ferland 等人[15] 的开创性工作以来，整值自回归（INAR）模型和整值广义自回归条件异方差（INGARCH）模型成为解决实际问题的重要工具。这些模型广泛应用于金融[39]、传染病[40]、环境科学[41] 等领域。关于 INAR 和 INGARCH 模型的详细介绍，可参考

Tjøstheim[42] 的综述以及 Weiß[43] 的专著。

整值时间序列分析通常依赖于特定的参数模型及其概率分布假设。由于泊松分布和负二项分布的广泛适用性，二者常在 INGARCH 模型中作为数据的条件分布[44,45]，或作为 INAR 模型中创新项的分布[46,47]。Davis 和 Liu[48] 考虑了以单参数指数族为条件分布的 INGARCH 模型。在实际应用中，基于特定分布的模型可能会出现问题，特别是当假设的分布与实际数据不匹配时[19]。在这种情况下，Ahmad 和 Francq[21] 提出的泊松拟极大似然估计（PQMLE）方法可作为条件极大似然估计方法的有效替代。当条件均值方程正确指定时，PQMLE 对分布假设错误具有较强的稳健性。

在现实世界中，随着新的时间序列数据的不断加入，人们需要不断评估现有模型的适用性。如果模型不再适用，及时获得提示至关重要[6]。在整值时间序列中，模型参数变点监测问题一直受到研究者的广泛关注。例如，针对 INAR 模型和泊松 INGARCH 模型的参数变点监测问题，Hudecová 等人[16] 提出了基于概率生成函数的在线监测方法。基于估计函数，Kirch 和 Kamgaing[17] 研究了 INARCH 模型的参数变点监测问题。Lee 和 Lee[18] 提出了基于模型残差的 CUSUM 在线监测方法，其中模型参数由条件极大似然方法估计。

然而，以上方法通常需要指定数据的条件分布或创新项的分布，这在实际应用中是一个较为严格的假设。Diop 和 Kengne[20] 建议在半参数框架下研究整值时间序列模型的参数变点监测问题，并提出一个基于参数估计量的 CUSUM 监测统计量。半参数框架放宽了对概率分布的假设，参数估计可由 PQMLE 方法[21] 获得。但是，当样本量较小时，参数估计中数值计算的不稳定性会导致基于参数估计量的在线监测方法的经验水平严重扭曲[20]。此外，该方法的计算量较大，每次新数据到达时都需重新进行参数估计。此时，采用基于模型残差的 CUSUM 方法更为合适。该方法往往更加稳定，能够有效控制第一类错误率[22]，而且只需基于训练样本进行一次参数估计，计算成本较低。目前，大多数整值时间序列的在线监测方法依赖于标准 CUSUM 统计量，但当变点位置靠后时，标准 CUSUM 统计量的检测能力较弱[23]。为克服这一问题，受 Gösmann 等人[24] 的启发，本文提出了一种基于模型残差的修正 CUSUM 监测统计量。该方法通过计算观测值与通过 PQMLE 方法获得的条件均值估计值之差得到模型残差。

1.3 主要研究内容和文章结构

本文主要研究了连续值和整值时间序列中，无分布假定的稳健在线监测方法。具体研究内容及结构安排如下：

第一章，介绍了本文的研究背景以及研究对象，并归纳了相关的研究成果。

第二章，针对连续值时间序列的分布变点监测问题，本文提出了一个基于经验特征函数的自正则在线监测方法。本文从理论上研究了该方法在原假设和备择假设下的渐近性质。由于在原假设下的渐近分布相当复杂，本文使用多元 Stationary Bootstrap 方法估计序贯检验的临界值。数值模拟表明，本文所提方法能够有效地控制第一类错误率。最后将该方法应用于风机叶片振动数据，展示了其在实际场景中的应用潜力。

第三章介绍了半参数框架下的整值时间序列模型及其参数变点监测问题。本文提出了一种基于 PQMLE 的修正 CUSUM 在线监测方法。首先，对于训练样本，采用 PQMLE 方法得到参数估计。其次，并计算模型的残差，并基于模型残差构造修正 CUSUM 统计量，定义在线监测方法的停止规则。随后，从理论上研究了所提在线监测方法的渐近性质，并通过数值模拟展示了该方法的有效性。

第四章，对本文的研究内容和成果进行总结，分析了研究中存在的不足，并对未来的研究方向进行展望。

第 2 章　基于特征函数的自正则在线监测方法

非参数在线监测方法旨在快速检测数据流中概率分布函数的结构变化。然而，当观测值之间的时间依赖性较强时，现有非参数在线监测方法往往难以有效控制第一类错误率。为解决这一问题，本文提出一种基于经验特征函数的非参数自正则在线监测方法。该方法通过引入额外的自正则因子，有效避免了第一类错误率的扭曲问题。本章内容安排如下：2.1 节介绍了概率分布函数的变点监测问题，并给出所提自正则监测统计量。2.2 节研究了该统计量在原假设和备择假设下的渐近性质。由于原假设下的渐近分布较为复杂，本文采用多元 Stationary Bootstrap 方法来估计序贯检验的临界值。2.3 节和 2.4 节分别通过数值模拟和实例分析展示了所提方法的有效性。2.5 节给出本章主要定理的证明，2.6 节为本章小节。

2.1　自正则在线监测方法

令 $\{\boldsymbol{X}_t\}_{t\in\mathbb{Z}}$ 为一个 d 维时间序列，其概率分布函数为 $F_t(\boldsymbol{u}) = \Pr(\boldsymbol{X}_t \le \boldsymbol{u})$, $\boldsymbol{u} \in \mathbb{R}^d$。本章所考虑的概率分布函数的变点监测问题如下。在监测开始之前，假设已收集到一组平稳的历史观测 $\{\boldsymbol{X}_1, \cdots, \boldsymbol{X}_m\}$，其满足 $F_1 = \cdots = F_m$。这些收集到的数据被称为训练样本。随后，新的样本 $\boldsymbol{X}_{m+1}, \boldsymbol{X}_{m+2}, \ldots$ 逐步到达。非参数在线监测方法旨在快速检测数据流中分布函数的结构变化，即连续检验以下假设[11]：

$$\begin{aligned} H_0 &: F_t = F_m, t = m+1, m+2, \cdots, m+Lm, \\ H_1 &: F_t = F_m, m+1 \le t \le m+k^*; F_t \ne F_m, m+k^*+1 \le t \le m+Lm, \end{aligned} \tag{2-1}$$

其中 F_m，F_t 表示未知的分布函数，$m+k^*(k^* \ge 0)$ 为未知的变点，L 为预先指定的监测周期。上述原假设可以等价地表示为

$$H_0 : \phi_t = \phi_m, t = m+1, m+2, \cdots, m+Lm, \tag{2-2}$$

其中 $\phi_t = \mathrm{E}\left(\mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle}\right)$ 是随机向量 $\boldsymbol{X}_t$ 的特征函数，$i = \sqrt{-1}$ 为虚数单位，$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \boldsymbol{x}^\top \boldsymbol{y}$ 表示向量的内积。

根据监测周期的不同，在线监测方法可分为封闭式（$0 < L < \infty$）和开放式（$L = \infty$）两类。对于封闭式方法，若始终未检测到结构变化，则在收集到固定数量（Lm）的新样本后停止监测。开放式在线监测方法则可能会无限期地持续运行。关于封闭式与开放式在线监测方法的渐近理论之间的技术差异，可参考 Kirch 和 Weber[49] 以及 Gösmann 等人[24] 的讨论。在非参数框架下，研究开放式在线监测方法的渐近理论并不容易[12]。因此，本文仅研究封闭式非参数在线监测方法。

在新的样本 $\boldsymbol{X}_{m+k}(k \geq 1)$ 到达时，非参数在线监测方法将比较训练样本与新到达样本之间的分布差异[11]，这等价于比较二者的特征函数[12]。考虑到自正则方法能够有效控制第一类错误率，受到 Chan 等人[36] 的启发，本文提出以下基于经验特征函数的自正则 CUSUM 统计量：

$$\Gamma_m SN(k) = \frac{\Gamma_m(k)}{S_m^2}, k = 1, 2, \ldots, Lm, \tag{2-3}$$

其中

$$\begin{aligned} \Gamma_m(k) &= \frac{(m+k)^2}{m} \int_{\mathbb{R}^d} \left|\hat{\phi}_{1:m}(\boldsymbol{u}) - \hat{\phi}_{1:m+k}(\boldsymbol{u})\right|^2 \omega(\boldsymbol{u}) d\boldsymbol{u}, \\ S_m^2 &= \frac{1}{m^2} \sum_{t=1}^{m} \int_{\mathbb{R}^d} t^2 \left|\hat{\phi}_{1:t}(\boldsymbol{u}) - \hat{\phi}_{1:m}(\boldsymbol{u})\right|^2 \omega(\boldsymbol{u}) d\boldsymbol{u}, \end{aligned} \tag{2-4}$$

其中 k 表示监测开始后新到达样本的数量，$\hat{\phi}_{a:b}(\boldsymbol{u}) = \frac{1}{b-a+1} \sum_{t=a}^{b} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle}$ 是基于样本 $\{\boldsymbol{X}_a, \ldots, \boldsymbol{X}_b\}$ 的经验特征函数。$\Gamma_m(k)$ 是 Lee 等人[12] 采用的 CUSUM 统计量，S_m^2 是本文引入的自正则因子。$\omega(\boldsymbol{u})$ 是一个适当选取的权重函数，以保证式 (2-4) 中的积分存在。若 $\omega(\boldsymbol{u})$ 为非负对称的可积函数，则有

$$\begin{aligned} \Gamma_m(k) &= \frac{(m+k)^2}{m} \left\{ \frac{1}{m^2} \sum_{\mu,\nu=1}^{m} H_{\mu,\nu} + \frac{1}{(m+k)^2} \sum_{\mu,\nu=1}^{m+k} H_{\mu,\nu} - \frac{2}{m(m+k)} \sum_{\mu=1}^{m} \sum_{\nu=1}^{m+k} H_{\mu,\nu} \right\}, \\ S_m^2 &= \frac{1}{m^2} \sum_{t=1}^{m} t^2 \left\{ \frac{1}{m^2} \sum_{\mu,\nu=1}^{m} H_{\mu,\nu} + \frac{1}{t^2} \sum_{\mu,\nu=1}^{t} H_{\mu,\nu} - \frac{2}{mt} \sum_{\mu=1}^{m} \sum_{\nu=1}^{t} H_{\mu,\nu} \right\}, \end{aligned} \tag{2-5}$$

其中 $H_{\mu,\nu} = H(\boldsymbol{X}_\mu - \boldsymbol{X}_\nu)$，$H(\boldsymbol{x}) = \int_{\mathbb{R}^d} \cos\langle \boldsymbol{x}, \boldsymbol{u}\rangle \omega(\boldsymbol{u}) d\boldsymbol{u}$。有多种权重函数可以得到 $H(\boldsymbol{x})$ 的显示表达，参见 Fan 等人[50]。通常，权重函数的选择是出于计算便捷性的考虑[1]。遵照 Lee 等人[12]，本文将权重函数设定为 $\omega(\boldsymbol{u}) = \exp\left(-a\|\boldsymbol{u}\|^2\right)$，其中 $a > 0$ 为可调参数，$\|\cdot\|$ 为欧式范数。随后，直接计算可得 $H(\boldsymbol{x}) = (\frac{\pi}{a})^{d/2} \exp\{-\frac{\|\boldsymbol{x}\|^2}{4a}\}$。

如果 $\{\boldsymbol{X}_t\}$ 的分布函数在某一时刻 $m + k^*$ 后发生变化，那么对于 $k > k^*$，统计量 $\Gamma_m^{SN}(k)$ 的值将显著增大。因此，当 $\Gamma_m^{SN}(k)$ 的取值过大时，应拒绝原假设。统计量 $\Gamma_m^{SN}(k)$ 的取值是否过大由一个边界函数 $q(\frac{k}{m})$ 决定[35]。具体而言，当以下条件首次成立时拒绝原假设：

$$D_m^{SN}(k) \stackrel{\Delta}{=} \frac{1}{q^2(\frac{k}{m})} \Gamma_m^{SN}(k) > C_\alpha, \tag{2-6}$$

其中 C_α 为序贯检验的临界值，由统计量 $\max\limits_{1 \leq k \leq Lm} D_m^{SN}(k)$ 在原假设下的渐近分布确定。也就是说，当 CUSUM 统计量 $\Gamma_m^{SN}(k)$ 首次超过临界曲线 $C_\alpha q^2(\frac{k}{m})$ 时，拒绝原假设并发出报警。边界函数 $q(\cdot)$ 用于控制在线监测方法的渐近第一类错误率[12,51]。根据 Chan 等人[36] 的方法，本文选择的边界函数为 $q(\theta) = (1 + \theta)$，$\theta > 0$。本文将

$D_{SN}^{m}(k)$ 作为最终的自正则监测统计量。为便于比较，令 $D_m(k) \stackrel{\Delta}{=} \frac{1}{q^2(\frac{k}{m})}\Gamma_m(k)$ 表示未引入自正则因子的监测统计量。

本文所提在线监测方法遵循以下停止规则：

$$\tau(m) = \begin{cases} \inf\{k : D_m^{SN}(k) > C_\alpha, 1 \le k \le L_m\}, \\ Lm+1, D_m^{SN}(k) \le C_\alpha, \forall 1 \le k \le L_m, \end{cases} \tag{2-7}$$

其中 $\tau(m)$ 表示结束监测的时间点。当自正则监测统计量 D_m^{SN} 超过临界值 C_α，或新收集数据的样本量达到预定值 Lm 时，停止监测。具体来说，从 $k=1$ 开始，依次检查条件 $D_m^{SN}(k) > C_\alpha$ 是否成立。如果该条件成立，则令 $\tau(m) = k$ 并拒绝零假设。否则，待新的样本 $\boldsymbol{X}_{m+k+1}$ 到达后，再次检查条件 $D_m^{SN}(k+1) > C_\alpha$。如果在整个监测期内都没有拒绝原假设，则停止监测并设定 $\tau(m) = Lm+1$。

2.2 渐近性质

本节将首先研究监测统计量在原假设下的渐近分布，做出如下假设[1]：

假设 2.1 假设 $\{\boldsymbol{X}_t\}$ 是一个 d 维严平稳强混合序列，其混合系数为 $\alpha(h)$。对于某些常数 $\kappa > 0$ 和 $\delta > 0$，存在常数 $C = C(\kappa, \delta)$ 使得 $\sum_{h=0}^{\infty}(h+1)^{\frac{\kappa}{2}}\alpha(h)^{\frac{\delta}{2+\kappa+\delta}} \le C$。此外，假设 $\mathrm{E}\|\boldsymbol{X}_t\|^{2+\kappa+\delta} < \infty$。

假设 2.2 $\omega(\boldsymbol{u})$ 是一个非负对称可积函数且 $\int_{\mathbb{R}^d}\|\boldsymbol{u}\|^4\omega(\boldsymbol{u})d\boldsymbol{u} < \infty$。

假设2.1中的强混合条件限制了 $\{\boldsymbol{X}_t\}$ 的时间依赖程度。混合系数 $\alpha(h)$ 用于衡量间隔一定时间的子序列之间的时间依赖性。对于时间序列 $\{\boldsymbol{X}_t\}$ 和 $h \in \mathbb{N}$，定义强混合系数 $\alpha(h) = \sup_{A\in\mathcal{F}_{-\infty}^0, B\in\mathcal{F}_h^\infty}|P(A\cap B) - P(A)P(B)|$，其中 $\mathcal{F}_b^a$ 表示由 $\{\boldsymbol{X}_t; a \le t \le b\}$ 生成的 σ-代数。如果当 $h \to \infty$ 时有 $\alpha(h) \to 0$，则称 $\{\boldsymbol{X}_t\}$ 为强混合序列。假设2.2则是对权重函数 $\omega(\boldsymbol{u})$ 所施加的一些条件，一些四阶矩有限的对称分布的概率密度函数满足该假设[33]。在原假设下，监测统计量的渐近分布如下。

定理 2.1 若假设2.1和2.2成立，则在原假设下，当 $m \to \infty$ 时，

$$\max_{1\le k\le Lm} D_m^{SN}(k) \tag{2-8}$$

的极限分布与

$$\sup_{\theta\in(0,L)} \frac{1}{(1+\theta)^2}\frac{\int_{\mathbb{R}^d}\left(Z_1(\theta,\boldsymbol{u}) - \theta Z_2(1,\boldsymbol{u})\right)^2\omega(\boldsymbol{u})d\boldsymbol{u}}{\int_0^1\int_{\mathbb{R}^d}\left(Z(\theta',\boldsymbol{u}) - \theta' Z(1,\boldsymbol{u})\right)^2\omega(\boldsymbol{u})d\boldsymbol{u}d\theta'} \tag{2-9}$$

的分布相同。$Z(\theta,\boldsymbol{u})$ 为一零均值高斯过程，其协方差结构为

$$\mathrm{Cov}\{Z(\theta_1,\boldsymbol{u}_1), Z(\theta_2,\boldsymbol{u}_2)\} = \theta_1 \wedge \theta_2 \Sigma(\boldsymbol{u}_1,\boldsymbol{u}_2),$$

其中 $\Sigma(\boldsymbol{u}_1,\boldsymbol{u}_2)=\sum_{j=0}^{\infty}\mathrm{Cov}\big(h_1(\boldsymbol{u}_1),h_{1+j}(\boldsymbol{u}_2)\big)+\sum_{j=1}^{\infty}\mathrm{Cov}\big(h_1(\boldsymbol{u}_2),h_{1+j}(\boldsymbol{u}_1)\big)$，$\theta_1\wedge\theta_2=\min(\theta_1,\theta_2)$，$h_t(\boldsymbol{u})=\cos\langle\boldsymbol{X}_t,\boldsymbol{u}\rangle+\sin\langle\boldsymbol{X}_t,\boldsymbol{u}\rangle$。$Z_1(\theta,\boldsymbol{u})$ 和 $Z_2(\theta,\boldsymbol{u})$ 是两个独立的零均值高斯过程，有着与 $Z(\theta,\boldsymbol{u})$ 相似的协方差结构。

定理2.1给出了监测统计量在原假设下的渐近分布。检验的临界值 C_α 可取为该分布的 $1-\alpha$ 分位数，从而确保该在线监测方法具有渐近为 α 的检验水平：

$$\begin{aligned}&\lim_{m\to\infty}\Pr(\tau(m)<\infty\mid H_0)\\&=\Pr\left(\sup_{\theta\in(0,L)}\frac{1}{(1+\theta)^2}\frac{\int_{\mathbb{R}^d}\big(Z_1(\theta,\boldsymbol{u})-\theta Z_2(1,\boldsymbol{u})\big)^2\omega(\boldsymbol{u})d\boldsymbol{u}}{\int_0^1\int_{\mathbb{R}^d}\big(Z(\theta',\boldsymbol{u})-\theta' Z(1,\boldsymbol{u})\big)^2\omega(\boldsymbol{u})d\boldsymbol{u}d\theta'}>C_\alpha\right).\end{aligned}\tag{2-10}$$

定理2.1中的渐近结果是基于本文默认选择的边界函数 $q(\theta)=(1+\theta)$，$\theta>0$ 得到的。已有许多学者研究了边界函数的不同选择[6,17,49,51]。Dette 和 Gösmann[3] 指出，可以选择一个合适的函数（增函数且有一个正的下界，或者满足 Weber[52] 给出的一些正则性条件）来作为边界函数。

接下来研究监测统计量在备择假设下的渐近性质，进行如下假设：

假设 2.3 假设 $k^*=\lfloor m\theta_*\rfloor$，$\theta_*\in(0,L)$ 是变点，其中 $\lfloor x\rfloor$ 表示不超过 x 的最大整数。令 ϕ_t 为 $\boldsymbol{X}_t$ 的特征函数，那么在备择假设下，

$$\phi_t=\begin{cases}\phi_{(0)},t=1,\ldots,m+k^*,\\ \phi_{(*)},t=m+k^*+1,\cdots,Lm,\end{cases}\tag{2-11}$$

其中 $\phi_{(0)}$ 和 $\phi_{(*)}$ 分别表示变点前后不同的特征函数。

定理 2.2 若假设2.2和2.3成立，则在备择假设下，当 $m\to\infty$ 时，

$$\max_{1\le k\le Lm}D_m^{SN}(k)\xrightarrow{\Pr}\infty.\tag{2-12}$$

定理2.2表明所提出的在线监测方法在备择假设下具有一致性。当 $\{\boldsymbol{X}_t\}$ 的分布发生变化时，该方法的检验功效渐近为 1，即 $\lim_{m\to\infty}\Pr(\tau(m)<\infty\mid H_1)=1$。

从定理2.1中可以看出，监测统计量在原假设下的渐近分布相当复杂，通过渐近分布确定临界值 C_α 并不容易。因此，本文采用多元 Stationary Bootstrap 方法[53]来估计序贯检验的临界值。令 $\{U_j\}_{j\ge1}$ 和 $\{l_j\}_{j\ge1}$ 为一系列独立的随机变量，其中 U_j 服从 $\{1,\cdots,m\}$ 上的离散均匀分布，l_j 服从参数为 p_b 的几何分布。另外，定义 R_{U_j,l_j} 为一个从 $\boldsymbol{X}_{U_j}$ 开始且块长为 l_j 的随机块，即 $R_{U_j,l_j}=\{\boldsymbol{X}_{U_j},\cdots,\boldsymbol{X}_{U_j+l_j-1}\}$。块长参数 p_b 决定了随机块 R_{U_j,l_j} 的平均长度。

Stationary Bootstrap 方法从训练样本 $\{\boldsymbol{X}_1,\ldots,\boldsymbol{X}_m\}$ 中抽取随机块生成伪样本。对于单变量时间序列（$d=1$），Politis 和 White[54] 提出了一个自适应选择算法，用于确定块长参数 p_b。对于多元时间序列（$d>1$），依据 Jentsch 和 Rao[55] 的建议，

本文将该自适应选择算法应用于每个子序列，并得到 d 个块长参数 $\{p_{b1},\cdots,p_{bd}\}$。随后，使用这 d 个块长参数的调和平均数作为整体块长参数，即 $p_b=\frac{d}{\frac{1}{p_{b1}}+\cdots+\frac{1}{p_{bd}}}$。多元 Stationary Bootstrap 方法的具体步骤如下：

(1) 将训练样本 $\{\boldsymbol{X}_1,\ldots,\boldsymbol{X}_m\}$ 按照时间下标首尾相连，构成一个圆环。

(2) 从训练样本构成的圆环中连续抽取随机块 $R_{U_j,l_j}, j=1,\ldots,$ 直到得到的随机块 $(R_{U_1,l_1},\cdots,R_{U_n,l_n})$ 的块长之和满足 $\sum_{j=1}^{n} l_j \geq m+Lm$。将这些随机块依次相连，选择前 $m+Lm$ 个样本作为 Bootstrap 样本，记为 $\{\boldsymbol{X}_1^*,\ldots,\boldsymbol{X}_{m+Lm}^*\}$。

(3) 将前 m 个 Bootstrap 样本视为平稳的训练样本 $\{\boldsymbol{X}_1^*,\ldots,\boldsymbol{X}_m^*\}$，计算统计量 $D^*=\max\limits_{1\leq k\leq Lm} D_m^{SN}(k)$。

(4) 重复步骤(2)-(3)共 B 次，将得到的 B 个统计量从小到大排序为 $D_1^*,\cdots,D_B^*$。临界值的估计为 $\hat{C}_\alpha=D^*_{\lfloor B(1-\alpha)\rfloor}$。

根据 Lee 等人[12] 和 Jentsch 与 Rao[55] 的建议，本文采用 Stationary Bootstrap 方法估计序贯检验的临界值。关于 Stationary Bootstrap 方法的一致性，Lee 等人[12] 在其框架内已提供了严格证明。此外，Weber[52] 对广泛使用的 Block Bootstrap 方法的一致性进行了详细证明。本文暂未涉及证明所用 Bootstrap 方法的一致性，这部分内容超出了当前讨论的范围，将在未来的研究中进一步探讨。第2.3节的数值模拟与第2.4节的实际案例分析验证了所用 Bootstrap 方法的有效性，研究结果表明该方法在实际应用中表现良好。

2.3 数值模拟

本节通过数值模拟研究所提在线监测方法的有限样本表现。序贯检验在显著性水平 $\alpha=5\%$ 下进行，所有模拟结果均基于 1000 次重复实验得到。训练样本量设定为 $m=\{100,200\}$，监测周期为 $L=\{1,2,3\}$。首先，本节将 D_m^{SN} 与未引入自正则因子的监测统计量 D_m 进行比较，后者定义为 $D_m \overset{\Delta}{=} \frac{1}{q^2(\frac{k}{m})}\Gamma_m(k)$。对于监测统计量 D_m 和 D_m^{SN} 中的权重函数 $\omega(u)$，其可调参数设定为 $a=1$。由于监测统计量 D_m 和 D_m^{SN} 的计算耗时较长，遵循 Lee 等人[12] 的建议，本文采用 wrap-speed 方法[56] 进行模拟实验。

此外，本文还将所提方法与另外两种基于经验分布函数的在线监测方法进行比较。这两种对比方法分别记作 $Q_{m,k}$ 和 $T_{m,q}$，它们分别是基于经验分布函数的标准 CUSUM 统计量和修正型 CUSUM 统计量，详细形式参见 Kojadinovic 和 Verdier[11]。本节主要比较了这些非参数在线监测方法的经验水平、经验势和平均检测延迟（即首次报警时间与实际变点之间的时间间隔）。

2.3.1 原假设下的模拟结果

本小节主要研究在线监测方法在原假设下的有限样本表现。为便于说明，令 $\mathbf{0}$ 表示二维零向量，I_2 表示二阶单位矩阵。除非特别指定，$\boldsymbol{\epsilon}_t$ 均假设为独立同分布的二元标准正态随机向量，即 $\boldsymbol{\epsilon}_t \overset{i.i.d.}{\sim} N(\mathbf{0}, I_2)$。受 Kojadinovic 和 Verdier[11] 的启发，首先考虑了一系列具有不同回归系数的二元 AR(1) 模型。即 $\boldsymbol{X}_t = \beta \boldsymbol{X}_{t-1} + \boldsymbol{\epsilon}_t$，$\beta \in \{0, 0.3, 0.5, 0.7, 0.9, -0.3, -0.5, -0.7, -0.9\}$。将这些模型依次记作 N_1 至 N_9。从模型 N_1 至 N_5，随着 β 从 0 增加到 0.9，样本观测之间的时间依赖性逐步增强。而模型 N_6 至 N_9 中系数为负，β 的绝对值依次增加。本节还考虑了两个分别具有较弱和较强时间依赖性的向量自回归模型，分别记作 N_{10} 和 N_{11}。最后，BEKK-GARCH(1,1) 模型 N_{12} 来自于 Hlávka 等人[1] 的研究。

(N_{10}) $\boldsymbol{X}_t = \boldsymbol{A}_0 \boldsymbol{X}_{t-1} + \boldsymbol{\epsilon}_t$，其中 $\boldsymbol{A}_0 = \begin{pmatrix} 0.1 & 0.05 \\ 0.05 & 0.1 \end{pmatrix}$。

(N_{11}) $\boldsymbol{X}_t = \boldsymbol{A}_1 \boldsymbol{X}_{t-1} + \boldsymbol{\epsilon}_t$，其中 $\boldsymbol{A}_1 = \begin{pmatrix} 0.5 & 0.2 \\ 0.2 & 0.1 \end{pmatrix}$。

(N_{12}) BEKK-GARCH(1,1) 模型：

$$\begin{cases} \boldsymbol{X}_t = \boldsymbol{H}_t^{\frac{1}{2}} \boldsymbol{\epsilon}_t, \boldsymbol{\epsilon}_t \sim N(\mathbf{0}, I_2), \\ \boldsymbol{H}_t = C^\top \boldsymbol{C} + \boldsymbol{A}^\top \boldsymbol{X}_{t-1} \boldsymbol{X}_{t-1}^\top \boldsymbol{A} + \boldsymbol{B}^\top \boldsymbol{H}_{t-1} \boldsymbol{B}, \end{cases}$$

其中 $\boldsymbol{C} = 10^{-3} \begin{pmatrix} 4 & 5 \\ 0 & 3 \end{pmatrix}$，$\boldsymbol{A} = \begin{pmatrix} 0.254 & -0.004 \\ 0.04 & 0.332 \end{pmatrix}$，$\boldsymbol{B} = \begin{pmatrix} 0.941 & 0.023 \\ -0.019 & 0.864 \end{pmatrix}$。

表2-1为所有非参数在线监测方法的经验水平。在模型 N_1（$\beta = 0$）中，$\boldsymbol{X}_t$ 为一系列独立同分布的随机向量。此时，所有在线监测方法的经验水平都接近于名义水平。从模型 N_2 到 N_5（β 从 0.3 逐步增加到 0.9），样本观测之间的时间依赖性依次增强。随着时间依赖性增加，$Q_{m,k}$，$T_{m,q}$ 以及 D_m 的经验水平逐渐扭曲。这与 Kojadinovic 和 Verdier[11] 发现的结果是一致的。相比之下，自正则在线监测方法 D_m^{SN} 保持了较好的经验水平。当 β 取值为负时（模型 N_6 到 N_9，β 从 -0.3 逐步变为 -0.9），时间依赖性对经验水平的影响不如 β 为正值时明显。但是，当 β 的绝对值较大时（模型 N_8，$\beta = -0.7$ 和模型 N_9，$\beta = -0.9$），仍然只有自正则方法 D_m^{SN} 表现良好。对于向量自回归模型 N_{10} 和 N_{11}，D_m^{SN} 表现较好，而另外三种方法的经验水平出现了明显扭曲。在 BEKK-GARCH(1,1) 模型 N_{12} 中，基于经验分布函数的方法（$Q_{m,k}$ 和 $T_{m,q}$）的经验水平严重扭曲，而基于经验特征函数的方法（D_m 和 D_m^{SN} ）则表现较好。总体而言，无论时间依赖性强弱，本文提出的自正则在线监测方法 D_m^{SN} 都能较好地控制第一类错误率。

表 2-1　所有非参数在线监测方法的经验水平（%）

	m	L	N_1	N_2	N_3	N_4	N_5	N_6	N_7	N_8	N_9	N_{10}	N_{11}	N_{12}
$Q_{m,k}$	100	1	5.7	7.2	10.5	11.5	22.4	4.8	6.7	7.5	17.0	7.2	9.7	9.7
		2	5.2	8.2	11.6	14.0	23.8	6.0	5.4	5.4	14.2	6.4	12.2	8.6
		3	5.4	8.7	9.8	13.4	24.4	5.7	3.5	7.7	16.0	6.2	11.8	10.1
	200	1	6.5	6.6	8.6	11.2	14.9	6.5	4.9	7.0	12.6	6.0	10.6	9.7
		2	4.7	6.7	8.3	11.4	17.8	5.8	4.9	5.4	12.0	5.8	9.5	7.9
		3	5.2	7.0	7.9	10.4	20.2	5.8	5.1	6.2	12.2	5.5	8.5	8.5
$T_{m,q}$	100	1	5.1	8.0	10.7	12.8	23.6	4.5	4.8	3.5	10.9	7.3	12.3	9.7
		2	5.8	7.0	9.8	12.8	24.3	3.2	3.9	3.5	12.2	7.0	9.4	8.9
		3	5.3	7.6	10.5	13.2	26.7	6.2	4.4	6.2	14.7	6.8	11.0	12.2
	200	1	4.7	7.5	8.0	11.8	16.9	5.2	4.6	4.8	9.5	5.5	9.6	9.1
		2	5.3	6.4	8.9	11.1	17.3	4.3	4.0	3.7	10.2	5.9	8.6	7.8
		3	5.0	7.1	8.2	12.0	18.8	4.5	4.6	5.9	12.6	5.3	9.2	8.7
D_m	100	1	5.8	7.2	11.4	13.9	31.5	3.9	5.9	9.6	14.5	7.0	13.3	4.2
		2	5.7	8.8	12.2	16.0	29.3	5.1	6.2	8.4	12.6	6.2	10.9	3.4
		3	4.9	6.3	9.4	10.7	34.0	3.7	5.6	9.7	14.2	5.2	11.5	3.7
	200	1	4.6	7.3	9.5	12.1	23.3	3.7	4.8	7.2	9.7	6.6	10.4	4.9
		2	4.0	7.2	8.7	10.1	19.6	4.1	5.5	9.9	8.5	6.8	11.2	5.7
		3	5.2	7.5	9.2	10.0	23.5	4.4	4.7	9.0	8.5	7.5	9.8	4.8
D_m^{SN}	100	1	5.0	4.0	5.6	6.6	4.0	3.7	4.4	3.6	3.4	4.7	6.3	4.2
		2	4.5	5.1	4.9	5.7	5.4	3.6	4.1	4.4	4.6	4.6	6.5	3.8
		3	5.9	5.6	4.3	4.1	4.3	2.9	3.1	3.9	3.7	4.0	6.2	4.5
	200	1	4.8	3.8	5.0	3.9	5.2	4.1	3.1	4.8	5.8	4.9	4.1	5.2
		2	4.3	5.3	4.3	5.2	5.4	2.5	5.3	4.5	3.1	4.4	5.2	5.5
		3	5.1	4.0	5.1	4.6	3.5	3.9	3.9	4.1	3.2	5.8	5.6	5.4

2.3.2　备择假设下的模拟结果

本节在上一小节模型的基础上，引入了均值或方差的结构变化，以评估所有非参数在线监测方法在备择假设下的表现。本节主要比较了在线监测方法的经验势和平均检测延迟。在本节中，假设变点位于 $m+k^*$，$0<k^*<Lm$。令 δ 表示变化幅度，$\mathbf{I}_S$ 表示集合 S 的示性函数。以下是本节所考虑的模型：

均值变化

(M$_1$) $\boldsymbol{X}_t = \boldsymbol{\epsilon}_t + \delta\boldsymbol{\mu}_1\mathbf{I}_{\{t>m+k^*\}}$，其中 $\boldsymbol{\mu}_1 = (1,1)^\top$。

(M$_2$) $\boldsymbol{X}_t = \boldsymbol{A}\boldsymbol{X}_{t-1} + \boldsymbol{\epsilon}_t + \delta\boldsymbol{\mu}_1\mathbf{I}_{\{t>m+k^*\}}$，其中 $\boldsymbol{A} = \begin{pmatrix} 0.1 & 0.05 \\ 0.05 & 0.1 \end{pmatrix}$，$\boldsymbol{\mu}_1 = (1,1)^\top$。

(M$_3$) 与 M$_2$ 中的情况相同，只是 $\boldsymbol{A} = \begin{pmatrix} 0.5 & 0.2 \\ 0.2 & 0.1 \end{pmatrix}$。

方差变化

(V$_1$) $\boldsymbol{X}_t = \boldsymbol{\epsilon}_t$，其中 $\boldsymbol{\epsilon}_t = \boldsymbol{\eta}_t\mathbf{I}_{\{t\le m+k^*\}} + \boldsymbol{\eta}_t^*\mathbf{I}_{\{t>m+k^*\}}$，$\boldsymbol{\eta}_t \sim N(\mathbf{0}, I_2)$，$\boldsymbol{\eta}_t^* \sim N\left(\mathbf{0}, (1+\delta)I_2\right)$。

(V$_2$) $\boldsymbol{X}_t = \boldsymbol{A}\boldsymbol{X}_{t-1} + \boldsymbol{\epsilon}_t$，其中 $\boldsymbol{A} = \begin{pmatrix} 0.1 & 0.05 \\ 0.05 & 0.1 \end{pmatrix}$，$\boldsymbol{\epsilon}_t$ 与 V$_1$ 中的一样。

(V$_3$) 与 V$_2$ 中的情况相同，只是 $\boldsymbol{A} = \begin{pmatrix} 0.5 & 0.2 \\ 0.2 & 0.1 \end{pmatrix}$。

(V$_4$) 令 $\boldsymbol{X}_t$ 为如模型 N$_{12}$ 所示的 BEKK-GARCH (1,1) 模型，其误差项各分量的方差发生变化：$\boldsymbol{\epsilon}_t = \boldsymbol{\eta}_t\mathbf{I}_{\{t\le m+k^*\}} + \boldsymbol{\eta}_t^*\mathbf{I}_{\{t>m+k^*\}}$，$\boldsymbol{\eta}_t \sim N(\mathbf{0}, I_2)$，$\boldsymbol{\eta}_t^* \sim N\left(\mathbf{0}, (1+\delta)I_2\right)$。

对于均值发生变化模型 M$_1$-M$_3$，样本之间的时间依赖性逐渐增强。在时刻 $m+k^*$ 之后，它们的均值向量由 $\mathbf{0}$ 变为 $\delta\boldsymbol{\mu}_1$。在方差发生变化的模型 V$_1$-V$_4$ 中，误差项各分量的方差由 1 变为 $1+\delta$。

首先比较所有在线监测方法在不同变化幅度 δ 下的经验势和平均检测延迟。令训练样本量和监测周期分别为 $m = 100$ 和 $L = 1$，变点的位置为 $m + k^* = 120$。检测延迟的计算方式为 $\tau(m) - (m + k^*)$。参照 Dette 和 Gösmann[3]，在计算经验平均检测延迟时，将没有拒绝原假设和提前拒绝原假设（错误报警，$\tau(m) < m + k^*$）的模拟实验排除在外。

图2-1展示了所有在线监测方法的平均检测延迟和经验势。左列为在不同模型下的平均检测延迟，右列为相应的经验势。无论是均值还是方差发生变化，基于经验特征函数的在线监测方法（D_m 和 D_m^{SN}）的检测延迟都明显短于基于经验分布函数的在线监测方法（$Q_{m,k}$ 和 $T_{m,q}$）。在经验势方面，D_m^{SN} 的经验势相较于 D_m 有所下降，特别是在时间依赖性较强的情形下（模型 M$_3$ 和 V$_3$）。在这两个模型下，D_m^{SN} 更为稳定，能够有效控制第一类错误率，而 D_m 则表现不佳。在方差发生变化的模型中，基于经验特征函数的方法（D_m^{SN} 和 D_m）明显优于基于经验分布函数的方法（$Q_{m,k}$ 和 $T_{m,q}$）。总体而言，本文所提方法在检测延迟方面优于基于分布函数的在线监测方法，且有着较好的检验势。

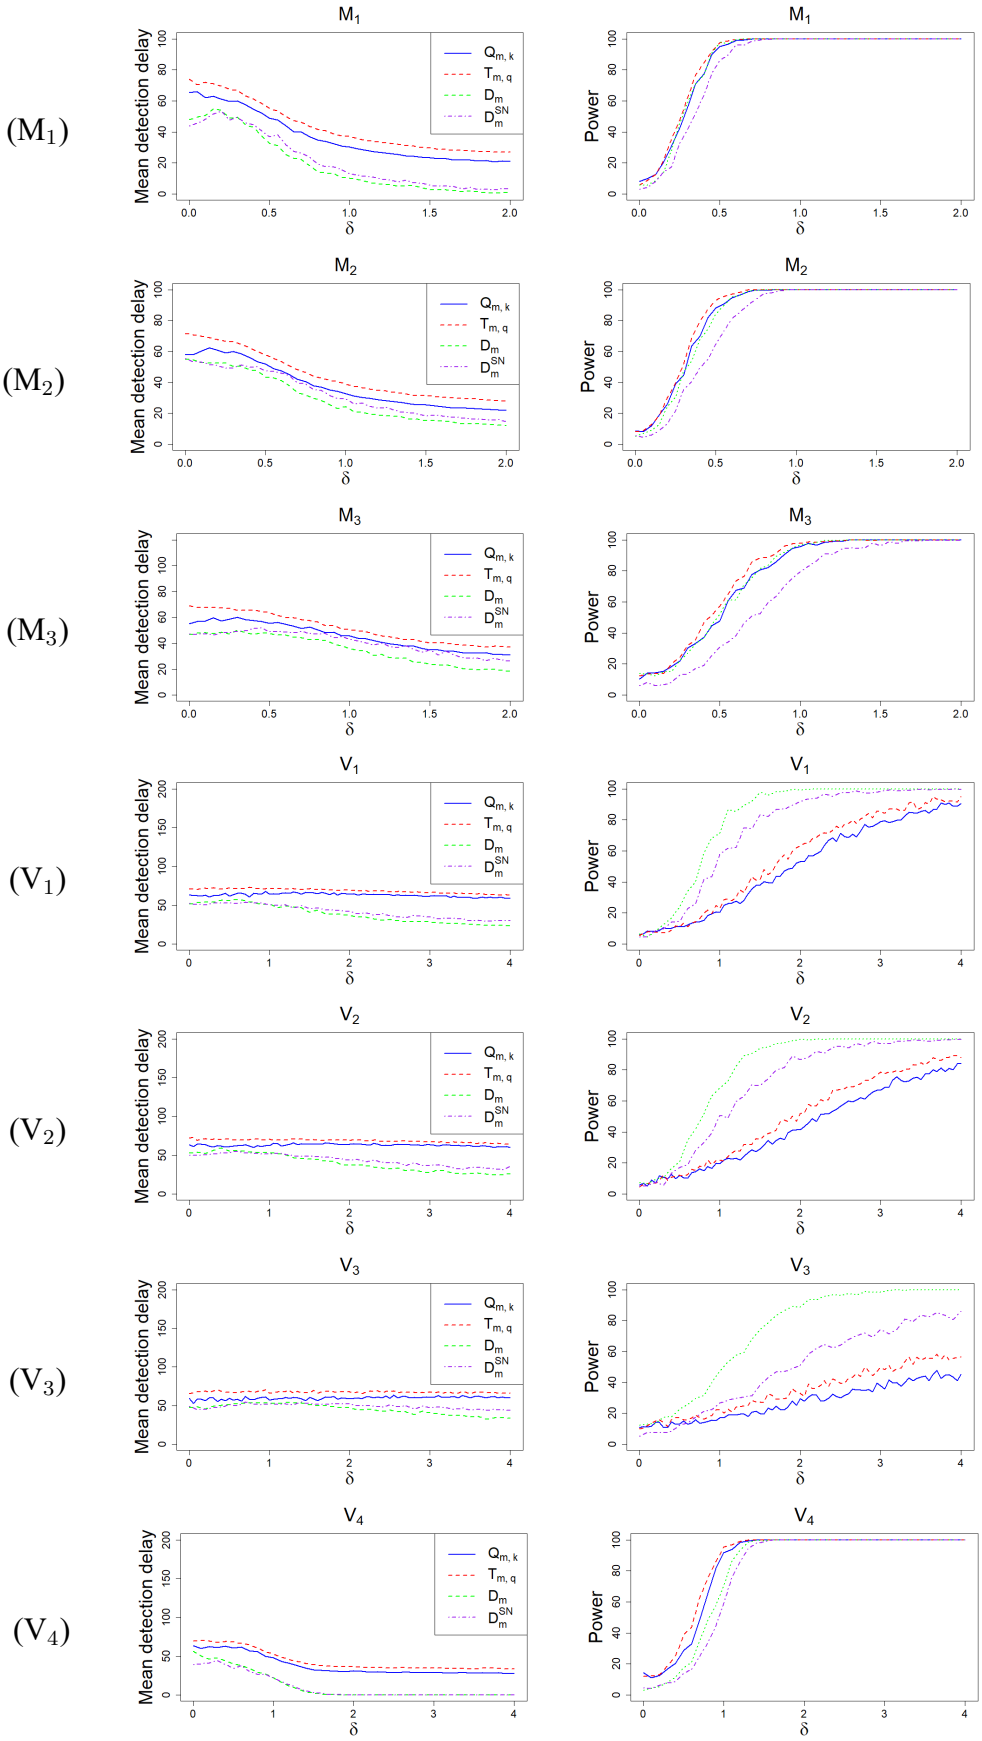

图 2-1　所有非参数在线监测方法的平均检测延迟和经验势（%）

接下来将比较所有在线监测方法对不同位置变点的整体检测能力。对于每个备择假设下的模型（M_1-M_3 以及 V_1-V_4），首先将变化幅度 δ 固定。在模型 M_1-M_3 中，序列 $\boldsymbol{X}_t$ 的均值向量由 $\mathbf{0}$ 变为 $\boldsymbol{\mu}_1 = (1,1)^\top$，即 $\delta = 1$。在模型 V_1-V_3 中，误差项各分量的方差由 1 变为 3（$\delta = 2$）。模型 V_4 中误差项各分量的方差则由 1 变为 2（$\delta = 1$）。随后，参照 Lee 等人[12] 的设定，取随机变点为 $m + k^* = m(1 + \lfloor LU \rfloor)$，其中 U 服从区间 $(0, 0.8)$ 上的均匀分布。

表 2-2　变点随机时，所有非参数在线监测方法的经验势（%）

	m	L	$M_{1;\delta=1}$	$M_{2;\delta=1}$	$M_{3;\delta=1}$	$V_{1;\delta=2}$	$V_{2;\delta=2}$	$V_{3;\delta=2}$	$V_{4;\delta=1}$
$Q_{m,k}$	100	1	90.2	82.5	63.7	36.4	30.5	20.4	62.8
		2	91.5	89.3	73.1	40.6	36.3	21.6	65.6
		3	94.6	91.8	74.8	49.2	42.8	30.2	66.3
	200	1	94.5	94.2	77.9	53.8	52.3	29.6	79.7
		2	97.4	96.6	81.4	59.3	57.4	35.5	84.2
		3	96.9	97.1	86.7	68.4	60.0	41.3	87.1
$T_{m,q}$	100	1	99.0	98.6	84.3	45.3	33.1	26.5	82.5
		2	100.0	99.9	95.4	64.0	53.3	33.0	91.8
		3	100.0	100.0	98.2	82.4	74.6	46.1	97.6
	200	1	100.0	99.9	95.5	75.3	67.6	36.4	95.3
		2	100.0	100.0	99.4	93.3	88.3	52.5	99.2
		3	100.0	100.0	99.9	97.1	95.5	73.9	99.7
D_m	100	1	91.1	87.7	70.9	75.3	70.3	63.4	56.7
		2	91.0	91.8	80.4	80.9	76.1	64.2	43.3
		3	94.6	93.5	79.6	79.6	78.5	69.7	45.4
	200	1	95.7	95.2	83.0	89.0	87.3	74.8	63.6
		2	98.9	97.1	89.0	90.7	89.3	80.2	57.6
		3	99.1	98.5	89.7	93.0	90.6	80.5	53.7
D_m^{SN}	100	1	84.1	82.5	52.1	62.4	48.8	37.2	45.2
		2	82.6	83.3	59.1	69.9	65.7	39.1	43.7
		3	87.4	88.0	66.6	72.1	69.8	43.8	39.8
	200	1	95.1	90.8	71.3	78.8	76.8	59.3	47.0
		2	97.5	94.7	75.8	85.0	82.0	61.8	48.0
		3	96.5	94.5	82.9	86.3	80.7	66.8	44.9

表 2-2 给出了所有非参数在线监测方法在变点随机时的经验势。在模型 M_1-M_3 下，随着观测值之间的时间依赖性增强，所有方法的经验势都有所下降。模型 M_1 和 M_2 的均值发生了结构变化，且时间依赖性相对较弱。此时，所有在线监测方法的经验势较为接近。在模型 M_3 下，自正则在线监控方法 D_m^{SN} 的经验势低于 D_m。随着训练样本量的增加，二者经验势的差距逐渐缩小。对于方差变化的模型 V_1-V_3，基于经验特征函数的方法（D_m 和 D_m^{SN}）优于基于经验分布函数的方法（$Q_{m,k}$ 和 $T_{m,q}$）。在模型 V_4 下，$Q_{m,k}$ 和 $T_{m,q}$ 的经验势较高。但是，这两个方法在多元 GARCH 模型 N_{12} 下的经验水平严重扭曲，而 D_m 和 D_m^{SN} 则相对可靠。总体而言，本文所提出的自正则在线监测方法 D_m^{SN} 显著改善了经验水平的扭曲现象，并且有着不错的检验功效。

2.4 实例分析

风机叶片的振动信号表征了叶片的状态。叶片的状态监测对风机的运行维护至关重要。本文所用数据为国内某风场 #1 号和 #5 号风机的叶片振动数据。三支叶片的振动信号由叶片内的振动传感器（安装位置相同）采集。信号采集系统的采样频率为 2560 赫兹，采集间隔为 2 小时，每一批次的采样点数为 128 KB。

每一批次的叶片振动信号到达后，首先对三支叶片的振动信号进行高通滤波处理。具体来说，本文使用了低截止频率为 0.1 赫兹的 Butterworth 数字滤波器，滤波阶数设定为 10 阶。在这之后，从每批预处理后的信号中提取与叶片振动状态相关的特征。将每批数据平均分割为 8 个时段，并计算每一时段中三支叶片振动信号的有效值（Root Mean Square，RMS）：$\{\mathrm{RMS}_{t1}, \mathrm{RMS}_{t2}, \mathrm{RMS}_{t3}\}$。RMS 反映了叶片的振动强度。对于长度为 N 的信号 $\{y_1, \cdots, y_N\}$，RMS 的计算公式为：$\mathrm{RMS} = \sqrt{\frac{1}{N}\sum_{j=1}^{N} y_j^2}$。在正常运行状态下，同一台风机三支叶片的振动强度相近。基于这一特性，本文对三支叶片的 RMS 序列两两作差，得到以下监测指标：

$$\boldsymbol{X}_t = \begin{pmatrix} X_{t1} \\ X_{t2} \\ X_{t3} \end{pmatrix} = \begin{pmatrix} \mathrm{RMS}_{t1} - \mathrm{RMS}_{t2} \\ \mathrm{RMS}_{t2} - \mathrm{RMS}_{t3} \\ \mathrm{RMS}_{t3} - \mathrm{RMS}_{t1} \end{pmatrix}, t = 1, \cdots .$$

2.4.1 #1 号风机

对 #1 号风风机，本文首先从前 36 小时（即 18 批次）的振动信号中提取监测指标 $\{\boldsymbol{X}_t\}, t = 1, \cdots, 144$，并将这些数据作为训练样本。如前所述，在正常运行条件下，三片叶片的振动强度相近。如图2-2（a）和（b）所示，训练阶段内三支叶片的振动幅度非常接近，表明叶片的整体状态良好。

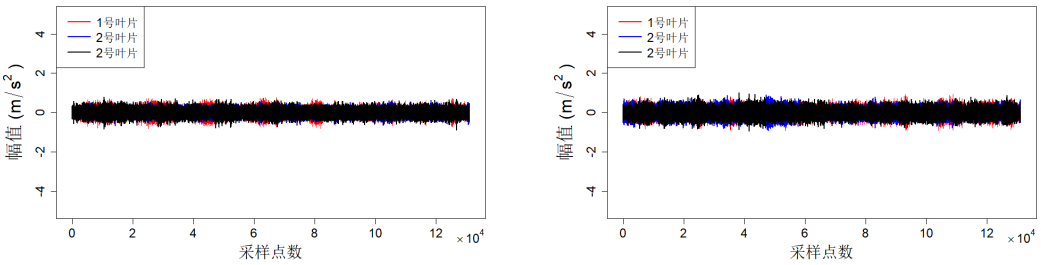

(a) (b)

图 2-2　训练阶段 #1 号风机的叶片振动信号：（a）第 1 批次的振动信号；（b）第 18 批次的振动信号

在监测开始之前，首先对训练样本进行了一些必要的分析，包括时间依赖性分析和离线变点分析。如图2-3（a）所示，训练样本似乎是平稳的。本文使用 R 包 npcp 中的 cpDist() 函数和 R 包 ecp 中的 e.divisive() 函数来检测训练样本中的结构变化。检验结果表明，在显著性水平 $\alpha = 5\%$ 下，训练样本的分布没有显著变化。这验证了图2-3（a）中的初步观察结果，即三支叶片的振动强度在训练阶段相近。此外，本文还使用自距离相关系数[57]（Auto Distance Correlation Function，ADCF）来分析训练样本的时间依赖性。根据图2-3（b），训练样本之间有着较强的时间依赖性。监测指标 $\{\boldsymbol{X}_t\}$ 的各个分量之间有较强的相关性，且每个分量本身也有着显著的时间依赖性。这是因为三支叶片形成一个相互连接的系统，它们的振动模式密切相关。另外，叶片在后续时段的振动状态受前一时段振动的影响，有着显著的时间依赖关系。

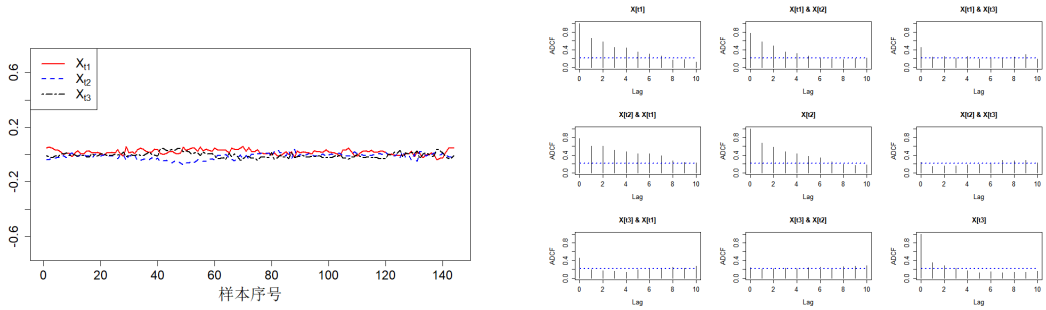

(a) (b)

图 2-3　#1 号风机的训练样本及其 ADCF：（a）从前 36 小时振动信号中提取的训练样本；（b）训练样本的 ADCF

本文使用所提出的自正则在线监测方法 D_m^{SN} 来检测后续监测指标 $\{\boldsymbol{X}_t\}_{t\geq m+1}$ 中的结构变化。比较起见，考虑未引入自正则因子的在线监测方法 D_m。序贯检验在 $\alpha = 5\%$ 的显著性水平下进行，监测周期设定为 $L = \{1, 2, 3, 4, 5\}$。权重函数 $\omega(u)$ 中的可调参数设定为 $a = 10$，Bootstrap 算法的重复次数为 $B = 2000$。

表 2-3　#1 号风机的监测结果

	L	$\tau(m)$	p 值
D_m	1	NA	0.098
	2	NA	0.076
	3	509	0.037
	4	519	0.026
	5	658	0.039
D_m^{SN}	1	NA	0.468
	2	NA	0.454
	3	NA	0.377
	4	NA	0.355
	5	NA	0.389

表2-3为对 #1 号风机的监测结果，包括停止时间 $\tau(m)$ 和检验的 p 值。停止时间 $\tau(m)$ 是监测统计量 D_m^{SN} 或 D_m 首次超过临界值的时间点；即在线监测方法发出警报的时刻。表2-3中的 NA 表示没有发出警报。D_m^{SN} 的 p 值计算方式为：$p = \frac{1}{B}\left\{\sum_{i=1}^{B}\mathbf{I}\left(D_i^* \geq \max_{1\leq k\leq Lm} D_m^{SN}(k)\right)\right\}$，其中 D_i^* 为监测统计量 D_m^{SN} 的 Bootstrap 版本。D_m 的 p 值的计算方法类似。

根据风电场的反馈，#1 号风机的三支叶片均正常运行。然而，如表2-3所示，当 $L > 2$ 时，D_m 发出误报。出现误报的原因可能是，当样本观测之间存在较强的时间依赖性时，D_m 的第一类错误率（即误报率）较高，正如第 2.3 节中的数值模拟结果所示。相比之下，自正则在线监测方法 D_m^{SN} 始终没有误报。因此，本文所提方法在实际应用中更为可靠。

2.4.2　#5 号风机

对于 #5 号风机，本文使用前 36 小时的监测指标作为训练样本：$\{\boldsymbol{X}_t\}, t = 1, \cdots, 144$。类似于 #1 号风机，本文对训练样本进行了离线变点分析和时间依赖性分析。分析结果表明，#5 号风机的训练样本中没有显著的结构变化，并且发现其存在较强的时间依赖性。接下来对 #5 号风机进行监测，序贯检验在 $\alpha = 5\%$ 的显著性水平下进行，监测周期设定为 $L = \{1, 2, 3\}$。监测方法中的其他参数与上一小节中的设定相同。#5 号风机的监测结果如表2-4所示。

表 2-4　#5 号风机的监测结果

	L	$\tau(m)$	p 值
D_m	1	225	<0.001
	2	229	<0.001
	3	230	<0.001
D_m^{SN}	1	246	0.006
	2	249	0.013
	3	253	0.021

根据风电场的反馈，#5 号风机的 1 号叶片最终发生了断裂故障。如表2-4所示，两个在线监测方法均发出了警报，其中 D_m 的警报时间大约比 D_m^{SN} 早 20 个样本点。随后，绘制这两个在线监测方法报警后的叶片振动信号，如图2-4和2-5所示。

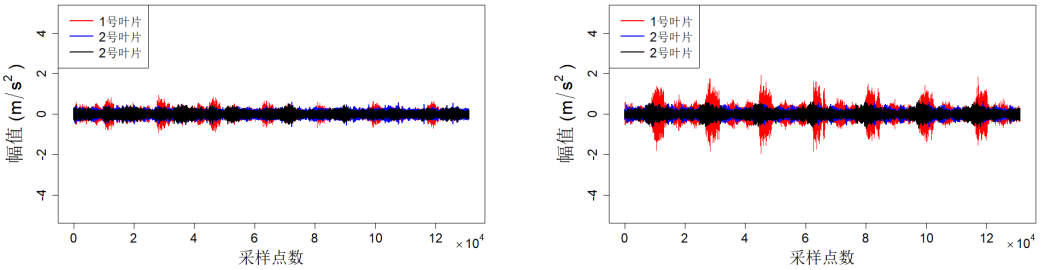

(a)　　(b)

图 2-4　在 D_m 报警后，#5 号风机的三支叶片的振动信号：（a）第 29 批次的振动信号；（b）第 30 批次的振动信号

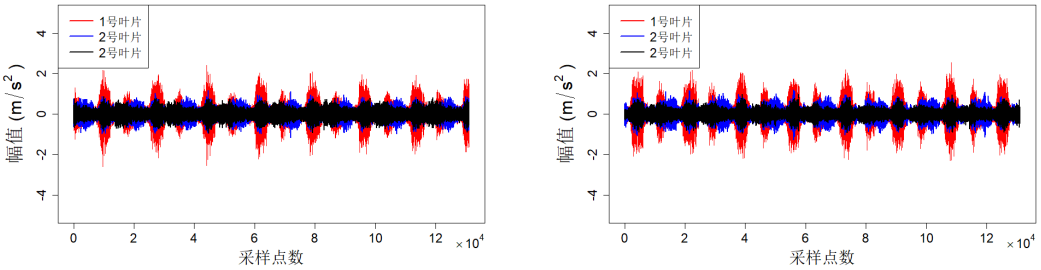

(a)　　(b)

图 2-5　在 D_m^{SN} 报警后，#5 号风机的三支叶片的振动信号：（a）第 31 批次的振动信号；（b）第 32 批次的振动信号

从图2-4和2-5中可以看出，当在线监测方法发出警报后，1 号叶片的振动信号中存在明显的异常冲击，而 2 号叶片和 3 号叶片的振幅较为接近。从 #5 号风机的

监测结果来看，本文提出的自正则在线监测方法 D_m^{SN} 能够较快地检测到叶片的振动状态变化，并及时对潜在故障进行预警。与未引入自正则因子的在线监测方法 D_m 相比，D_m^{SN} 的报警时间并没有晚太久。综合 #1 号风机和 #5 号风机的监测结果，D_m^{SN} 在控制第一类错误率（误报率）上有着显著的优势，且有着可接受的检测延迟。总体而言，本文所提出的在线监测方法 D_m^{SN} 表现良好。

2.5 本章定理证明

这一节为本章第2.2节中主要定理的证明。定理2.1的证明建立在 Hlávka 等人[1]的基础工作上。在本节中，除非另有说明，C 都表示一个可以在实数上任意变化的通用常数。

首先证明定理2.1，从一些必要的引理开始：

引理 2.1 当假设2.2成立时，直接计算可得

$$\begin{aligned}&\int_{\mathbb{R}^d}\left|\frac{1}{m}\sum_{t=1}^{m}\mathrm{e}^{i\langle \boldsymbol{X}_t,\boldsymbol{u}\rangle}-\frac{1}{m+k}\sum_{t=1}^{m+k}\mathrm{e}^{i\langle \boldsymbol{X}_t,\boldsymbol{u}\rangle}\right|^2\omega(\boldsymbol{u})d\boldsymbol{u}\\&=\int_{\mathbb{R}^d}\left|\frac{1}{m}\sum_{t=1}^{m}h_t(\boldsymbol{u})-\frac{1}{m+k}\sum_{t=1}^{m+k}h_t(\boldsymbol{u})\right|^2\omega(\boldsymbol{u})d\boldsymbol{u},\end{aligned}$$

其中 $h_t(\boldsymbol{u})=\cos\langle \boldsymbol{X}_t,\boldsymbol{u}\rangle+\sin\langle \boldsymbol{X}_t,\boldsymbol{u}\rangle$。

证明 简便起见，分别定义 $|f(\boldsymbol{u})|_\omega \overset{\Delta}{=} \int_{\mathbb{R}^d} f(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}$，$\delta_k(\boldsymbol{u}) \overset{\Delta}{=} |\hat{\phi}_{1:m}(\boldsymbol{u})-\hat{\phi}_{1:m+k}(\boldsymbol{u})|^2$ 以及 $\widetilde{\delta}_k(\boldsymbol{u}) \overset{\Delta}{=} |\frac{1}{m}\sum_{t=1}^{m}h_t(\boldsymbol{u})-\frac{1}{m+k}\sum_{t=1}^{m+k}h_t(\boldsymbol{u})|^2$。然后可以得到：

$$\begin{aligned}|\delta_k(\boldsymbol{u})|_\omega=&\frac{1}{m^2}\sum_{\mu,\nu=1}^{m}\int_{\mathbb{R}^d}\cos\langle \boldsymbol{X}_\mu-\boldsymbol{X}_\nu,\boldsymbol{u}\rangle\omega(\boldsymbol{u})d\boldsymbol{u}\\&+\frac{1}{(m+k)^2}\sum_{\mu,\nu=1}^{m+k}\int_{\mathbb{R}^d}\cos\langle \boldsymbol{X}_\mu-\boldsymbol{X}_\nu,\boldsymbol{u}\rangle\omega(\boldsymbol{u})d\boldsymbol{u}\\&-\frac{2}{m(m+k)}\sum_{\mu=1}^{m_l}\sum_{\nu=1}^{m+k}\int_{\mathbb{R}^d}\cos\langle \boldsymbol{X}_\mu-\boldsymbol{X}_\nu,\boldsymbol{u}\rangle\omega(\boldsymbol{u})d\boldsymbol{u},\end{aligned}$$

$$\begin{aligned}|\widetilde{\delta}_k(\boldsymbol{u})|_\omega=&\frac{1}{m^2}\sum_{\mu,\nu=1}^{m}\int_{\mathbb{R}^d}h_\mu(\boldsymbol{u})h_\nu(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}\\&+\frac{1}{(m+k)^2}\sum_{\mu,\nu=1}^{m+k}\int_{\mathbb{R}^d}h_\mu(\boldsymbol{u})h_\nu(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}\\&-\frac{2}{m(m+k)}\sum_{\mu=1}^{m}\sum_{\nu=1}^{m+k}\int_{\mathbb{R}^d}h_\mu(\boldsymbol{u})h_\nu(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}.\end{aligned}$$

由三角恒等式 $\cos(a-b)=\cos(a)\cos(b)+\sin(a)\sin(b)$ 以及权重函数 $\omega(\boldsymbol{u})$ 的对称性可得：

$$
\begin{aligned}
&\int_{\mathbb{R}^d} h_\mu(\boldsymbol{u})h_\nu(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}\\
&=|h_\mu(\boldsymbol{u})h_\nu(\boldsymbol{u})|_\omega\\
&=|(\cos\langle \boldsymbol{X}_\mu,\boldsymbol{u}\rangle+\sin\langle \boldsymbol{X}_\mu,\boldsymbol{u}\rangle)(\cos\langle \boldsymbol{X}_\nu,\boldsymbol{u}\rangle+\sin\langle \boldsymbol{X}_\nu,\boldsymbol{u}\rangle)|_\omega\\
&=|\cos\langle \boldsymbol{X}_\mu,\boldsymbol{u}\rangle\cos\langle \boldsymbol{X}_\nu,\boldsymbol{u}\rangle+\sin\langle \boldsymbol{X}_\mu,\boldsymbol{u}\rangle\sin\langle \boldsymbol{X}_\nu,\boldsymbol{u}\rangle|_\omega\\
&=|\cos\langle \boldsymbol{X}_\mu-\boldsymbol{X}_\nu,\boldsymbol{u}\rangle|_\omega.
\end{aligned}
$$

将上述结果带入 $|\widetilde{\delta}_k(\boldsymbol{u})|_\omega$ 展开式的每一项中，直接可得引理2.1成立。 □

经过简单的代数变换,，引理2.1得出了在特定类型的权重函数下特征函数 L_2 范数的等价形式。基于此引理可得：

$$
\begin{aligned}
\Gamma_m(k)&=\frac{(m+k)^2}{m}\int_{\mathbb{R}^d}\left|\hat{\phi}_{1:m}(\boldsymbol{u})-\hat{\phi}_{1:m+k}(\boldsymbol{u})\right|^2\omega(\boldsymbol{u})d\boldsymbol{u}\\
&=\left|\left(\frac{1}{\sqrt{m}}\sum_{t=1}^{m+k}\mathrm{e}^{i\langle \boldsymbol{X}_t,\boldsymbol{u}\rangle}-\frac{m+k}{m}\frac{1}{\sqrt{m}}\sum_{t=1}^{m}\mathrm{e}^{i\langle \boldsymbol{X}_t,\boldsymbol{u}\rangle}\right)^2\right|_\omega\\
&=\left|\left(\frac{1}{\sqrt{m}}\sum_{t=1}^{m+k}h_t(\boldsymbol{u})-\frac{m+k}{m}\frac{1}{\sqrt{m}}\sum_{t=1}^{m}h_t(\boldsymbol{u})\right)^2\right|_\omega,\\
S_m^2&=\frac{1}{m^2}\sum_{t=1}^{m}\int_{\mathbb{R}^d}t^2|\hat{\phi}_{1:t}(\boldsymbol{u})-\hat{\phi}_{1:m}(\boldsymbol{u})|^2\omega(\boldsymbol{u})d\boldsymbol{u}\\
&=\frac{1}{m}\sum_{t=1}^{m}\left|\left(\frac{1}{\sqrt{m}}\sum_{j=1}^{t}\mathrm{e}^{i\langle \boldsymbol{X}_j,\boldsymbol{u}\rangle}-\frac{t}{m}\frac{1}{\sqrt{m}}\sum_{j=1}^{m}\mathrm{e}^{i\langle \boldsymbol{X}_j,\boldsymbol{u}\rangle}\right)^2\right|_\omega\\
&=\frac{1}{m}\sum_{t=1}^{m}\left|\left(\frac{1}{\sqrt{m}}\sum_{j=1}^{t}h_j(\boldsymbol{u})-\frac{t}{m}\frac{1}{\sqrt{m}}\sum_{j=1}^{m}h_j(\boldsymbol{u})\right)^2\right|_\omega.
\end{aligned}
$$

后面的证明过程都基于以上的等价形式进行。接下来的引理2.2阐述了强混合序列的部分和的一些基本结果，参见 Yokoyama[58]。

引理 2.2 不失一般性，可假设 $\mathrm{E}h_t(\boldsymbol{u})=0$。因为在引理 2.1 中，$h_t(\boldsymbol{u})$ 可替换为 $h_t(\boldsymbol{u})-\mathrm{E}h_1(\boldsymbol{u})$ 而不改变最终的计算结果。当假设2.1成立时，可以得到：
(1) 对 $\delta>0$（如假设2.1中所述）和任一 $\boldsymbol{u}\in\mathbb{R}^d$，

$$
\mathrm{E}\left|\sum_{t=1}^{m}h_t(\boldsymbol{u})\right|^2\le Cm\left(\mathrm{E}|h_1(\boldsymbol{u})|^{2+\delta}\right)^{\frac{2}{2+\delta}}\sum_{j=1}^{\infty}\alpha(j)^{\frac{\delta}{2+\delta}}.
$$

若 $h_t(\boldsymbol{u})$ 替换为 $h_t(\boldsymbol{u}_1)-h_t(\boldsymbol{u}_2),\boldsymbol{u}_1,\boldsymbol{u}_2\in\mathbb{R}^d$，上述不等式仍然成立[1]。此外，

若序列 $\{h_t(\boldsymbol{u})\}$ 的长时方差存在，即 $0<\sigma^2=\sum_{j=-\infty}^{\infty}\mathrm{Cov}\big(h_1(\boldsymbol{u}),h_{1+j}(\boldsymbol{u})\big)<\infty$，则当 $m\to\infty$ 时，以下中心极限定理成立：

$$\frac{1}{\sqrt{m}}\sum_{t=1}^{m}h_t(\boldsymbol{u})\xrightarrow{d}N(0,\sigma^2).$$

(2) 对于 $\kappa>0$（如假设2.1中所述），令 $r=2+\kappa$。若序列 $\{h_t(\boldsymbol{u})\}$ 的长时方差 σ^2 存在，则对于 $m\geq 1$，

$$\mathrm{E}\left|\sum_{t=1}^{m}h_t(\boldsymbol{u})\right|^r\leq Cm^{\frac{r}{2}},\mathrm{E}\left(\max_{1\leq j\leq m}\left|\sum_{t=1}^{j}h_t(\boldsymbol{u})\right|^r\right)\leq Cm^{\frac{r}{2}}.$$

证明 结论 (1) 由 Yokoyama[58] 的定理 1 的证明过程中的式 (4.1) 和 (4.2) 推导而来。结论 (2) 为该文献中的定理 1 和推论 1。 □

引理 2.3 令 $\Lambda_{m,\theta}(\boldsymbol{u}),m=1,2,\cdots$ 以及 $\Lambda_\theta(\boldsymbol{u})$ 为定义在有界闭集 $K_\delta\subset\mathbb{R}^d$ 上且依赖于参数 $\theta\in\Theta$ 的一族可测随机函数。若它们满足以下条件：

(1)

$$\sup_{m,\theta}\mathrm{E}\int_{K_\delta}|\omega(\boldsymbol{u})||\Lambda_{m,\theta}(\boldsymbol{u})|d\boldsymbol{u}<\infty.$$

(2) 存在常数 $a>0$ 使得

$$\sup_{m,\theta}\mathrm{E}|\Lambda_{m,\theta}(\boldsymbol{u}_1)-\Lambda_{m,\theta}(\boldsymbol{u}_2)|\leq C|\boldsymbol{u}_1-\boldsymbol{u}_2|^a,$$

其中 $C>0$。

(3) $\Lambda_{m,\theta}(\boldsymbol{u})$ 的边际分布在参数空间 Θ 上一致收敛于 $\Lambda_\theta(\boldsymbol{u})$ 的边际分布。

那么，这些随机函数的积分也保持相同的收敛性。即积分 $\int_{K_\delta}\omega(\boldsymbol{u})\Lambda_{m,\theta}(\boldsymbol{u})d\boldsymbol{u}$ 的分布在 Θ 上一致收敛于积分 $\int_{K_\delta}\omega(\boldsymbol{u})\Lambda_\theta(\boldsymbol{u})d\boldsymbol{u}$ 的分布。由此易得

$$\int_{K_\delta}\omega(\boldsymbol{u})\Lambda_{m,\theta}(\boldsymbol{u})d\boldsymbol{u}\xrightarrow{d}\int_{K_\delta}\omega(\boldsymbol{u})\Lambda_\theta(\boldsymbol{u})d\boldsymbol{u}.$$

证明 引理 2.3 是关于随机函数积分的极限定理，见 Ibragimov 和 Hasminskii[59] 专著中的定理 22（第 380 页）。 □

以下引理对定理2.1的证明至关重要，主要结果来自 Hlávka 等人[1]。

引理 2.4 令 $Z_m(\theta,\boldsymbol{u})=\frac{1}{\sqrt{m}}\sum_{t=1}^{\lfloor m\theta\rfloor}h_t(\boldsymbol{u}),\theta\in(0,1+L)$。不失一般性，可假设 $\mathrm{E}h_t(\boldsymbol{u})=0$。若假设2.1和2.2成立，并且序列 $\{h_t(\boldsymbol{u})\}$ 的长时方差 σ^2 存在，则在原假设下：

(1) 对于 $\mathbb{R}^d$ 的任意紧子集 K_δ，$\sup_m\mathrm{E}\int_{K_\delta}\big(Z_m(\theta,\boldsymbol{u})\big)^2\omega(\boldsymbol{u})d\boldsymbol{u}<\infty$。

(2) 存在常数 $a>0$，$C>0$ 使得对任意 $\theta\in(0,1+L)$ 和 $\boldsymbol{u}_1,\boldsymbol{u}_2\in\mathbb{R}^{2d}$，

$$\sup_m\mathrm{E}|Z_m^2(\theta,\boldsymbol{u}_1)-Z_m^2(\theta,\boldsymbol{u}_2)^2|\leq C\|\boldsymbol{u}_1-\boldsymbol{u}_2\|^a.$$

(3) 当 $m \to \infty$ 时，$\{Z_m(\theta, \boldsymbol{u})\}$ 的边际分布收敛于零均值高斯过程 $\{Z(\theta, \boldsymbol{u})\}$ 的边际分布。$\{Z(\theta, \boldsymbol{u})\}$ 的协方差结构为

$$\mathrm{Cov}\{Z(\theta_1, \boldsymbol{u}_1), Z(\theta_2, \boldsymbol{u}_2)\} = (\theta_1 \wedge \theta_2)\Sigma(\boldsymbol{u}_1, \boldsymbol{u}_2),$$

其中 $\Sigma(\boldsymbol{u}_1, \boldsymbol{u}_2) = \sum_{j=0}^{\infty} \mathrm{Cov}\big(h_1(\boldsymbol{u}_1), h_{1+j}(\boldsymbol{u}_2)\big) + \sum_{j=1}^{\infty} \mathrm{Cov}\big(h_1(\boldsymbol{u}_2), h_{1+j}(\boldsymbol{u}_1)\big)$ 。

注 $Z_m^*(\theta, \boldsymbol{u}) = \frac{1}{\sqrt{m}} \sum_{t=1}^{\lfloor m\theta \rfloor} h_t(\boldsymbol{u}) - \frac{\lfloor m\theta \rfloor}{m} \frac{1}{\sqrt{m}} \sum_{t=1}^{m} h_t(\boldsymbol{u}), \theta \in (1, L)$ 也满足 (1) 和 (2)，且证明过程类似。

证明 这一部分参考了 Hlávka 等人[1] 中引理 2 的证明。

(1) 根据假设，对于每个 $\boldsymbol{u}$，序列 $\{h_t(\boldsymbol{u})\}$ 是强混合的，其混合系数与序列 $\{\boldsymbol{X}_t\}$ 相同。此外，根据引理 2.4 中的假设，$\mathrm{E}Z_m(\theta, s) = 0$。由于序列 $\{h_t(\boldsymbol{u})\}$ 的长时方差存在，因此

$$\mathrm{E}\left(\frac{1}{\sqrt{k}} \sum_{t=1}^{k} h_t(\boldsymbol{u})\right)^2 = \frac{1}{k} \sum_{\mu,\nu=1}^{k} \mathrm{Cov}(h_\mu(\boldsymbol{u}), h_\nu(\boldsymbol{u})) \to \sigma^2, k \to \infty,$$

$$\mathrm{E}\big(Z_m(\theta, \boldsymbol{u})\big)^2 = \frac{\lfloor m\theta \rfloor}{m} \left(\frac{1}{\lfloor m\theta \rfloor} \sum_{\mu,\nu=1}^{\lfloor m\theta \rfloor} \mathrm{Cov}(h_\mu(\boldsymbol{u}), h_\nu(\boldsymbol{u}))\right) \to \theta\sigma^2, m \to \infty.$$

由此可知，$\mathrm{E}\big(Z_m(\theta, \boldsymbol{u})\big)^2$ 是一致有界的。由假设2.2中权重函数的可积性可得

$$\sup_m \mathrm{E} \int_{K_\delta} \big(Z_m(\theta, \boldsymbol{u})\big)^2 \omega(\boldsymbol{u}) d\boldsymbol{u} < \infty.$$

(2) 由正弦和余弦函数的有界性以及中值定理，可知 $\mathrm{E}|h_t(\boldsymbol{u}_1) - h_t(\boldsymbol{u}_2)| \le C\|\boldsymbol{u}_1 - \boldsymbol{u}_2\|$。此外，利用 Hölder 不等式和 $\mathrm{E}\big(Z_m(\theta, \boldsymbol{u})\big)^2$ 的一致有界性，可以得出

$$\begin{aligned}
\mathrm{E}|Z_m^2(\theta, \boldsymbol{u}_1) - Z_m^2(\theta, \boldsymbol{u}_2)| &\le C\Big\{\mathrm{E}|Z_m(\theta, \boldsymbol{u}_1) - Z_m(\theta, \boldsymbol{u}_2)|^2 \mathrm{E}|Z_m(\theta, \boldsymbol{u}_1) + Z_m(\theta, \boldsymbol{u}_2)|^2\Big\}^{\frac{1}{2}} \\
&\le C\Big\{E|Z_m(\theta, \boldsymbol{u}_1) - Z_m(\theta, \boldsymbol{u}_2)|^2\Big\}^{\frac{1}{2}} \\
&= C\Big\{\frac{1}{m}\mathrm{E}|\sum_{t=1}^{\lfloor m\theta \rfloor} \big(h_t(\boldsymbol{u}_1) - h_t(\boldsymbol{u}_2)\big)|^2\Big\}^{\frac{1}{2}}.
\end{aligned}$$

然后，根据引理 2.2，将 $h_t(\boldsymbol{u})$ 替换为 $h_t(\boldsymbol{u}_1) - h_t(\boldsymbol{u}_2)$ 得出类似的结论，即强混合序列的矩不等式仍然成立。因此

$$\frac{1}{m}\mathrm{E}|\sum_{t=1}^{\lfloor m\theta \rfloor} \big(h_t(\boldsymbol{u}_1) - h_t(\boldsymbol{u}_2)\big)|^2 \le C\frac{\lfloor m\theta \rfloor}{m}\Big\{|\mathrm{E}\big(h_1(\boldsymbol{u}_1) - h_1(\boldsymbol{u}_2)\big)|^{2+\delta}\Big\}^{\frac{2}{2+\delta}},$$

$$|\mathrm{E}\big(h_t(\boldsymbol{u}_1) - h_t(\boldsymbol{u}_2)\big)|^{2+\delta} = \Big\{|\mathrm{E}\big(h_t(\boldsymbol{u}_1) - h_t(\boldsymbol{u}_2)\big)|^2\Big\}^{\frac{2+\delta}{2}} \le C\|\boldsymbol{u}_1 - \boldsymbol{u}_2\|^a,$$

其中 a 是一个合适的常数。也就是说，存在常数 $a > 0$ 和 $C > 0$，使得对于任意 $\theta \in (0, 1+L)$ 和任意 $\boldsymbol{u}_1, \boldsymbol{u}_2 \in \mathbb{R}^d$，

$$\sup_m \mathrm{E}|Z_m^2(\theta, \boldsymbol{u}_1) - Z_m^2(\theta, \boldsymbol{u}_1)| \le C\|\boldsymbol{u}_1 - \boldsymbol{u}_2\|^a.$$

(3) 参考 Hlávka 等人[1] 的结果，可得出这一结论。 □

依据上述辅助引理，定理2.1的证明如下。

证明 对于本文所提出的监测统计量，由引理 2.1 可得

$$D_m^{SN}(k) \stackrel{\Delta}{=} \frac{1}{q^2(\frac{k}{m})} \frac{\Gamma_m(k)}{S_m^2}, k = 1, \ldots, Lm,$$

其中 $q(\frac{k}{m}) = (1 + \frac{k}{m})$，

$$\begin{aligned}\Gamma_m(k) &= \frac{(m+k)^2}{m} \int_{\mathbb{R}^d} \left|\hat{\phi}_{1:m}(\boldsymbol{u}) - \hat{\phi}_{1:m+k}(\boldsymbol{u})\right|^2 \omega(\boldsymbol{u}) d\boldsymbol{u} \\ &= \left\| \frac{1}{\sqrt{m}} \sum_{t=1}^{m+k} h_t(\boldsymbol{u}) - \frac{m+k}{m} \frac{1}{\sqrt{m}} \sum_{t=1}^{m} h_t(\boldsymbol{u}) \right\|_\omega^2,\end{aligned}$$

$$\begin{aligned}S_m^2 &= \frac{1}{m^2} \sum_{t=1}^{m} \int_{\mathbb{R}^d} t^2 |\hat{\phi}_{1:t}(\boldsymbol{u}) - \hat{\phi}_{1:m}(\boldsymbol{u})|^2 \omega(\boldsymbol{u}) d\boldsymbol{u} \\ &= \frac{1}{m} \sum_{j=1}^{m} \left\| \frac{1}{\sqrt{m}} \sum_{t=1}^{j} h_t(\boldsymbol{u}) - \frac{j}{m} \frac{1}{\sqrt{m}} \sum_{t=1}^{m} h_t(\boldsymbol{u}) \right\|_\omega^2,\end{aligned}$$

其中 $\|f(\boldsymbol{u})\|_\omega^2 = \int_{\mathbb{R}^d} (f(\boldsymbol{u}))^2 \omega(\boldsymbol{u}) d\boldsymbol{u}$。

为便于表述，定义

$$\begin{aligned}U_m(\theta, \boldsymbol{u}) &= Z_m(1+\theta, \boldsymbol{u}) - \left(\frac{m + \lfloor m\theta \rfloor}{m}\right) Z_m(1, \boldsymbol{u}), \theta \in (0, L), \\ U(\theta, \boldsymbol{u}) &= Z(1+\theta, \boldsymbol{u}) - (1+\theta) Z(1, \boldsymbol{u}), \theta \in (0, L), \\ P_m(\theta, \boldsymbol{u}) &= Z_m(\theta, \boldsymbol{u}) - \frac{\lfloor m\theta \rfloor}{m} Z_m(1, \boldsymbol{u}), \theta \in (0, 1), \\ P(\theta, \boldsymbol{u}) &= Z(\theta, \boldsymbol{u}) - \theta Z(1, \boldsymbol{u}), \theta \in (0, 1),\end{aligned}$$

其中 $Z_m(\theta, \boldsymbol{u}) = \frac{1}{\sqrt{m}} \sum_{t=1}^{\lfloor m\theta \rfloor} h_t(\boldsymbol{u})$ ，$Z(\theta, \boldsymbol{u})$ 为零均值高斯过程，其协方差结构为 $\mathrm{Cov}\{Z(\theta_1, \boldsymbol{u}_1), Z(\theta_2, \boldsymbol{u}_2)\} = (\theta_1 \wedge \theta_2)\Sigma(\boldsymbol{u}_1, \boldsymbol{u}_2)$，详见引理 2.4。那么，由引理 2.4 可知，$\{U_m(\theta, \boldsymbol{u})\}$ 和 $\{P_m(\theta, \boldsymbol{u})\}$ 的边际分布分别收敛到零均值高斯过程 $\{U(\theta, \boldsymbol{u})\}$ 和 $\{P(\theta, \boldsymbol{u})\}$ 的边际分布。

接下来，研究以下过程的渐近行为：

$$V_m(\theta)=\frac{1}{(1+\frac{\lfloor m\theta\rfloor}{m})^2}\|U_m(\theta,\boldsymbol{u})\|_\omega^2=\int_{\mathbb{R}^d}\frac{1}{(1+\frac{\lfloor m\theta\rfloor}{m})^2}\left(U_m(\theta,\boldsymbol{u})\right)^2\omega(\boldsymbol{u})d\boldsymbol{u},\theta\in(0,L).$$

首先证明 $V_m(\theta)$ 的任意有限维分布的收敛性。令 $V(\theta)=\frac{1}{(1+\theta)^2}\|U(\theta,\boldsymbol{u})\|_\omega^2$，$\Lambda_{m,\theta}(\boldsymbol{u})=\left(\frac{1}{1+\frac{\lfloor m\theta\rfloor}{m}}U_m(\theta,\boldsymbol{u})\right)^2$，$\Lambda_\theta(\boldsymbol{u})=\left(\frac{1}{1+\theta}U(\theta,\boldsymbol{u})\right)^2$。对给定的 $\theta\in(0,L)$，由于 $\frac{1}{1+\frac{\lfloor m\theta\rfloor}{m}}$ 非负且有界，结合引理 2.4 可以得出，$\Lambda_{m,\theta}(\boldsymbol{u})$ 和 $\Lambda_\theta(\boldsymbol{u})$ 满足引理 2.3 中的三个条件。因此，对于任意紧集 $K_\delta\subset\mathbb{R}^d$，

$$\int_{K_\delta}\Lambda_{m,\theta}(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}\xrightarrow{d}\int_{K_\delta}\Lambda_\theta(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}. \tag{2-13}$$

接下来证明这个结论在 $\mathbb{R}^d$ 上成立。类似于 Hlávka 等人[60] 中定理 4.1 的证明，由于 $\omega(\boldsymbol{u})$ 为可积函数，对于所有 $\delta>0$，存在一个紧集 K_δ 使得

$$\mathrm{E}\int_{\mathbb{R}^d\setminus K_\delta}\frac{1}{(1+\frac{\lfloor m\theta\rfloor}{m})^2}(U_m(\theta,\boldsymbol{u}))^2\omega(\boldsymbol{u})d\boldsymbol{u}<C\int_{\mathbb{R}^d\setminus K_\delta}\omega(\boldsymbol{u})d\boldsymbol{u}<\delta. \tag{2-14}$$

式 (2-14) 中的第一个不等式由 $\mathrm{E}\left(U_m(\theta,\boldsymbol{u})\right)^2$ 的一致有界推出，这一点可以参考引理2.4下的注释。第二个不等式依赖于权重函数的可积性。

在 (2-14) 中，如果将 $\Lambda_{m,\theta}(\boldsymbol{u})$ 替换为 $\Lambda_\theta(\boldsymbol{u})$，可以得出类似的结论，这与 (2-13) 一起表明 $\int_{\mathbb{R}^d}\Lambda_{m,\theta}(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}\xrightarrow{d}\int_{\mathbb{R}^d}\Lambda_\theta(\boldsymbol{u})\omega(\boldsymbol{u})d\boldsymbol{u}$。即，对于给定的 $\theta\in(0,L)$，有 $V_m(\theta)\xrightarrow{d}V(\theta)$。类似可得，对于任意的 $k\in\mathbb{N}$，$a_1,\cdots,a_k\in\mathbb{R}$，$\theta_1,\cdots,\theta_k\in(0,L)$，

$$\sum_{t=1}^k a_iV_m(\theta_i)\xrightarrow{d}\sum_{t=1}^k a_iV(\theta_i).$$

因此，由 Cramér-Wold 方法，

$$\Big(V_m(\theta_1),...,V_m(\theta_k)\Big)\xrightarrow{d}\Big(V(\theta_1),...,V(\theta_k)\Big).$$

由此可得，$V_m(\theta)$ 的有限维分布收敛成立，接下来将证明其胎紧性。

根据引理 2.2 中的矩不等式，Hölder 不等式以及 Jensen 不等式可以得出，对于 $r=2+\kappa>2$ 和 $0<\theta,\theta+h<L$，

$$\begin{aligned}&\mathrm{E}\left|\int_{\mathbb{R}^d}\left(U_m^2(\theta+h,\boldsymbol{u})-U_m^2(\theta,\boldsymbol{u})\right)\omega(\boldsymbol{u})d\boldsymbol{u}\right|^r\\ \le&\mathrm{E}^{\frac12}\left(\int_{\mathbb{R}^d}\left(U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\right)^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\right)\\ *&\mathrm{E}^{\frac12}\left(\int_{\mathbb{R}^d}\left(U_m(\theta+h,\boldsymbol{u})+U_m(\theta,\boldsymbol{u})\right)^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\right)\\ \le&C|h|^a,\end{aligned} \tag{2-15}$$

其中 a 为某一常数。

接下来将详细解释如何推导出 (2-15) 中的两个不等式。

$$
\begin{aligned}
&\mathrm{E}\left|\int_{\mathbb{R}^d}\left(U_m^2(\theta+h,\boldsymbol{u})-U_m^2(\theta,\boldsymbol{u})\right)\omega(\boldsymbol{u})d\boldsymbol{u}\right|^r\\
=&\mathrm{E}\left|\int_{\mathbb{R}^d}\left\{\left(U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\right)\left(U_m(\theta+h,\boldsymbol{u})+U_m(\theta,\boldsymbol{u})\right)\right\}\omega(\boldsymbol{u})d\boldsymbol{u}\right|^r\\
\leq&\mathrm{E}\left|\int_{\mathbb{R}^d}\left\{\left|U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\right|*\left|U_m(\theta+h,\boldsymbol{u})+U_m(\theta,\boldsymbol{u})\right|\right\}\omega(\boldsymbol{u})d\boldsymbol{u}\right|^r\\
\leq&\mathrm{E}\left|\sqrt{\|U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\|_\omega^2}\sqrt{\|U_m(\theta+h,\boldsymbol{u})+U_m(\theta,\boldsymbol{u})\|_\omega^2}\quad\right|^r\\
=&\mathrm{E}\left[\left(\sqrt{\|U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\|_\omega^2}\right)^r\left(\sqrt{\|U_m(\theta+h,\boldsymbol{u})+U_m(\theta,\boldsymbol{u})\|_\omega^2}\right)^r\right]\\
\leq&\sqrt{\mathrm{E}\left(\|U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\|_\omega^2\right)^r}\sqrt{\mathrm{E}\left(\|U_m(\theta+h,\boldsymbol{u})+U_m(\theta,\boldsymbol{u})\|_\omega^2\right)^r}\\
\leq&\sqrt{\mathrm{E}\left(\int_{\mathbb{R}^d}\left|U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\right|^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\right)}\\
&*\sqrt{\mathrm{E}\left(\int_{\mathbb{R}^d}\left|U_m(\theta+h,\boldsymbol{u})+U_m(\theta,\boldsymbol{u})\right|^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\right)}\\
\overset{\Delta}{=}&\sqrt{I_1}\sqrt{I_2}.
\end{aligned}
\tag{2-16}
$$

这是式 (2-15) 中的第一个不等式。式 (2-16) 中的第二个不等式可由积分的 Hölder 不等式得到。式 (2-16) 中的第三个不等式由 Hölder 不等式得到。而式 (2-16) 中的第四个不等式由积分的 Jensen 不等式得到。

接下来推导式 (2-15) 中第二个不等式（最后一行）。考虑 Jensen 不等式的以下推论：对于 $a>0, b>0$ 和 $p>1$，有 $(a+b)^p \leq 2^{p-1}(a^p+b^p)$（因为 $(\frac{a+b}{2})^p \leq \frac{a^p+b^p}{2}$）。对于 I_1，

$$
\begin{aligned}
I_1&=\mathrm{E}\left(\int_{\mathbb{R}^d}\left|U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\right|^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\right)\\
&=\int_{\mathbb{R}^d}\mathrm{E}\left|U_m(\theta+h,\boldsymbol{u})-U_m(\theta,\boldsymbol{u})\right|^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\\
&=\int_{\mathbb{R}^d}\mathrm{E}\left(Z_m(1+\theta+h,\boldsymbol{u})-Z_m(1+\theta,\boldsymbol{u})-\frac{\lfloor m(\theta+h)\rfloor-\lfloor m\theta\rfloor}{m}Z_m(1,\boldsymbol{u})\right)^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\\
&=\int_{\mathbb{R}^d}\mathrm{E}\left(\frac{1}{\sqrt{m}}\sum_{t=\lfloor m(1+\theta)\rfloor+1}^{\lfloor m(1+\theta+h)\rfloor}h_t(\boldsymbol{u})-\frac{1}{\sqrt{m}}\frac{\lfloor m(\theta+h)\rfloor-\lfloor m\theta\rfloor}{m}\sum_{t=1}^{m}h_t(\boldsymbol{u})\right)^{2r}\omega(\boldsymbol{u})d\boldsymbol{u}\\
&=\int_{\mathbb{R}^d}\mathrm{E}\left(A-B\right)^{2r}\omega(\boldsymbol{u})d\boldsymbol{u},
\end{aligned}
\tag{2-17}
$$

其中 $A \overset{\Delta}{=} \frac{1}{\sqrt{m}} \sum_{t=\lfloor m(1+\theta)\rfloor+1}^{\lfloor m(1+\theta+h)\rfloor} h_t(\boldsymbol{u}), B \overset{\Delta}{=} \frac{1}{\sqrt{m}} \frac{\lfloor m(\theta+h)\rfloor - \lfloor m\theta\rfloor}{m} \sum_{t=1}^{m} h_t(\boldsymbol{u})$。进一步可得

$$\begin{aligned} \mathrm{E}\,(A-B)^{2r} &= \mathrm{E}\,(|A-B|)^{2r} \\ &\le \mathrm{E}\,(|A|+|B|)^{2r} \\ &\le 2^{2r-1}\mathrm{E}(A^{2r}+B^{2r}), \end{aligned} \tag{2-18}$$

$$\begin{aligned} \mathrm{E}(A^{2r}) &= \mathrm{E}\left(\frac{1}{\sqrt{m}} \sum_{t=\lfloor m(1+\theta)\rfloor+1}^{\lfloor m(1+\theta+h)\rfloor} h_t(u)\right)^{2r} \\ &= m^{-r}\mathrm{E}\left(\sum_{t=\lfloor m(1+\theta)\rfloor+1}^{\lfloor m(1+\theta+h)\rfloor} h_t(\boldsymbol{u})\right)^{2r} \\ &\le Cm^{-r}(mh)^{\frac{2r}{2}} \\ &\le Ch^r, \end{aligned} \tag{2-19}$$

$$\begin{aligned} \mathrm{E}(B^{2r}) &= E\left(\frac{1}{\sqrt{m}} \frac{\lfloor m(\theta+h)\rfloor - \lfloor m\theta\rfloor}{m} \sum_{t=1}^{m} h_t(\boldsymbol{u})\right)^{2r} \\ &= m^{-r}\frac{(\lfloor m(\theta+h)\rfloor - \lfloor m\theta\rfloor)^{2r}}{m^{2r}}\mathrm{E}\left(\sum_{t=1}^{m} h_t(\boldsymbol{u})\right)^{2r} \\ &\le Cm^{-r}\frac{(\lfloor m(\theta+h)\rfloor - \lfloor m\theta\rfloor)^{2r}}{m^{2r}} m^{\frac{2r}{2}} \\ &\le Ch^{2r}, \end{aligned} \tag{2-20}$$

其中 C 为一个有限常数，可以在实数范围内变化，(2-19) 和 (2-20) 由引理 2.2 中的矩不等式得到。

结合 (2-17)-(2-20) 以及权重函数 $\omega(\boldsymbol{u})$ 的可积性可知，存在常数 a 和 C，使得 $\sqrt{I_1} \le C|h|^a$。按照类似的方法，可以证明 $\sqrt{I_2} \le C$。因此，$\sqrt{I_1}\sqrt{I_2} \le C|h|^a$，于是，式 (2-15) 中最后一行的不等式成立。

按照类似于 Hlávka 等人[1,60] 的方法，根据 Billingsley[61] 的定理 15.6，可以得出以下弱收敛结果：

$$V_m(\theta) \Longrightarrow \frac{1}{(1+\theta)^2}\int_{\mathbb{R}^d} \left(Z(1+\theta,\boldsymbol{u}) - (1+\theta)\,Z(1,\boldsymbol{u})\right)^2 \omega(\boldsymbol{u})d\boldsymbol{u}.$$

按照类似的路线进行，可以得到关于 $\|P_m(\theta,\boldsymbol{u})\|_\omega^2$ 和 $\|P(\theta,\boldsymbol{u})\|_\omega^2$ 的类似结论：$\|P_m(\theta,\boldsymbol{u})\|_\omega^2 \Longrightarrow \|P(\theta,\boldsymbol{u})\|_\omega^2$。此外，由连续映射定理可得，$S_m^2$ 的极限分布与

$$\int_0^1 \|P(\theta,\boldsymbol{u})\|_\omega^2 d\theta \overset{D}{=} \int_0^1\int_{\mathbb{R}^d} (Z(\theta,\boldsymbol{u}) - \theta Z(1,\boldsymbol{u}))^2\omega(\boldsymbol{u})d\boldsymbol{u}d\theta$$

的分布相同。

注意到 $\{Z(1+\theta,\boldsymbol{u})-(1+\theta)\,Z(1,\boldsymbol{u})\},\theta\in(0,L)$ 与 $\{Z(\theta,\boldsymbol{v})-\theta Z(1,\boldsymbol{v})\},\theta\in(0,1)$ 是独立的。可通过计算它们的协方差来验证这一点：

$$\begin{aligned}
&\mathrm{Cov}\Big\{\Big(Z(1+\theta,\boldsymbol{u})-(1+\theta)\,Z(1,\boldsymbol{u})\Big),\Big(Z(\theta,\boldsymbol{v})-\theta Z(1,\boldsymbol{v})\Big)\Big\}\\
&=\mathrm{Cov}\{Z(1+\theta,\boldsymbol{u}),Z(\theta,\boldsymbol{v})\}-\theta\mathrm{Cov}\{Z(1+\theta,\boldsymbol{u}),Z(1,\boldsymbol{v})\}\\
&-(1+\theta)\mathrm{Cov}\{Z(1,\boldsymbol{u}),Z(\theta,\boldsymbol{v})\}+\theta(1+\theta)\mathrm{Cov}\{Z(1,\boldsymbol{u}),Z(1,\boldsymbol{v})\}\\
&=\big(\theta-\theta-\theta(1+\theta)+\theta(1+\theta)\big)\Sigma(\boldsymbol{u},\boldsymbol{v})\\
&=0.
\end{aligned}$$

因此，当 $m\to\infty$ 时，$\max\limits_{1\le k\le Lm}D_m^{SN}(k)$ 的渐近分布与

$$\sup_{\theta\in(0,L)}\frac{1}{(1+\theta)^2}\frac{\int_{\mathbb{R}^d}\left(Z(1+\theta,\boldsymbol{u})-(1+\theta)\,Z(1,\boldsymbol{u})\right)^2\omega(\boldsymbol{u})d\boldsymbol{u}}{\int_0^1\int_{\mathbb{R}^d}\left(Z(\theta',\boldsymbol{u})-\theta' Z(1,\boldsymbol{u})\right)^2\omega(\boldsymbol{u})d\boldsymbol{u}d\theta'}$$

的分布相同。

接下来对渐近分布进行适当简化。注意到 $\{Z(1+\theta,\boldsymbol{u})-Z(1,\boldsymbol{u})\},\theta>0$ 与 $Z(1,\boldsymbol{u})$ 是独立的，这一点可以通过计算它们的协方差来验证。此外 $\{Z(1+\theta,\boldsymbol{u})-Z(1,\boldsymbol{u})\},\theta>0$ 可以视为一个新的零均值高斯过程 $\{Z_1(\theta,\boldsymbol{u})\},\theta>0$，二者有着相同的协方差结构，这可以通过比较它们的协方差结构得到。于是

$$\begin{aligned}
Z(1+\theta,\boldsymbol{u})-(1+\theta)\,Z(1,\boldsymbol{u})&=(Z(1+\theta,\boldsymbol{u})-Z(1,\boldsymbol{u}))-\theta Z(1,\boldsymbol{u})\\
&\overset{D}{=}Z_1(\theta,\boldsymbol{u})-\theta Z_2(1,\boldsymbol{u}),
\end{aligned}$$

其中 $Z_1(\theta,\boldsymbol{u})$ 和 $Z_2(\theta,\boldsymbol{u})$ 是两个独立的零均值高斯过程，二者有着相似的协方差结构。于是，当 $m\to\infty$ 时，$\max\limits_{1\le k\le Lm}D_m^{SN}(k)$ 的极限分布与下式的分布相同：

$$\sup_{\theta\in(0,L)}\frac{1}{(1+\theta)^2}\frac{\int_{\mathbb{R}^d}\left(Z_1(\theta,\boldsymbol{u})-\theta Z_2(1,\boldsymbol{u})\right)^2\omega(\boldsymbol{u})d\boldsymbol{u}}{\int_0^1\int_{\mathbb{R}^d}\left(Z(\theta',\boldsymbol{u})-\theta' Z(1,\boldsymbol{u})\right)^2\omega(\boldsymbol{u})d\boldsymbol{u}d\theta'}.$$

□

接下来证明定理2.2。当备择假设成立时，如假设2.3所示，

$$\phi_t=\begin{cases}\phi_{(0)},t=1,\ldots,m+k^*,\\ \phi_{(*)},t=m+k^*+1,\cdots,Lm,\end{cases}$$

其中 $k^*=\lfloor m\theta_*\rfloor$，$\theta_*\in(0,L)$ 为变点，ϕ_t 为 $\boldsymbol{X}_t$ 的特征函数，$\phi_{(0)}$ 和 $\phi_{(*)}$ 分别为变点前后的不同特征函数。

证明 对任意 $\theta \in (\theta_*, L)$，令 $k = \lfloor m\theta \rfloor > k^*$，则有

$$\frac{1}{m}\left(\sum_{t=m+1}^{m+k} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle} - \frac{k}{m}\sum_{t=1}^{m} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle}\right) \xrightarrow{\Pr} (\theta - \theta^*)(\phi_{(*)}(\boldsymbol{u}) - \phi_{(0)}(\boldsymbol{u})),$$

$$\frac{1}{m^2}\int_{\mathbb{R}^d}\left(\sum_{t=m+1}^{m+k} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle} - \frac{k}{m}\sum_{t=1}^{m} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle}\right)^2 \omega(\boldsymbol{u})d\boldsymbol{u} \xrightarrow{\Pr} (\theta - \theta^*)^2 \int_{\mathbb{R}^d} (\phi_{(*)}(\boldsymbol{u}) - \phi_{(0)}(\boldsymbol{u}))^2 \omega(\boldsymbol{u})d\boldsymbol{u},$$

$$\begin{aligned} D_m(k) &= \frac{1}{m(1+\frac{k}{m})^2}\int_{\mathbb{R}^d}\left(\sum_{t=1}^{m+k} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle} - \frac{m+k}{m}\sum_{t=1}^{m} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle}\right)^2 \omega(\boldsymbol{u})d\boldsymbol{u} \\ &\geq \frac{1}{(1+L)^2}\left(\frac{1}{m}\int_{\mathbb{R}^d}\left(\sum_{t=1}^{m+k} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle} - \frac{m+k}{m}\sum_{t=1}^{m} \mathrm{e}^{i\langle \boldsymbol{X}_t, \boldsymbol{u}\rangle}\right)^2 \omega(\boldsymbol{u})d\boldsymbol{u}\right) \xrightarrow{\Pr} \infty. \end{aligned}$$

易得定理2.2成立。 □

2.6 本章小节

当观测值之间存在较强的时间依赖性时，现有非参数在线监测方法经常出现经验水平扭曲现象。为解决这一问题，本文提出了一个基于经验特征函数的自正则在线监测方法 D_m^{SN}。本文研究了所提监测统计量在原假设和备择假设下的渐近性质，并采用多元 Stationary Bootstrap 方法估计检验的临界值。数值模拟结果表明，与现有方法相比，D_m^{SN} 在改善经验水平扭曲方面具有显著优势。D_m^{SN} 是一个更为稳定的检验方法，且有着较好的检验功效。最后，对两台风机的叶片振动数据进行分析，展现了该方法的实际应用价值。

第 3 章　基于 PQMLE 的整值时间序列模型参数变点监测

上一章在无分布假定的框架下探讨了连续值时间序列的变点监测问题。整值时间序列是时间序列分析中的重要研究对象。针对整值时间序列模型的参数变点监测问题，本文提出了一种基于泊松拟极大似然估计（PQMLE）的修正 CUSUM 在线监测方法。首先基于训练样本估计模型参数，随后计算模型残差并构造修正 CUSUM 监测统计量。该方法不依赖于数据的特定分布假设，在有效控制第一类错误率的同时，有着较好的检测能力。

本章内容安排如下 3.1 节介绍了一类半参数框架下的整值时间序列模型，并给出了该模型参数的 PQMLE 渐近性质。3.2 节阐述了整值时间序列模型的参数变点监测问题，提出了基于 PQMLE 的修正 CUSUM 在线监测方法，并研究其渐近性质。3.3 节通过数值模拟研究了所提方法的有限样本表现。3.4 节给出了本章主要定理的证明。3.5 节为本章总结小结。

3.1　模型假设

令 $\{Y_t\}_{t\in\mathbb{Z}}$ 为一非负整值时间序列，其遵循特定的参数模型 $\mathcal{M}_\theta$：

$$\lambda_t = \mathrm{E}(Y_t|\mathcal{F}_{t-1}) = f_\theta(Y_{t-1}, Y_{t-2}, \dots), \tag{3-1}$$

其中 λ_t 为 Y_t 的条件均值函数，$\mathcal{F}_t = \sigma\{Y_t, Y_{t-1}, \cdots\}$ 是由 $Y_t, Y_{t-1}, \cdots$ 生成的 σ-代数。f_θ 为非负可测函数，θ 属于某个参数空间 $\Theta \subset \mathbb{R}^d$。对给定的参数 θ，本章假设任何属于 $\mathcal{M}_\theta$ 的 $\{Y_t\}_{t\in\mathbb{Z}}$ 为平稳遍历过程，且存在某常数 $c > 2$，使得 $E{Y_t}^{1+c} < \infty$。参照 Diop and Kengne[20]，对条件期望函数 f_θ 施加一些必要的 Lipschitz 型条件：

假设$\mathbf{A_i}(\Theta)$ (i=0,1,2)　对任一 $y \in \mathbb{N}_0^{\mathbb{N}}$，$\mathbb{N}_0 = \mathbb{N} \cup 0$，函数 $\theta \mapsto f_\theta(y)$ 在 Θ 上 i 阶连续可微，且满足 $\|\partial^i f_\theta(0)/\partial\theta^i\|_\Theta < \infty$。另外，存在一列非负实数序列 $(\alpha_k^{(i)})_{k\geq 1}$，其满足 $\sum_{k=1}^\infty \alpha_k^{(0)} < 1$ （$\sum_{k=1}^\infty \alpha_k^{(i)} < \infty, i = 1, 2$）；使得对于任意的 $y, y' \in \mathbb{N}_0^{\mathbb{N}}$，有

$$\sup_{\theta\in\Theta}\left\|\frac{\partial^i f_\theta(y)}{\partial\theta^i} - \frac{\partial^i f_\theta(y')}{\partial\theta^i}\right\| \leq \sum_{k=1}^\infty \alpha_k^{(i)}|y_k - y_k'|,$$

其中 $\|\cdot\|$ 表示向量范数。另外，对某常数 $\nu > \frac{3}{2}$，$\alpha_k^{(0)} + \alpha_k^{(1)} = O(k^{-\nu})$。

$\mathcal{M}_\theta$ 是一类半参数模型，因为它仅指定整值时间序列的条件均值函数 λ_t，无需具体的概率分布假设。该模型包括多个经典的整值时间序列模型[19,20]。例如，泊松 INGARCH 模型[15]、负二项 INGARCH 模型[44] 以及 INAR 模型[13,14,43]。特别地，

泊松 INGARCH(1,1) 模型和负二项 INGARCH(1,1) 模型分别为

$$Y_t|\mathcal{F}_{t-1} \sim \text{Poisson}(\lambda_t), \quad \lambda_t = \omega + \alpha\lambda_{t-1} + \beta Y_{t-1},$$
$$Y_t|\mathcal{F}_{t-1} \sim \text{NB}(r, p_t), \quad \lambda_t = \frac{r(1-p_t)}{p_t} = \omega + \alpha\lambda_{t-1} + \beta Y_{t-1},$$

其中 $\omega > 0, 0 \le \alpha + \beta < 1$，未知参数 $\theta = (\omega, \alpha, \beta)^\top$ 唯一确定 INGARCH(1,1) 模型的条件均值。此外，$\mathcal{M}_\theta$ 还包含常见的 INAR(1) 模型：$Y_t = \alpha \circ Y_{t-1} + e_t$，$0 < \alpha < 1$。其中 $\circ$ 为二项稀疏算子，满足 $\alpha \circ Y_{t-1} = \sum_{i=1}^{Y_{t-1}} Z_i$，$Z_i$ 为一系列参数为 α 的独立同分布伯努利随机变量。创新项 e_t 为一系列独立同分布的离散随机变量。在 INAR(1) 模型中，条件均值由参数 $\theta = (\omega, \alpha)^\top$ 唯一确定：$\lambda_t = \alpha Y_{t-1} + \omega$，$\omega = E(e_t)$。

在某些条件下，Ahmad 和 Francq[21] 证明了模型 $\mathcal{M}_{\theta_0}$ 中参数 θ_0 的 PQMLE 的渐近性质。令 $m \ge 1$，$\theta_0 \in \Theta$。若 $\{Y_1, \cdots, Y_m\} \in \mathcal{M}_{\theta_0}$，那么未知参数 θ_0 的泊松拟极大似然估计为

$$\hat{\theta}_{1:m} = \arg\max_{\theta \in \Theta} \sum_{t=1}^{m} \hat{l}_t(\theta), \tag{3-2}$$

其中 $\hat{l}_t(\theta) = -\tilde{\lambda}_t(\theta) + Y_t \log \tilde{\lambda}_t(\theta)$，$\tilde{\lambda}_t(\theta) = f_\theta(Y_{t-1}, \ldots, Y_1, y_0, y_0, \cdots)$，$y_0$ 为一个预先给定的非负整数（如 $y_0 = 0$）。为了得到参数估计量 $\hat{\theta}_m$ 的相合性和渐近正态性，引入以下条件[21]：

假设 A0 对所有的 $(\theta, \theta') \in \Theta \times \Theta$，若对某些 $t \in \mathbb{N}$，有 $f_\theta(Y_{t-1}, Y_{t-2}, \ldots) = f_{\theta'}(Y_{t-1}, Y_{t-2}, \ldots)$ a.s. 。那么必有 $\theta = \theta'$。此外，存在 $c_0 > 0$ 使得对于所有 $y \in \mathbb{N}_0^{\mathbb{N}}$，都有 $\inf_{\theta \in \Theta} f_\theta(y) \ge c_0$。

假设 A1 θ_0 是 $\Theta \subset \mathbb{R}^d$ 的内点。

假设 A2 当 $t \to \infty$ 时，有 $a_t \xrightarrow{\text{a.s.}} 0$，$Y_t a_t \xrightarrow{\text{a.s.}} 0$，其中 $a_t = \sup_{\theta \in \Theta} \left|\lambda_t(\theta) - \tilde{\lambda}_t(\theta)\right|$。

假设 A3 矩阵 $J = \mathrm{E}\left(\frac{1}{\lambda_t(\theta_0)} \frac{\partial \lambda_t(\theta_0)}{\partial \theta} \frac{\partial \lambda_t(\theta_0)}{\partial \theta'}\right)$ 和 $I = \mathrm{E}\left(\frac{\mathrm{Var}(Y_t|F_{t-1})}{\lambda_t^2(\theta_0)} \frac{\partial \lambda_t(\theta_0)}{\partial \theta} \frac{\partial \lambda_t(\theta_0)}{\partial \theta'}\right)$ 存在。

假设 A4 对于所有 $c' \in \mathbb{R}$，若 $c' \frac{\partial \lambda_t(\theta_0)}{\partial \theta} = 0$ a.s.，则 $c' = 0$。

假设 A5 存在 θ_0 的邻域 $V(\theta_0)$，使得对于所有 $i, k \in \{1, \ldots, d\}$，

$$\mathrm{E}\left(\sup_{\theta \in V(\theta_0)} \left|\frac{\partial^2 \lambda_t(\theta)}{\partial \theta_i \partial \theta_k}\right|\right) < \infty.$$

假设 A6 对于某个 $h > \frac{1}{2}$，$b_t = O(t^{-h})$，$b_t Y_t = O(t^{-h})$，$a_t d_t Y_t = O(t^{-h})$，其中

$$b_t = \sup_{\theta \in \Theta} \left\{\mathrm{E}\left(\left\|\frac{\partial \lambda_t(\theta)}{\partial \theta} - \frac{\partial \tilde{\lambda}_t(\theta)}{\partial \theta}\right\|\right)\right\},$$

$$d_t = \sup_{\theta \in \Theta} \max\left\{\mathrm{E}\left(\left\|\frac{1}{\lambda_t(\theta)} \frac{\partial \lambda_t(\theta)}{\partial \theta}\right\|\right), \mathrm{E}\left(\left\|\frac{1}{\tilde{\lambda}_t(\theta)} \frac{\partial \tilde{\lambda}_t(\theta)}{\partial \theta}\right\|\right)\right\}.$$

在假设A0-A6下，Ahmad 和 Franc[21] 证明了估计量 $\hat{\theta}_{1:m}$ 的强相合性和渐近正态性。当 $m \to \infty$ 时，

$$\hat{\theta}_{1:m} \xrightarrow{\text{a.s.}} \theta_0; \sqrt{m}(\hat{\theta}_{1:m} - \theta_0) \xrightarrow{d} N(0, \Sigma^{-1}), \tag{3-3}$$

其中 $\Sigma = JI^{-1}J$，J 和 I 定义于假设A3中。

3.2 整值时间序列模型参数变点监测

本节首先利用 PQMLE 方法估计整值时间序列模型的参数，再构造基于模型残差的修正 CUSUM 监测统计量，最后给出监测统计量在原假设下的渐近分布及备择假设下的一致性。

为便于说明，令 $\{Y_t\}$ 为遵循特定参数模型 $\mathcal{M}(\theta_t)$ 的整值时间序列。整值时间序列模型的参数变点监测问题如下。在监测开始之前，假设已经获得一组历史数据 $Y_1, \cdots, Y_m$。这些数都据遵循模型 $\mathcal{M}(\theta_0)$，即 $\theta_1 = \theta_2 = \cdots = \theta_m = \theta_0$。将这组平稳的历史数据作为训练样本。在时刻 m 之后，新的数据 $Y_{m+1}, Y_{m+2}, \ldots$ 逐步到达。在线监测监测方法的目的是在模型参数发生变化后，尽快发出警报。

考虑以下假设检验：

$$\begin{aligned} H_0 :& \theta_t = \theta_0, m+1 \le t \le m+Lm, \\ H_1 :& \theta_t = \theta_0, m+1 \le t \le m+k^*; \theta_t = \theta^*, m+k^*+1 \le t \le m+Lm, \end{aligned} \tag{3-4}$$

其中 $\theta_0 \neq \theta^*$ 为变点前后的未知参数，$m+k^*(k^* \ge 0)$ 为未知的变点，$L > 0$ 是预先指定的监测周期。在线监测方法可分为封闭式（$0 < L < \infty$）和开放式（$L = \infty$）两种。对于封闭式在线监测方法，如果整个监测周期内未检测到结构变化，则监测将在时刻 $Lm+1$ 停止。相比之下，开放式在线监测方法可能会无休止地进行[49]。

为检验假设 (3-4)，受 Gösmann 等人[24] 的启发，本文提出以下基于模型残差的修正 CUSUM 统计量：

$$E_m(k) = \max_{j=0}^{k-1} (\hat{\sigma}_m^2)^{-1/2} \frac{k-j}{\sqrt{m}} \left| \frac{1}{m+j} \sum_{t=1}^{m+j} \hat{\epsilon}_t - \frac{1}{k-j} \sum_{t=m+j+1}^{m+k} \hat{\epsilon}_t \right|, k = 1, 2, \ldots, Lm, \tag{3-5}$$

其中 $\hat{\epsilon}_t = Y_t - \lambda_t(\hat{\theta}_{1:m})$ 为模型残差，$\hat{\theta}_{1:m}$ 为基于训练样本 $Y_1, \cdots, Y_m$ 的泊松拟极大似然估计。$\hat{\sigma}_m^2 = \frac{1}{m}\sum_{t=1}^m \hat{\epsilon}_t^2$ 为模型残差的方差估计。在时刻 $m+k$，$E_m(k)$ 不断比较潜在变点（$m+j, 0 \le j < k$）前后的模型残差。如果 $\{Y_t\}$ 所遵循模型的参数在某一时刻 $m+k^*$ 后发生变化，那么对于 $k > k^*$，统计量 $E_m(k)$ 的取值将远大于 0。

当统计量 $E_m(k)$ 的取值很大时，应拒绝原假设。该规则由以下停止时间定义

$$\tau(m)=\begin{cases}\inf\left\{k: E_m(k)>\frac{1}{\rho(\frac{k}{m})}C_\alpha, 1\le k\le Lm\right\},\\ min\{Lm+1,\infty\}, E_m(k)\le\frac{1}{\rho(\frac{k}{m})}C_\alpha, \forall 1\le k\le Lm,\end{cases} \tag{3-6}$$

其中常数 C_α 是序贯检验的临界值。边界函数 $\rho(\cdot)$ 用来控制 CUSUM 统计量的渐近行为[51]。$\tau(m)$ 表示停止监测的时间点。在封闭式在线监测方法（$0<L<\infty$）中，当修正 CUSUM 统计量 $E_m(k)$ 超过临界曲线 $\frac{1}{\rho(\frac{k}{m})}C_\alpha$，或收集的数据达到预定数量 Lm 时，监测过程终止。对 $k\ge 1$，依次检查条件 $E_m(k)>\frac{1}{\rho(\frac{k}{m})}C_\alpha$ 是否成立。若存在 k 满足该条件，则令 $\tau(m)=k$ 并停止监测，否则继续监测。另外，若 $E_m(k)\le\frac{1}{\rho(\frac{k}{m})}C_\alpha, \forall 1\le k\le Lm$，则在时刻 $Lm+1$ 停止监测。开放式在线监测方法（$L=\infty$）则没有最长运行时间的限制。

接下来，本文将研究所提在线监测方法在原假设下的渐近性质。首先规定 $\mathbb{R}_{\ge 0}$ 和 $\mathbb{R}_{>0}$ 分别为非负实数集和正实数集，$\{W(s)\}_{s\in[0,\infty)}$ 表示一个标准布朗运动。令 $\epsilon_t=Y_t-\lambda_t(\theta_0)$ 为真实参数下的残差序列，其方差为 σ^2。在原假设下，$(Y_t,\lambda_t(\theta_0))$ 都是平稳遍历过程[20]，因此 ϵ_t 为平稳遍历的鞅差序列。结合 PQMLE 的相合性与渐近正态性，易知 $\hat{\sigma}_m^2$ 是 σ^2 的相合估计，$\hat{\sigma}_m^2=\sigma^2+o_P(1)$。引入以下关键假设：

假设 3.1 对于每个 $m\in\mathbb{N}$，存在两个独立的标准布朗运动 $W_{m,1}$ 和 $W_{m,2}$，使得对于某 $0<\xi<\frac{1}{2}$，以下近似成立：

$$\begin{aligned}\sup_{k=1}^{\infty}\frac{1}{k^\xi}\left|\sum_{t=m+1}^{m+k}\epsilon_t-\sigma W_{m,1}(k)\right|&=O_P(1),\\ \frac{1}{m^\xi}\left|\sum_{t=1}^{m}\epsilon_t-\sigma W_{m,2}(m)\right|&=O_P(1).\end{aligned} \tag{3-7}$$

假设 3.2 边界函数 $\rho(\cdot)\colon\mathbb{R}_{\ge 0}\mapsto\mathbb{R}_{>0}$ 为正连续函数。在 $L=\infty$ 的情况下，其满足以下条件：

(1) $\limsup_{t\to\infty}t\rho(t)<\infty$，

(2) $1/\rho$ 在 $\mathbb{R}_{\ge 0}$ 上一致连续。

假设 3.3 令 $R_{i,j}=\frac{1}{j-i+1}\sum_{t=i}^{j}(\hat{\epsilon}_t-\epsilon_t)$。对 $k>m$，当 $m\to\infty$ 时，

$$\max_{1\le i<j\le k}\frac{(j-i+1)}{\sqrt{k}}|R_{i,j}|=o(1) \tag{3-8}$$

以概率 1 成立。

假设3.1为一致不变性原理（Invariance Principle），该假设在变点监测研究中十分常见[17,62]。在本文中，可使用平稳鞅差序列的强不变性原理[63] 验证该假设。平

稳鞅差序列的强不变性原理可参见 Lee 和 Lee[18]：对某常数 $0 < \xi < \frac{1}{2}$，存在一个标准布朗运动 $\{W(s)\}_{s\in[0,\infty)}$，使得 $\sum_{t=1}^{k} \epsilon_t - \sigma W(k) = O(k^{\xi})$ 几乎处处成立。

假设3.2中的 (1) 和 (2) 是对边界函数的一些限制性条件，用来控制 CUSUM 统计量的行为，以确保渐近性质成立[24]。假设3.3对余项 $R_{i,j}$ 施加了必要的限制，确保可以使用估计残差 $\hat{\epsilon}_t$ 替换真实值 ϵ_t。此假设可以通过对 $R_{i,j}$ 泰勒展开进行验证[18,64]。此外，基于该假设可以推导出以下关键结论[24]，用于证明最终的弱收敛结果。当 $m \to \infty$ 时，

$$\sup_{k=1}^{\infty} \max_{1\le i<j\le m+k} \frac{(j-i+1)}{(m+k)^{1/2}} |R_{i,j}| = \sup_{k=m+1}^{\infty} \max_{1\le i<j\le k} \frac{(j-i+1)}{k^{1/2}} |R_{i,j}| = o(1) \text{ a.s.}$$

在原假设下，监测统计量的渐近分布如下。

定理 3.1 若假设$\mathrm{A_i}(\Theta)$ (i=0,1,2)、假设A0-A6 以及假设3.1-3.3成立，则在原假设下，当 $m \to \infty$ 时有以下弱收敛结果：

（1）封闭式在线监测方法（$L < \infty$）

$$\sup_{k=1}^{Lm} \rho(k/m) E_m(k) \Longrightarrow \sup_{0\le t\le L} \max_{0\le s\le t} (t+1)\rho(t) \left| W\left(\frac{s}{1+s}\right) - W\left(\frac{t}{1+t}\right) \right|, \tag{3-9}$$

其中 $\Longrightarrow$ 表示弱收敛，$W(\cdot)$ 是一个标准布朗运动。

（2）开放式在线监测方法（$L = \infty$）

$$\sup_{k=1}^{\infty} \rho(k/m) E_m(k) \Longrightarrow \sup_{0\le t<\infty} \max_{0\le s\le t} (t+1)\rho(t) \left| W\left(\frac{s}{1+s}\right) - W\left(\frac{t}{1+t}\right) \right|. \tag{3-10}$$

定理 3.1 给出了所提出的基于模型残差的修正 CUSUM 监测统计量在原假设下的渐近分布。边界函数 $\rho(t)$ 保证了式 (3-9) 和 (3-10) 右侧的随机变量是依概率有界的。检验的临界值 C_α 可取为对应渐近分布的 $1-\alpha$ 分位数，进而保证在线监测方法的渐近检验水平为 α。以开放式监测方法为例：

$$\begin{aligned} &\lim_{m\to\infty} \Pr(\tau(m) < \infty \mid H_0) \\ &= \Pr\left(\sup_{0\le t<\infty} \max_{0\le s\le t} (t+1)\rho(t) \left| W\left(\frac{s}{1+s}\right) - W\left(\frac{t}{1+t}\right) \right| > C_\alpha \right) = \alpha. \end{aligned} \tag{3-11}$$

可以看出，定理3.1中的渐近分布的最终形式依赖于边界函数的选择。通常，边界函数的选择主要考虑其数学上的便利性，以便获得易于处理的渐近分布[6]。可以选择一个满足假设3.2的合适函数作为边界函数，并指定常数 C_α 为对应渐近分布的分位数。本文选择的边界函数为以下参数族：

$$\rho_\gamma(t) = (1+t)^{-1} \left(\frac{t}{1+t}\right)^{-\gamma}, \gamma \in [0, 1/2). \tag{3-12}$$

此类边界函数在变点监测领域中应用广泛[17,26,49]，参数 γ 用于调整检测延迟[12,28]。

推论 3.1 对于给定的边界函数 $\rho_\gamma(t)$，定理3.1中的渐近分布简化如下：

（1）封闭式在线监测方法（$L<\infty$）

$$\begin{aligned}&\sup_{0\le t\le L}\max_{0\le s\le t}(t+1)\rho_\gamma(t)\left|W\left(\frac{s}{1+s}\right)-W\left(\frac{t}{1+t}\right)\right|\\&\qquad\overset{D}{=}\sup_{0\le t\le L/(1+L)}\max_{0\le s\le t}\frac{1}{t^\gamma}\left|W(t)-W(s)\right|,\end{aligned}\tag{3-13}$$

其中 $\overset{D}{=}$ 表示同分布。

（2）开放式在线监测方法（$L<\infty$）

$$\begin{aligned}&\sup_{0\le t<\infty}\max_{0\le s\le t}(t+1)\rho_\gamma(t)\left|W\left(\frac{s}{1+s}\right)-W\left(\frac{t}{1+t}\right)\right|\\&\qquad\overset{D}{=}\sup_{0\le t<1}\max_{0\le s\le t}\frac{1}{t^\gamma}\left|W(t)-W(s)\right|.\end{aligned}\tag{3-14}$$

接下来研究所提在线监测方法在备择假设下的一致性。与 Gösmann 等人[24] 所列条件有所不同，本文对需要的假设进行了适当调整，以得到所需的渐近性质。

假设 3.4 在备择假设 H_1 下，

$$\theta_t=\theta_0, m+1\le t\le m+k^*; \theta_t=\theta^*, m+k^*+1\le t\le m+Lm,$$

其中变点 $k^*=k_m^*\in\mathbb{N}$ 可能依赖于 m，$\theta_0\neq\theta^*$ 表示变点前后不同的模型参数。在变点之前，假设真实参数 θ_0 下的残差序列 $\{\epsilon_t\}$ 以及余项 $R_{i,j}$ 满足以下假设：

$$\frac{1}{\sqrt{m+k_m^*}}\left|\sum_{t=1}^{m+k_m^*}\epsilon_t\right|=O_P(1), \sqrt{m+k_m^*}|R_{1,m+k_m^*}|=O_P(1).$$

第一个式子可由平稳遍历鞅差序列 $\{\epsilon_t\}$ 的不变性原理或者中心极限定理得到，第二个式子可由 PQMLE 的强相合性和渐近正态性得到。接下来，对变点之后的情况作出必要的假设。定义 $\epsilon_t^*=Y_t-\lambda_t(\theta^*)$ 为变点后的真实残差序列。

（1）封闭式在线监测方法（$L<\infty$）

假设变点 $k_m^*=\lfloor ms^*\rfloor$，$s^*\in(0,L)$，则 $\frac{k_m^*}{m}=O(1)$。假设存在正常数 c_a，使得

$$\frac{1}{\sqrt{m}}\left|\sum_{t=m+k_m^*+1}^{m+k_m^*+\lfloor c_a m\rfloor}\epsilon_t^*\right|=O_P(1).$$

另外，假设 $c_a+s^*<L$。

（2）开放式在线监测方法（$L=\infty$）

若 $\frac{k_m^*}{m}=O(1)$，则与封闭式在线监测方法中的假设相同。

若 $\frac{k_m^*}{m}\to\infty$，则假设

$$\frac{1}{\sqrt{k_m^*}}\left|\sum_{t=m+k_m^*+1}^{m+k_m^*+\lfloor c_a k_m^*\rfloor}\epsilon_t^*\right|=O_P(1).$$

另外，对开放式监测方法，假设权重函数还满足：$\liminf_{t\to\infty} t\rho(t) > 0$。

显然，若变点前后的真实残差序列都满足中心极限定理，以上条件自然成立。在 k_m^* 与训练样本量 m 成比例时，常数 c_a 确保有足够的变点后数据用于检测出变点。对于变点非常靠后的情形（即 $k_m^*/m \to \infty$），假设3.4额外规定了权重函数增长速度的下限[24]，式 (3-12) 中定义的函数族 $\rho_\gamma(t)$ 都满足这一假定。

定理 3.2 首先令假设$A_i(\Theta)$ (i=0,1,2)、假设A0-A6以及假设3.2成立。

（1）封闭式在线监测方法（$L < \infty$）

若假设3.4的相应条件成立，则在备择假设下，当 $m \to \infty$ 时，

$$\sup_{k=1}^{Lm} \rho\left(k/m\right) E_m(k) \xrightarrow{\Pr} \infty.$$

（2）开放式在线监测方法（$L = \infty$）

若假设3.4的相应条件成立，则在备择假设下，当 $m \to \infty$ 时，

$$\sup_{k=1}^{\infty} \rho\left(k/m\right) E_m(k) \xrightarrow{\Pr} \infty.$$

定理3.2表明本文所采用的在线监测方法在备择假设下具有一致性。由此可得，对任一常数 $c \in \mathbb{R}$，当 $L < \infty$ 时，

$$\lim_{m\to\infty} \Pr\left(\sup_{k=1}^{Lm} \rho\left(k/m\right) E_m(k) > c\right) = 1.$$

对于 $L = \infty$，有类似的结论成立。因此，当整值时间序列模型的参数从 θ_0 变为 θ^* 时，封闭式和开放式在线监测方法的检验功效渐近为 1，即 $\lim_{m\to\infty} \Pr(\tau(m) < \infty \mid H_1) = 1$。

3.3 数值模拟

本节将通过数值模拟研究所采用的修正 CUSUM 在线监测方法的有限样本表现。所有模拟结果都基于 1000 次重复实验得到，其中序贯检验在 5% 的显著性水平下进行。训练样本大小为 $m = \{300, 600, 900\}$，监测周期为 $L = \{1, 2, 3\}$，边界函数中的参数选为 $\gamma = \{0, 0.25, 0.45\}$。比较起见，本文考虑了两类经典的 CUSUM 统计量，标准 CUSUM 统计量[18,28]$Q_m(k)$ 和 Page 型 CUSUM 统计量[62]$P_m(k)$：

$$Q_m(k) = \frac{k}{\sqrt{m}}(\hat{\sigma}_m^2)^{-1/2}\left|\frac{1}{m}\sum_{t=1}^{m}\hat{\epsilon}_t - \frac{1}{k}\sum_{t=m+1}^{m+k}\hat{\epsilon}_t\right|,$$

$$P_m(k) = \frac{k-j}{\sqrt{m}}\max_{j=0}^{k-1}(\hat{\sigma}_m^2)^{-1/2}\left|\frac{1}{m}\sum_{t=1}^{m}\hat{\epsilon}_t - \frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right|.$$

这两个 CUSUM 监测统计量的渐近分布可参考 Gösmann 等人[24]。对于封闭式情形（$L < \infty$），

$$\begin{aligned}\sup_{k=1}^{Lm} \rho_\gamma(k/m) Q_m(k) &\Longrightarrow \sup_{0 \le t \le L/(1+L)} \frac{1}{t^\gamma} |W(t)|, \\ \sup_{k=1}^{Lm} \rho_\gamma(k/m) P_m(k) &\Longrightarrow \sup_{0 \le t \le L/(1+L)} \max_{0 \le s \le t} \frac{1}{t^\gamma} \left| W(t) - \frac{1-t}{1-s} W(s) \right|.\end{aligned} \tag{3-15}$$

对于开放式情形的渐近分布，令式 (3-15) 中的 $L \to \infty$ 即可得到。

本文主要关注于比较这三类基于模型残差的 CUSUM 统计量的经验水平、经验势和平均检测延迟（即首次报警时间与实际变点之间的时间间隔）。对于这三个 CUSUM 监测统计量，其对应的检验临界值可以取为其渐近分布的 95% 分位数。本文在 5000 个等距格点上模拟标准布朗运动，并进行 10000 次模拟来近似对应渐近分布的分位数。表 3-1 为模拟得到的三个 CUSUM 在线监测方法的临界值。

表 3-1　本节中三种 CUSUM 在线监测方法的临界值表

L	γ	$Q_m(k)$	$P_m(k)$	$E_m(k)$
1	0	1.5706	1.6673	1.7718
	0.25	1.9902	2.0989	2.216
	0.45	2.6837	2.8315	2.8663
2	0	1.8632	1.8999	2.0028
	0.25	2.1417	2.2507	2.379
	0.45	2.7238	2.843	2.9088
3	0	1.9659	1.9912	2.155
	0.25	2.2106	2.2959	2.4412
	0.45	2.7575	2.8529	2.9312
4	0	1.9785	2.0638	2.207
	0.25	2.2465	2.3241	2.4541
	0.45	2.7719	2.8539	2.9641
∞	0	2.2365	2.2599	2.4977
	0.25	2.386	2.4296	2.5975
	0.45	2.7992	2.9241	2.9701

3.3.1 原假设下的模拟结果

本节主要研究在线监测方法在原假设下的有限样本表现，考虑以下 INAR(1) 模型和 INGARCH(1,1) 模型。

(P_1) 泊松 INAR(1) 模型：

$Y_t = \alpha \circ Y_{t-1} + e_t$，其中创新项 $e_t \overset{i.i.d}{\sim} \text{Poisson}(\omega)$，$\omega = 1$，$\alpha = 0.3$。

(P_2) 负二项 INAR(1) 模型：

$Y_t = \alpha \circ Y_{t-1} + e_t$，其中创新项 $e_t \overset{i.i.d}{\sim} \text{NB}(r, p)$，$r = 1$，$p = 0.5$，$\alpha = 0.3$。

(P_3) 与模型(P_2)类似，只是 $r = 5$。

(P_4) 与模型(P_2)类似，只是 $r = 10$。

(P_5) 泊松 INGARCH(1,1) 模型：

$Y_t|\mathcal{F}_{t-1} \sim \text{Poisson}(\lambda_t)$，$\lambda_t = \omega + \alpha\lambda_{t-1} + \beta Y_{t-1}$，其中 $\omega = 1$，$\alpha = 0.3$，$\beta = 0.2$。

(P_6) 负二项 INGARCH(1,1) 模型：

$Y_t|\mathcal{F}_{t-1} \sim \text{NB}(r, p_t)$，$\lambda_t = \frac{r(1-p_t)}{p_t} = \omega + \alpha\lambda_{t-1} + \beta Y_{t-1}$，其中 $r = 1$，$\omega = 1$，$\alpha = 0.3$，$\beta = 0.2$。

(P_7) 与模型(P_6)类似，只是 $r = 5$。

(P_8) 与模型(P_6)类似，只是 $r = 10$。

模型(P_1)-(P_4)为常见的 INAR(1) 模型，(P_5)-(P_8)为常见的 INGARCH(1,1) 模型。本文比较了三种 CUSUM 在线监测方法在封闭式情形和开放式情形下的经验水平。在模拟开放式在线监测方法时，由于模拟实验无法持续进行，因此本文将开放式在线监测方法中的监测周期统一设定为 $L = 10$。

表3-2，3-3和3-4 分别为不同权重函数 $\rho_\gamma(\cdot)$ 下，封闭式 CUSUM 在线监测方法的经验水平。表3-5则展示了开放式在线监测方法的结果。在封闭式情形下，$Q_m(k)$、$P_m(k)$ 和 $E_m(k)$ 表现接近。对于泊松 INAR(1) 模型和泊松 INGARCH(1,1) 模型，PQMLE 与条件极大似然估计几乎等价[21]，三种 CUSUM 方法均表现良好。然而，在负二项 INAR(1) 模型和负二项 INGARCH(1,1) 模型中，三种 CUSUM 方法在 $r = 1$ 的对应模型（P_2，P_6）下表现不佳，可能的原因是 PQMLE 在这两个模型中难以达到完全的渐近效率[65]。从表3-2到表3-4，边界函数中的参数 γ 依次增加。对比发现，过大的 γ 会使得经验水平有所扭曲。

在开放式情形下，本文所采用的 CUSUM 方法的表现和封闭式情形类似。总体而言，当 $\gamma = 0$ 时，三种 CUSUM 在线监测方法在大部分整值时间序列模型下都能有效控制第一类错误率。

表 3-2　$\gamma = 0$ 时，不同封闭式 CUSUM 在线监测方法的经验水平（%）

	m	L	P_1	P_2	P_3	P_4	P_5	P_6	P_7	P_8
$Q_m(k)$	300	1	5.0	5.8	5.7	5.2	6.7	9.5	6.7	5.7
		2	4.3	5.1	4.7	4.7	5.0	8.3	6.9	5.9
		3	5.5	5.8	5.8	5.3	4.6	7.9	6.5	7.5
	600	1	5.1	4.7	5.9	5.7	5.3	7.5	5.6	6.7
		2	4.2	4.5	4.3	4.0	4.3	6.5	5.2	6.1
		3	5.7	5.4	4.3	4.7	4.1	7.1	5.9	4.8
	900	1	5.5	5.5	3.9	5.3	5.1	7.0	5.1	5.7
		2	4.3	5.3	4.6	4.4	4.3	6.3	5.6	5.9
		3	5.1	4.9	5.8	4.5	5.3	7.1	4.7	5.4
$P_m(k)$	300	1	4.6	5.4	5.8	5.4	6.2	9.7	7.0	6.1
		2	4.7	6.5	5.0	5.5	6.2	9.2	7.5	6.7
		3	6.5	5.6	6.2	5.6	5.5	8.9	7.3	8.1
	600	1	5.1	5.1	5.5	5.4	5.3	8.1	5.7	6.5
		2	4.9	5.5	4.8	4.7	4.7	6.7	5.4	6.5
		3	5.9	5.0	4.9	5.1	4.7	7.8	6.5	5.3
	900	1	5.1	4.7	4.5	5.5	4.5	7.3	5.3	5.3
		2	4.7	5.7	4.9	4.7	4.8	7.5	6.1	6.4
		3	5.6	5.1	6.1	5.3	6.1	8.4	5.5	5.8
$E_m(k)$	300	1	4.4	4.9	4.5	4.6	5.9	8.6	6.7	5.5
		2	5.3	6.3	5.3	5.6	5.7	9.6	7.7	6.9
		3	6.2	5.5	5.7	5.5	4.9	8.8	7.1	7.3
	600	1	4.3	4.6	5.2	4.6	5.1	7.5	5.1	6.0
		2	5.0	5.7	5.1	4.8	5.0	7.2	5.9	6.7
		3	5.5	4.8	4.5	5.1	5.2	7.5	6.6	5.5
	900	1	4.5	4.1	3.9	4.8	4.3	6.9	5.4	4.4
		2	4.9	5.7	5.2	5.1	5.2	7.8	6.6	7.1
		3	4.5	4.7	5.3	5.2	5.6	8.4	5.8	6.2

表 3-3　$\gamma = 0.25$ 时，不同封闭式 CUSUM 在线监测方法的经验水平（%）

	m	L	P_1	P_2	P_3	P_4	P_5	P_6	P_7	P_8
$Q_m(k)$	300	1	6.7	6.6	5.5	5.6	5.5	10.5	6.9	7.1
		2	6.0	5.7	6.5	6.4	6.5	11.9	7.8	5.9
		3	5.8	6.1	6.1	4.7	5.7	11.0	5.9	6.5
	600	1	5.0	5.5	5.3	4.7	6.1	9.7	6.9	5.9
		2	5.4	5.8	5.2	5.1	5.7	8.8	5.5	5.3
		3	5.3	5.0	6.2	4.7	5.2	9.3	6.8	4.9
	900	1	4.5	5.9	5.2	5.3	5.4	8.5	6.1	6.1
		2	5.2	6.7	5.6	6.1	6.0	7.9	6.4	6.6
		3	4.2	6.5	5.9	4.9	5.1	7.5	5.1	7.8
$P_m(k)$	300	1	6.7	6.3	5.7	5.3	5.7	11.0	7.1	7.3
		2	5.0	5.7	6.9	6.3	6.5	12.6	7.7	6.3
		3	5.7	6.4	6.2	4.6	5.8	12.1	6.3	6.4
	600	1	5.1	5.9	5.5	5.5	6.1	10.8	6.9	6.2
		2	5.4	5.8	5.1	4.9	5.5	9.1	5.9	5.3
		3	5.5	5.5	5.9	4.8	5.7	9.9	7.2	5.1
	900	1	4.3	6.1	5.7	5.6	5.4	9.7	6.5	6.2
		2	5.1	6.6	5.9	5.7	5.1	8.1	5.9	5.9
		3	4.5	5.8	6.3	4.6	5.6	8.5	5.3	8.0
$E_m(k)$	300	1	6.2	5.5	5.1	4.9	4.8	10.3	6.1	6.9
		2	5.1	6.4	6.7	5.5	5.7	11.7	7.4	5.9
		3	5.8	5.9	6.2	4.8	6.1	11.6	6.3	6.4
	600	1	4.1	5.5	5.3	5.1	5.3	9.6	6.2	5.3
		2	5.0	5.7	4.5	4.7	5.3	8.9	5.8	4.7
		3	5.4	4.7	5.7	4.7	5.5	9.6	6.1	5.1
	900	1	3.9	5.5	5.0	4.8	5.3	8.6	6.0	5.6
		2	5.3	6.3	4.9	5.3	4.6	7.7	6.1	5.9
		3	4.9	5.2	5.5	4.7	4.9	8.2	5.3	7.5

表 3-4　$\gamma = 0.45$ 时，不同封闭式 CUSUM 在线监测方法的经验水平（%）

	m	L	P_1	P_2	P_3	P_4	P_5	P_6	P_7	P_8
$Q_m(k)$	300	1	5.6	7.7	4.7	5.9	6.1	12.9	9.5	6.9
		2	6.3	7.6	6.2	5.8	7.1	15.7	9.7	7.5
		3	4.7	7.2	5.5	5.3	5.7	12.3	8.9	6.3
	600	1	6.5	7.7	4.9	5.7	6.7	11.9	8.4	8.9
		2	6.9	7.3	6.2	4.9	5.6	12.6	9.0	6.3
		3	6.5	7.3	5.6	6.1	5.3	14.1	8.1	7.3
	900	1	6.0	8.1	5.9	5.2	5.6	11.1	8.3	7.6
		2	5.9	7.0	5.8	5.7	5.0	13.0	6.9	8.3
		3	6.5	7.5	5.5	4.9	6.1	12.7	7.5	7.3
$P_m(k)$	300	1	5.7	8.4	4.0	5.1	5.6	15.0	9.3	6.9
		2	6.4	8.1	5.9	5.6	6.5	17.3	10.7	7.9
		3	5.1	8.3	5.0	5.7	5.8	14.1	9.5	6.8
	600	1	5.9	7.6	4.7	5.2	7.5	13.4	9.5	8.5
		2	5.7	7.4	5.7	4.9	6.3	14.3	9.0	6.9
		3	6.3	8.5	5.7	6.6	5.5	15.9	9.1	8.4
	900	1	6.1	7.7	5.9	4.7	5.8	12.9	8.6	7.2
		2	5.7	6.5	5.5	5.9	5.6	15.3	7.5	8.1
		3	7.0	7.5	5.9	5.2	6.5	14.9	8.9	7.6
$E_m(k)$	300	1	5.7	8.3	4.3	5.2	6.1	15.7	9.4	6.6
		2	6.1	8.1	5.9	5.7	6.3	17.6	10.8	7.8
		3	5.5	7.7	5.3	5.5	5.9	13.9	9.5	6.4
	600	1	6.0	7.9	5.2	5.3	7.9	13.5	9.5	8.7
		2	5.8	6.9	5.7	5.1	6.5	14.2	8.3	7.0
		3	6.2	8.5	5.5	6.8	5.8	15.7	8.8	7.9
	900	1	5.9	8.1	6.3	5.3	5.9	13.3	8.8	7.3
		2	5.8	7.1	5.5	6.2	5.9	14.6	7.9	8.1
		3	6.6	7.3	5.8	5.1	6.5	14.7	8.7	7.4

表 3-5　不同开放式 CUSUM 在线监测方法的经验水平（%）

γ		m	P_1	P_2	P_3	P_4	P_5	P_6	P_7	P_8
0	$Q_m(k)$	300	4.4	5.4	4.2	4.9	3.8	8.8	6.4	5.3
		600	3.1	5.1	4.5	4.4	4.5	6.8	5.1	5.6
		900	4.4	4.9	4.3	4.4	4.2	6.0	4.9	4.9
	$P_m(k)$	300	4.5	5.2	4.4	5.1	4.1	9.7	6.5	5.8
		600	3.2	5.2	4.6	4.6	4.7	7.5	5.2	5.8
		900	4.5	4.7	4.4	4.5	4.3	6.3	5.2	5.3
	$E_m(k)$	300	4.0	4.7	3.4	4.6	3.6	8.7	5.5	5.3
		600	3.6	4.1	4.1	4.3	3.9	6.7	4.3	5.1
		900	4.2	4.1	3.9	3.7	3.6	5.6	5.0	4.8
0.25	$Q_m(k)$	300	4.9	6.3	5.1	4.6	5.3	8.7	6.6	6.1
		600	5.1	5.2	4.9	5.3	3.9	8.0	5.4	5.0
		900	3.9	4.8	4.4	5.0	5.6	6.9	4.9	4.1
	$P_m(k)$	300	4.9	6.6	5.3	5.1	5.5	10.2	7.3	6.6
		600	5.7	5.3	4.9	5.0	4.1	9.4	6.3	5.1
		900	4.1	4.9	4.3	5.1	6.1	7.5	5.2	4.8
	$E_m(k)$	300	4.6	6.1	5.0	5.0	5.6	10.5	7.3	5.9
		600	5.9	5.2	4.4	4.9	4.1	8.9	6.3	4.9
		900	3.4	5.2	4.6	4.9	4.8	6.7	4.5	4.9
0.45	$Q_m(k)$	300	5.1	7.7	5.7	6.5	6.1	13.7	8.1	7.7
		600	5.0	7.2	5.5	5.5	5.7	13.1	9.0	7.3
		900	5.3	6.4	5.9	5.7	4.8	11.8	8.2	7.1
	$P_m(k)$	300	4.7	7.3	5.8	6.1	5.4	14.7	8.3	7.8
		600	4.9	6.9	4.9	4.9	5.5	14.7	8.9	7.5
		900	4.7	6.5	5.5	5.3	4.6	12.9	8.9	6.9
	$E_m(k)$	300	5.5	8.0	6.2	6.3	5.9	15.6	9.4	8.8
		600	5.4	7.6	5.0	5.6	5.8	15.3	10.0	8.1
		900	5.3	6.9	6.3	5.2	5.5	13.1	9.4	7.5

3.3.2 备择假设下的模拟结果

本节将研究所采用的修正 CUSUM 在线监测方法 $E_m(k)$ 和两个对比方法在备择假设下的有限样本表现，重点比较它们的经验势和平均检测延迟。在 INAR(1) 模型中，条件均值由参数 $\theta = (\omega, \alpha)^\top$ 唯一确定：$\lambda_t = \alpha Y_{t-1} + \omega$，$\omega = E(e_t)$。本文分别考虑了仅参数 ω 变化和仅参数 α 变化的情形。对于 INGARCH(1,1) 模型，参数 $\theta = (\omega, \alpha, \beta)^\top$ 唯一确定其条件均值：$\lambda_t = \omega + \alpha\lambda_{t-1} + \beta Y_{t-1}$，本文分别研究了三个参数 ω, α, β 单独变化的情形。假设变点位置为 $m + k^*$，其中训练样本量为 $m = 300$。对于封闭式情形，令 $L = 3$，并对三个 CUSUM 方法在早期变点和靠后变点下进行比较。具体来说，早期变点对应 $k^* = 0.3 * Lm = 270$，靠后变点对应 $k^* = 0.7 * Lm = 630$。在开放式情形下，本文于 $k = 3000$ 处（$L = 10$）停止模拟，变点位置为 $m + k^* = 1800$。边界函数中的参数为 $\gamma = 0$。本文考虑了以下模型：

(S_1) 泊松 INAR(1) 模型，仅 $\omega = E(e_t)$ 变化。

$Y_t = 0.3 \circ Y_{t-1} + e_t$，创新项 $e_t = \eta_t \mathbf{I}_{\{t \le m+k^*\}} + \eta_t^* \mathbf{I}_{\{t > m+k^*\}}$，其中 $\eta_t \sim \text{Poisson}(1)$，$\eta_t^* \sim \text{Poisson}(1+\delta)$，$\delta \ge 0$。

(S_2) 泊松 INAR(1) 模型，仅 α 变化。

$Y_t = (0.3 + \delta \mathbf{I}_{\{t > m+k^*\}}) \circ Y_{t-1} + e_t$，$0 \le \delta < 0.7$，创新项 $e_t \sim \text{Poisson}(1)$。

(S_3) 负二项 INAR(1) 模型，仅 $\omega = E(e_t)$ 变化。

$Y_t = 0.3 \circ Y_{t-1} + e_t$，创新项 $e_t = \eta_t \mathbf{I}_{\{t \le m+k^*\}} + \eta_t^* \mathbf{I}_{\{t > m+k^*\}}$，其中 $\eta_t \sim \text{NB}(1, 0.5)$，$\eta_t^* \sim \text{NB}(1+\delta, 0.5)$，$\delta \ge 0$。也就是说，$E(e_t)$ 由 1 变为 $1+\delta$。

(S_4) 负二项 INAR(1) 模型，仅 α 变化。

$Y_t = (0.3 + \delta \mathbf{I}_{\{t > m+k^*\}}) \circ Y_{t-1} + e_t$，$0 \le \delta < 0.7$，创新项 $e_t \sim \text{NB}(1, 0.5)$。

(S_5) 泊松 INGARCH(1,1) 模型，仅 ω 变化。

$Y_t | \mathcal{F}_{t-1} \sim \text{Poisson}(\lambda_t)$，$\lambda_t = (\omega + \delta \mathbf{I}_{\{t > m+k^*\}}) + 0.3\lambda_{t-1} + 0.2Y_{t-1}$，$\delta \ge 0$。

(S_6) 泊松 INGARCH(1,1) 模型，仅 α 变化。

$Y_t | \mathcal{F}_{t-1} \sim \text{Poisson}(\lambda_t)$，$\lambda_t = \omega + (0.3 + \delta \mathbf{I}_{\{t > m+k^*\}})\lambda_{t-1} + 0.2Y_{t-1}$，$0 \le \delta < 0.5$。

(S_7) 泊松 INGARCH(1,1) 模型，仅 β 变化。

$Y_t | \mathcal{F}_{t-1} \sim \text{Poisson}(\lambda_t)$，$\lambda_t = \omega + 0.3\lambda_{t-1} + (0.2 + \delta \mathbf{I}_{\{t > m+k^*\}})Y_{t-1}$，$0 \le \delta < 0.5$。

(S_8) 负二项 INGARCH(1,1) 模型，仅 ω 变化。

$Y_t | \mathcal{F}_{t-1} \sim \text{NB}(10, p_t)$，$\lambda_t = \frac{r(1-p_t)}{p_t} = (\omega + \delta \mathbf{I}_{\{t > m+k^*\}}) + 0.3\lambda_{t-1} + 0.2Y_{t-1}$，$\delta \ge 0$。

(S_9) 负二项 INGARCH(1,1) 模型，仅 α 变化。

$Y_t | \mathcal{F}_{t-1} \sim \text{NB}(10, p_t)$，$\lambda_t \omega + (0.3 + \delta \mathbf{I}_{\{t > m+k^*\}})\lambda_{t-1} + 0.2Y_{t-1}$，$0 \le \delta < 0.5$。

(S_{10}) 负二项 INGARCH(1,1) 模型，仅 β 变化。

$Y_t | \mathcal{F}_{t-1} \sim \text{NB}(10, p_t)$，$\lambda_t = \omega + 0.3\lambda_{t-1} + (0.2 + \delta \mathbf{I}_{\{t > m+k^*\}})Y_{t-1}$，$0 \le \delta < 0.5$。

在下方所有图中，左列展示了三种 CUSUM 在线监测方法在不同模型下的平均检测延迟，右列则为相应的经验势。图3-1和3-2 展示了封闭式在线监测方法在早期变点下的表现，此时，三种 CUSUM 方法的表现较为接近。图3-3和3-4 展示了封闭式在线监测方法在靠后变点下的平均检测延迟和经验势，其中本文所采用的方法 $E_m(k)$ 的经验势略优于对比方法 $P_m(k)$，显著优于 $Q_m(k)$。图3-5和3-6为开放式在线监测方法的表现，本文所采用的方法 $E_m(k)$ 的经验势和平均检测延迟都优于对比方法。总体而言，三种 CUSUM 监测统计量在检测早期变点时表现相似。当变点位置靠后时，$E_m(k)$ 的表现则优于其他统计量。

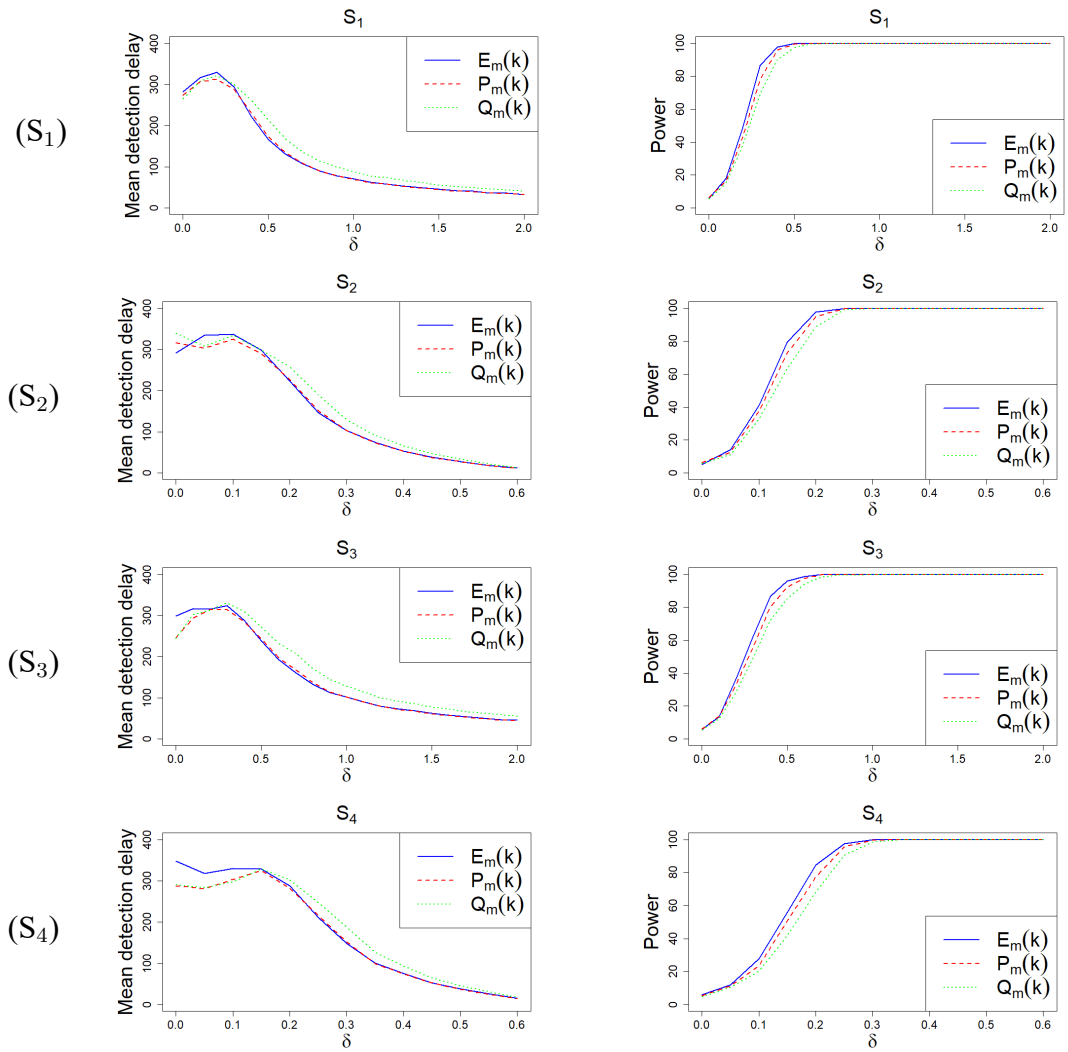

图 3-1　INAR(1) 模型参数变化时，不同封闭式 CUSUM 在线监测方法在早期变点（$k^* = 270$）下的平均检测延迟和经验势（%）

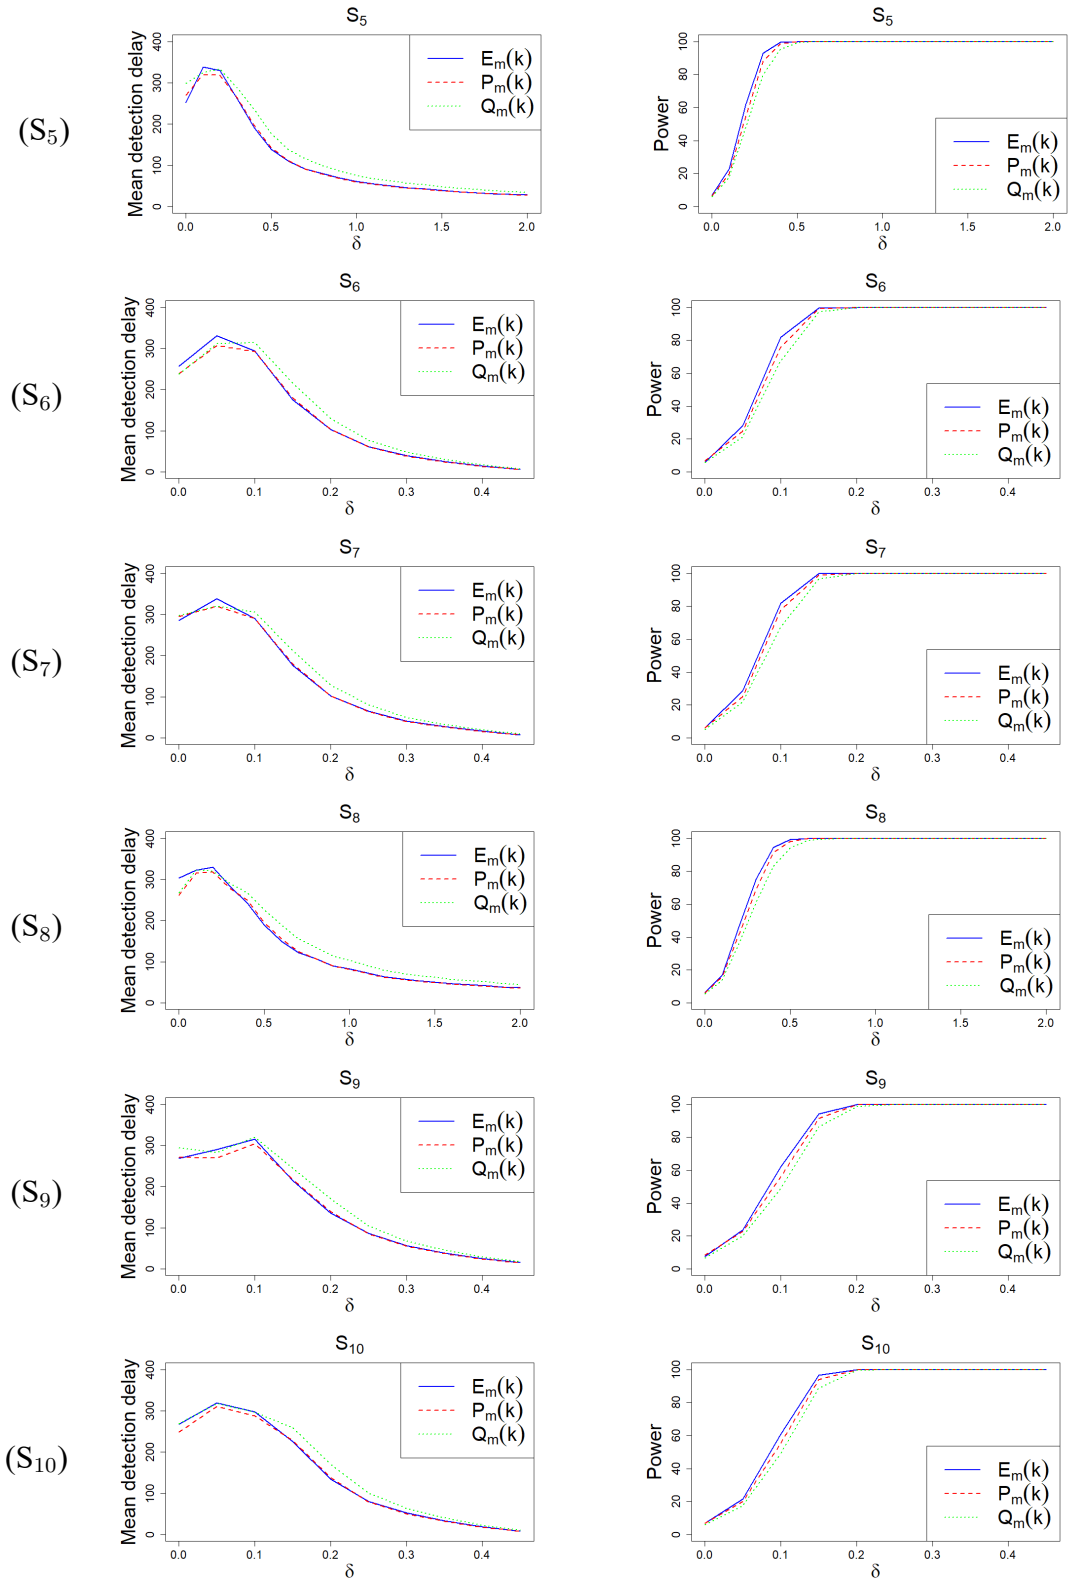

图 3-2　INGARCH(1,1) 模型参数变化时，不同封闭式 CUSUM 在线监测方法在早期变点（$k^* = 270$）下的平均检测延迟和经验势（%）

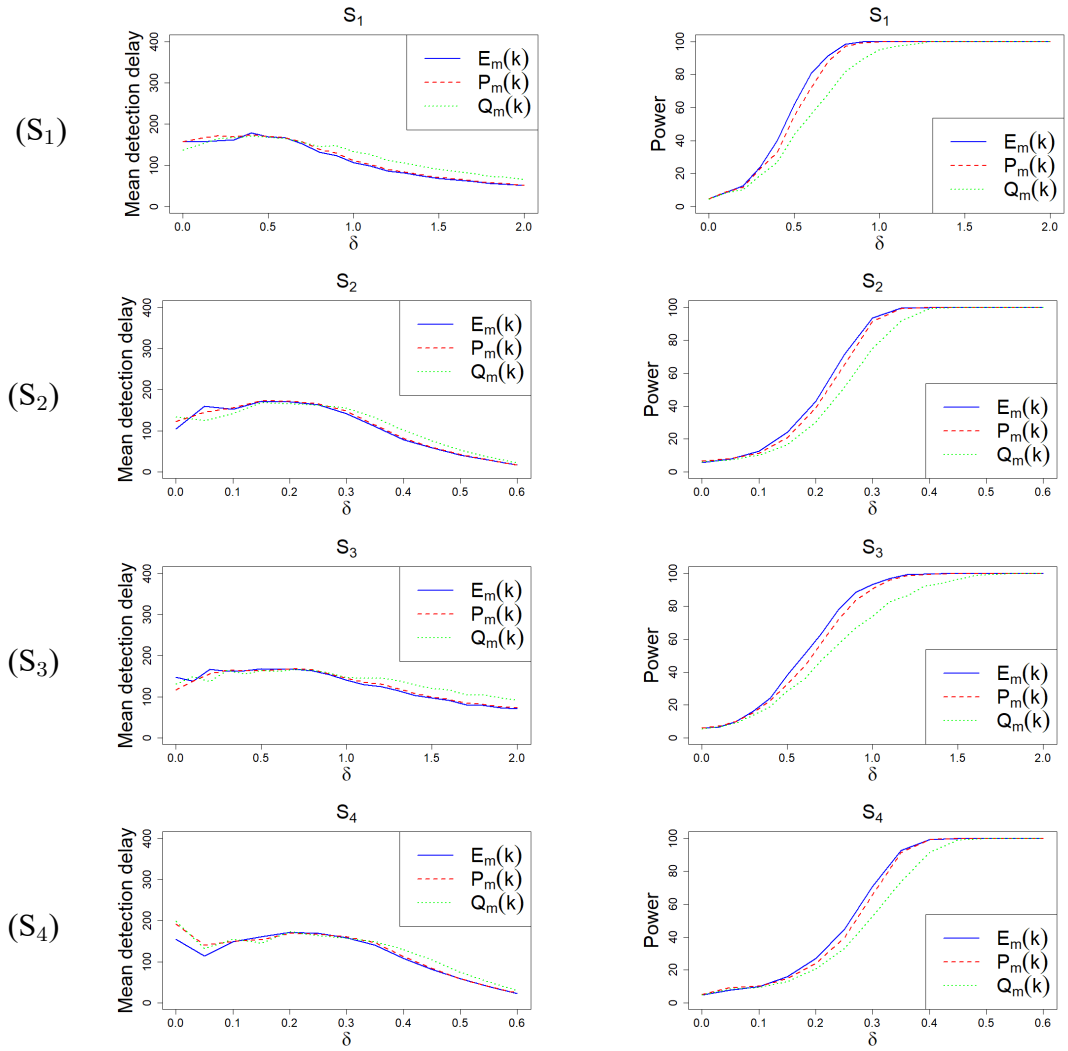

图 3-3　INAR(1) 模型参数变化时，不同封闭式 CUSUM 在线监测方法在靠后变点（$k^* = 630$）下的平均检测延迟和经验势（%）

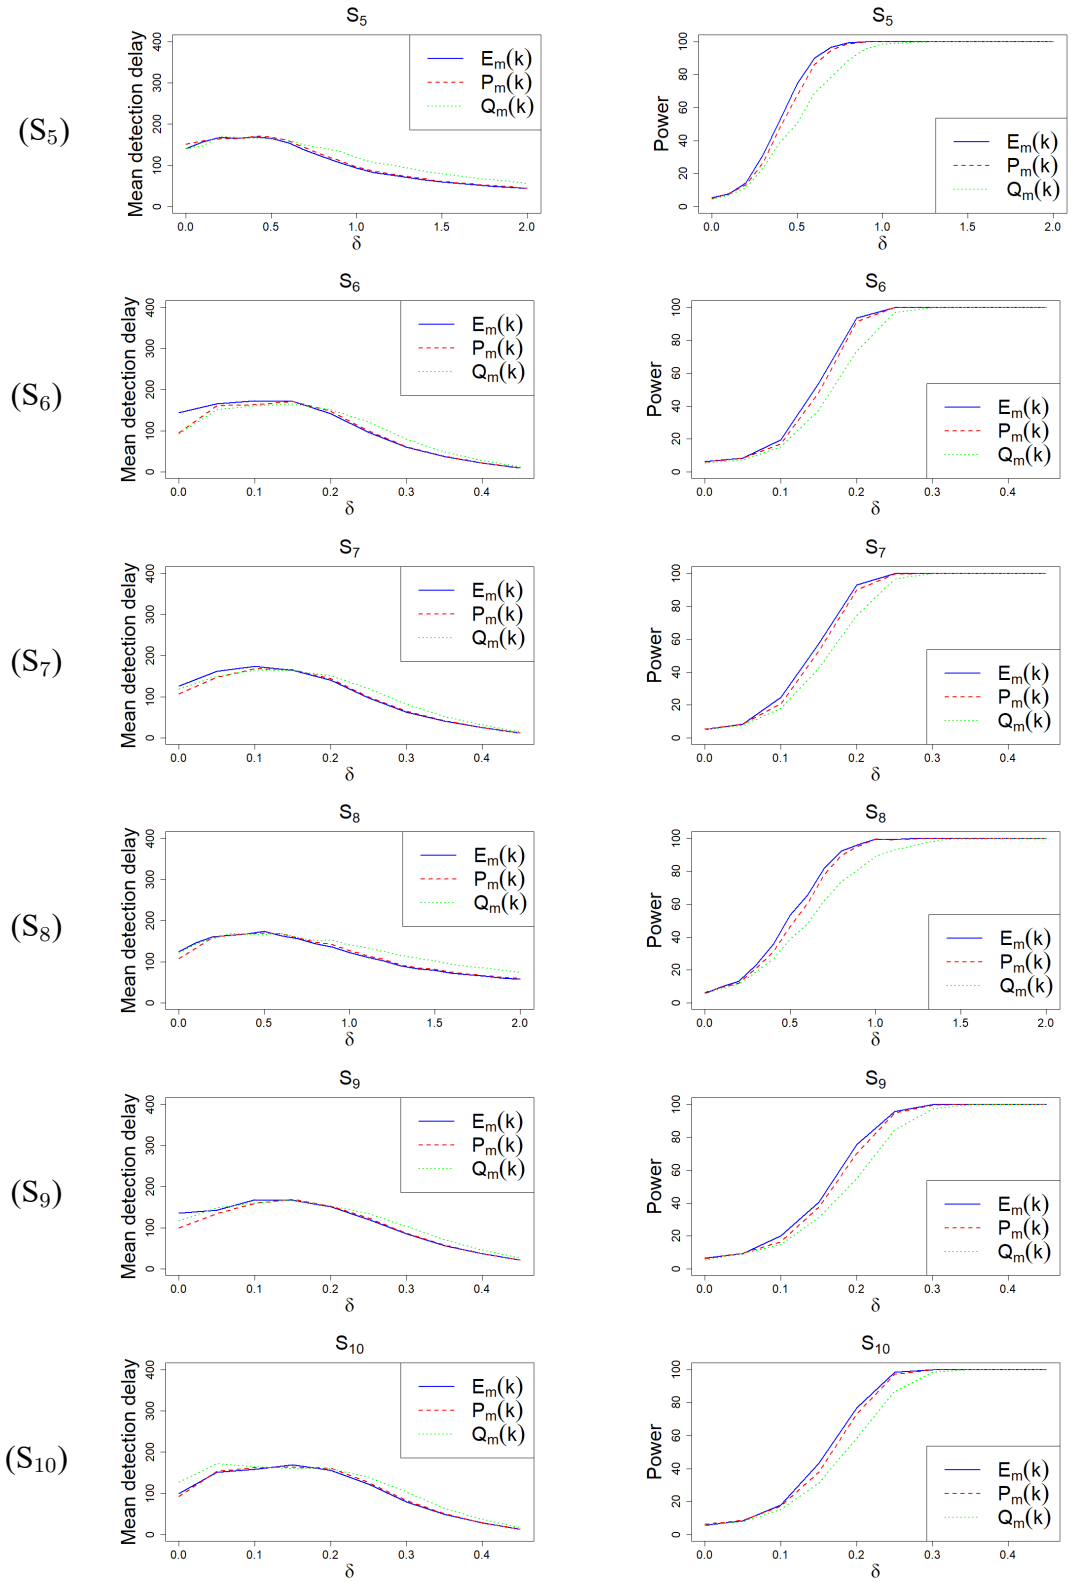

图 3-4　INGARCH(1,1) 模型参数变化时，不同封闭式 CUSUM 在线监测方法在靠后变点（$k^* = 630$）下的平均检测延迟和经验势（%）

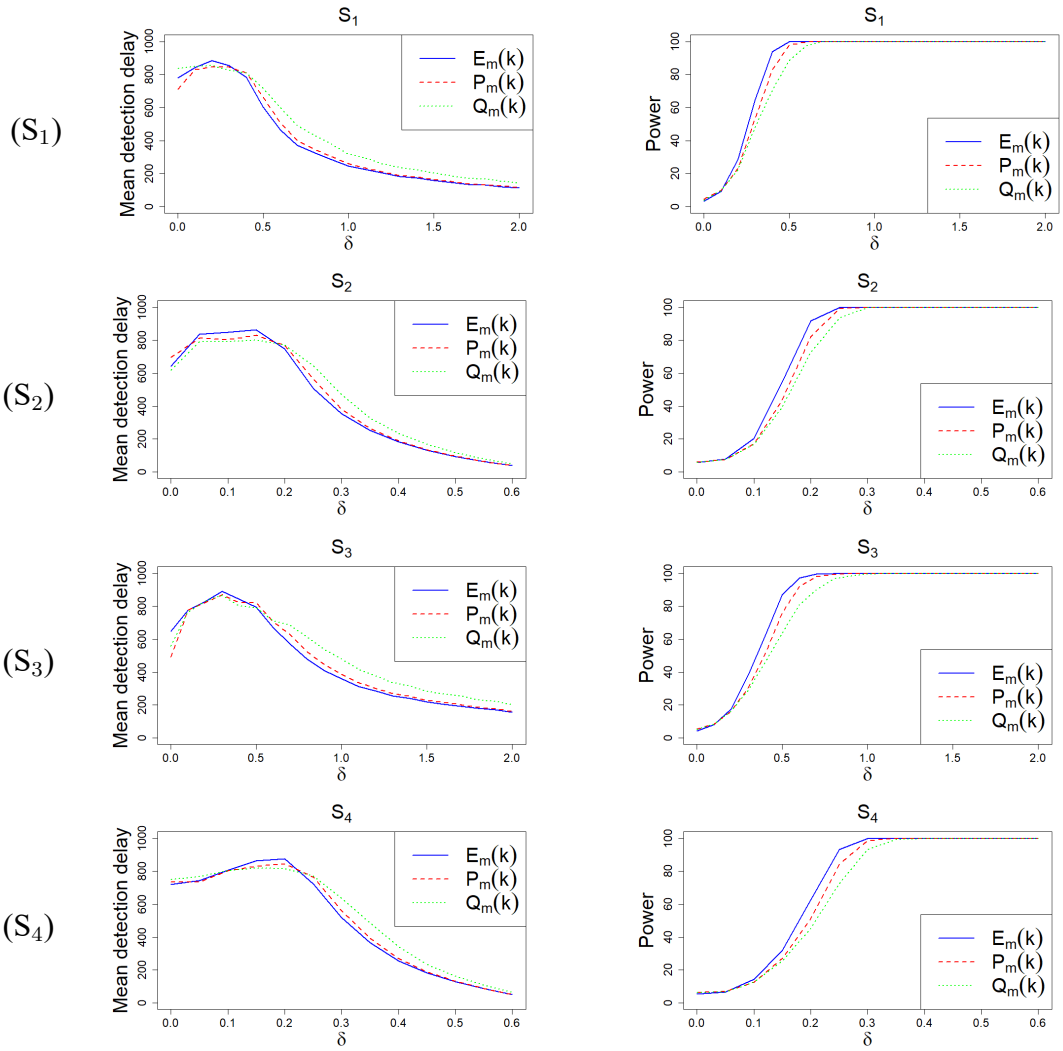

图 3-5　INAR(1) 模型参数变化时，不同开放式 CUSUM 在线监测方法的平均检测延迟和经验势（%）

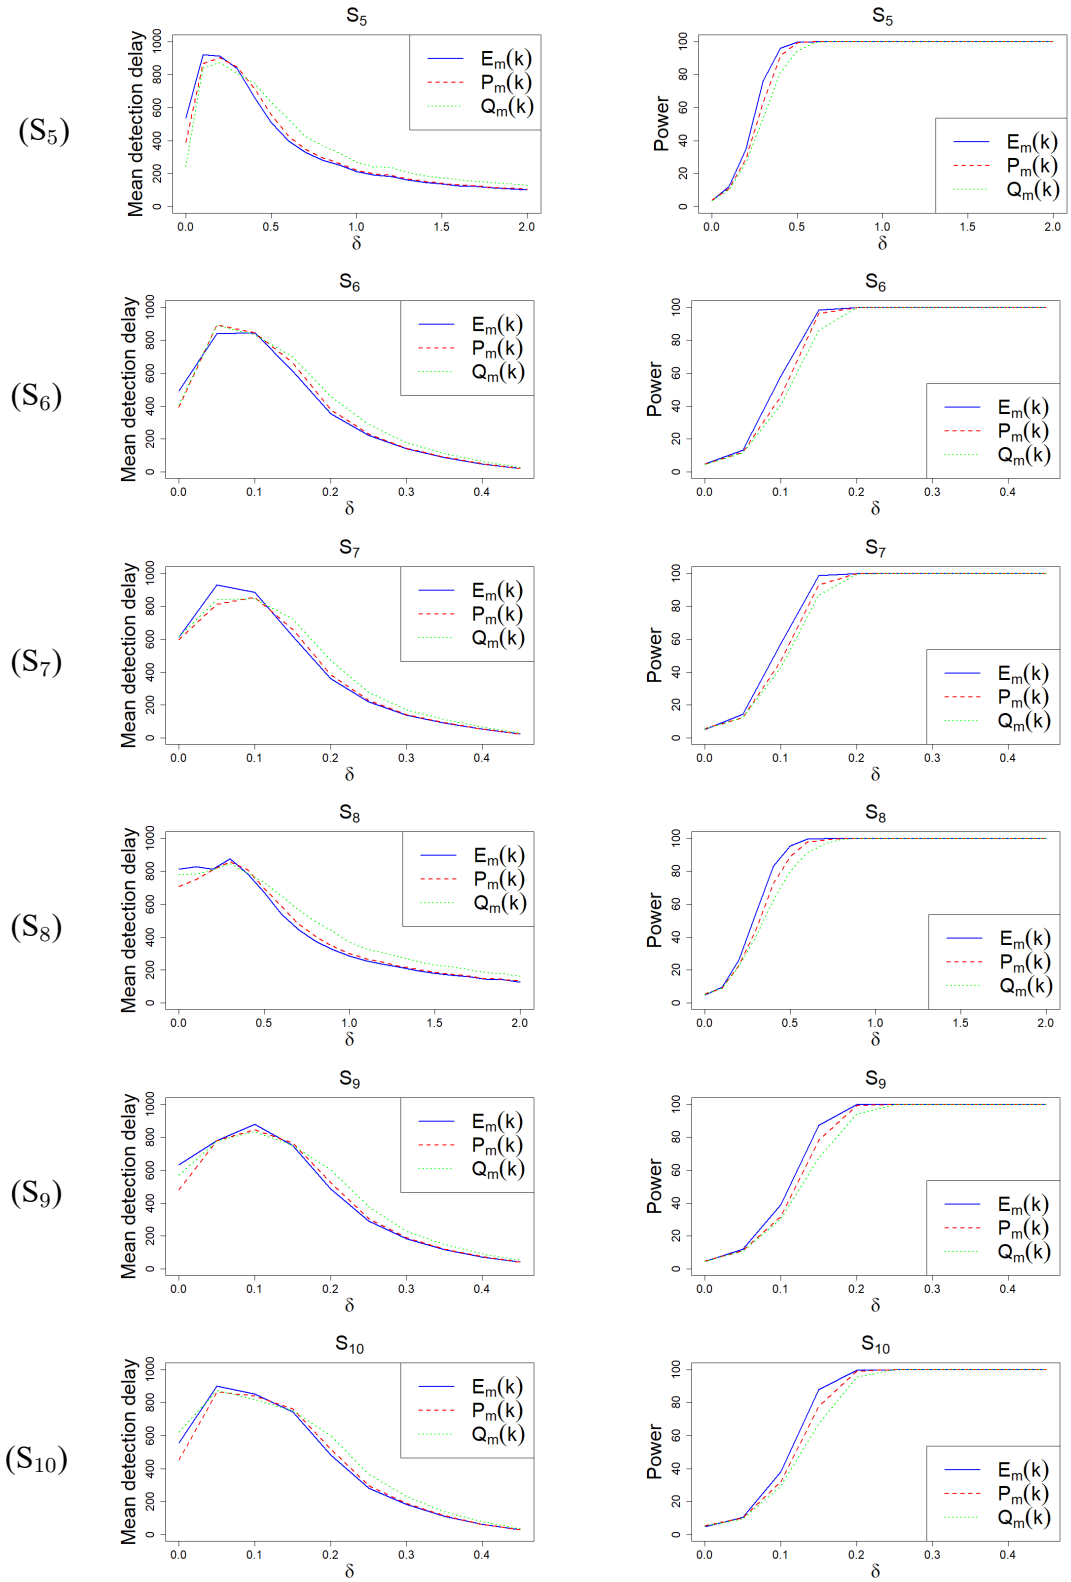

图 3-6　INGARCH(1,1) 模型参数变化时，不同开放式 CUSUM 在线监测方法的平均检测延迟和经验势（%）

3.4 本章定理证明

这一节为本章主要定理的证明。第3.2节中的定理3.1和定理3.2的证明与 Gösmann 等人[24] 的证明路线基本相同。首先引入以下记号：

$$E_m(k) = \max_{j=0}^{k-1}(\hat{\sigma}_m^2)^{-1/2}\frac{k-j}{\sqrt{m}}\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t - \frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right|, \tag{3-16}$$

$$\widetilde{E}_m(k) = \max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}\sigma}\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t - \frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right|, \tag{3-17}$$

$$E_m^*(k) = \max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}\sigma}\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\epsilon_t - \frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\epsilon_t\right|, \tag{3-18}$$

其中 $\epsilon_t = Y_t - \lambda_t(\theta_0)$ 为真实参数下的残差序列，其方差为 σ^2，$\sigma > 0$。$\hat{\sigma}_m^2 = \frac{1}{m}\sum_{t=1}^m \hat{\epsilon}_t^2$ 为模型残差的方差估计。相较于 $E_m(k)$，$\widetilde{E}_m(k)$ 用真实方差替换了相应的估计量，$E_m^*(k)$ 进一步将参数估计下的残差序列 $\{\hat{\epsilon}_t\}$ 替换为真实参数下的残差序列 $\{\epsilon_t\}$。

在整个证明过程中，以下条件经常使用：由假设3.2，边界函数 $\rho(\cdot)$ 为正连续函数，且有着一致的上界 U。另外，在开放式（$L = \infty$）情形下，$\limsup_{t\to\infty} t\rho(t) < \infty$。首先证明定理3.1，从几个必要的引理开始。在以下每个引理中，都假设定理3.1的所有假设成立。

引理 3.1 当 $m \to \infty$ 时，

$$\sup_{k=1}^{\infty}\rho\left(k/m\right)\left|\widetilde{E}_m(k) - E_m^*(k)\right| = o_P(1).$$

证明 前文中，余项定义为 $R_{i,j} = \frac{1}{j-i+1}\sum_{t=i}^j(\hat{\epsilon}_t - \epsilon_t)$。与 Gösmann 等人[24] 的证明思路类似，首先由逆三角不等式可得：

$$\begin{aligned}
&\left|\widetilde{E}_m(k) - E_m^*(k)\right| \\
&\le \frac{1}{\sqrt{m}\sigma}\max_{j=0}^{k-1}(k-j)\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t - \frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t - \frac{1}{m+j}\sum_{t=1}^{m+j}\epsilon_t + \frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\epsilon_t\right| \\
&= \frac{1}{\sqrt{m}\sigma}\max_{j=0}^{k-1}(k-j)\left|R_{1,m+j} - R_{m+j+1,m+k}\right|,
\end{aligned}$$

$$
\begin{aligned}
&\sup_{k=1}^{\infty}\frac{\rho(k/m)}{\sqrt{m}\sigma}\max_{j=0}^{k-1}(k-j)\left|R_{m+j+1,m+k}\right| \\
=&\sup_{k=1}^{\infty}\frac{\rho(k/m)\sqrt{m+k}}{\sqrt{m}\sigma}\max_{j=0}^{k-1}\frac{k-j}{\sqrt{m+k}}\left|R_{m+j+1,m+k}\right| \\
\le&\sup_{k=1}^{\infty}\frac{\rho(k/m)\sqrt{m+k}}{\sqrt{m}\sigma}\sup_{k=1}^{\infty}\max_{1\le i<j\le m+k}\frac{j-i+1}{\sqrt{m+k}}\left|R_{i,j}\right|.
\end{aligned}
\tag{3-19}
$$

类似于式 (3-19)，可得

$$
\begin{aligned}
&\sup_{k=1}^{\infty}\frac{\rho(k/m)}{\sqrt{m}\sigma}\max_{j=0}^{k-1}(k-j)\left|R_{1,m+j}\right| \\
\le&\sup_{k=1}^{\infty}\frac{\rho(k/m)(m+k)}{m}\sqrt{m}\sup_{k=1}^{\infty}\max_{j=0}^{k-1}\frac{1}{\sigma}\left|R_{1,m+j}\right| \\
=&\sup_{k=1}^{\infty}\frac{\rho(k/m)(m+k)}{m}\sup_{k=0}^{\infty}\frac{\sqrt{m}}{\sigma}\left|R_{i,j}\right|.
\end{aligned}
\tag{3-20}
$$

由假设3.2中对边界函数 $\rho(\cdot)$ 的条件可得

$$
\sup_{k=1}^{\infty}\frac{\rho(k/m)(m+k)}{m}=\sup_{k=1}^{\infty}\rho(k/m)(1+k/m)\le\sup_{t\ge0}\rho(t)(1+t)<\infty. \tag{3-21}
$$

类似可得

$$
\sup_{k=1}^{\infty}\frac{\rho(k/m)\sqrt{m+k}}{\sqrt{m}}<\infty.
$$

另外，由假设3.3可知

$$
\begin{aligned}
&\sup_{k=1}^{\infty}\sqrt{m}\left|R_{1,m+k}\right| \\
&\le\sup_{k=1}^{\infty}\sqrt{m+k}\left|R_{1,m+k}\right| \\
&=\sup_{k=m}^{\infty}\sqrt{k}\left|R_{1,k}\right| \\
&\overset{j=k,i=1}{\le}\sup_{k=m}^{\infty}\max_{1\le i<j\le k}\frac{j-i+1}{\sqrt{k}}\left|R_{i,j}\right| \\
&=o(1)
\end{aligned}
$$

以概率 1 成立。

结合以上结论，随机可得引理3.1成立。 □

接下来的引理表明 $E_m^*(k)$ 可以由标准布朗运动进行近似。

引理 3.2 定义

$$
B_m(k)=\frac{1}{\sqrt{m}}\max_{j=0}^{k-1}\left|W_{m,1}(k)-\frac{m+k}{m+j}W_{m,1}(j)-\frac{k-j}{m+j}W_{m,2}(m)\right|,
$$

其中 $W_{m,1}(\cdot)$ 和 $W_{m,2}(\cdot)$ 是在假设3.1中定义的两个独立的标准布朗运动。

当 $m \to \infty$ 时，

$$\sup_{k=1}^{\infty} \rho\left(k/m\right) \left|E_m^*(k) - B_m(k)\right| = o_P(1).$$

证明 首先，对 $E_m^*(k)$ 进行简单变换：

$$\begin{aligned}
E_m^*(k) &= \max_{j=0}^{k-1} \frac{k-j}{\sqrt{m}\sigma} \left| \frac{1}{m+j} \sum_{t=1}^{m+j} \epsilon_t - \frac{1}{k-j} \sum_{t=m+j+1}^{m+k} \epsilon_t \right| \\
&= \max_{j=0}^{k-1} \frac{1}{\sqrt{m}\sigma} \left| \frac{k-j}{m+j} \left(\sum_{t=1}^{m} \epsilon_t + \sum_{t=m+1}^{m+j} \epsilon_t \right) - \left(\sum_{t=m+1}^{m+k} \epsilon_t - \sum_{t=m+1}^{m+j} \epsilon_t \right) \right| \\
&= \max_{j=0}^{k-1} \frac{1}{\sqrt{m}\sigma} \left| \sum_{t=m+1}^{m+k} \epsilon_t - \frac{m+k}{m+j} \sum_{t=m+1}^{m+j} \epsilon_t - \frac{k-j}{m+j} \sum_{t=1}^{m} \epsilon_t \right|.
\end{aligned} \tag{3-22}$$

由逆三角不等式可得

$$\begin{aligned}
&\left|E_m^*(k) - B_m(k)\right| \\
=&\left| \max_{j=0}^{k-1} \frac{1}{\sqrt{m}\sigma} \left| \sum_{t=m+1}^{m+k} \epsilon_t - \frac{m+k}{m+j} \sum_{t=m+1}^{m+j} \epsilon_t - \frac{k-j}{m+j} \sum_{t=1}^{m} \epsilon_t \right| \right. \\
&\left. - \frac{1}{\sqrt{m}} \max_{j=0}^{k-1} \left| W_{m,1}(k) - \frac{m+k}{m+j} W_{m,1}(j) - \frac{k-j}{m+j} W_{m,2}(m) \right| \right| \\
\le& \frac{1}{\sqrt{m}\sigma} \max_{j=0}^{k-1} \left| \left(\sum_{t=m+1}^{m+k} \epsilon_t - \frac{m+k}{m+j} \sum_{t=m+1}^{m+j} \epsilon_t - \frac{k-j}{m+j} \sum_{t=1}^{m} \epsilon_t \right) \right. \\
&\left. - \left(\sigma W_{m,1}(k) - \frac{m+k}{m+j} \sigma W_{m,1}(j) - \frac{k-j}{m+j} \sigma W_{m,2}(m) \right) \right| \\
\le& \frac{1}{\sqrt{m}\sigma} \left| \sum_{t=m+1}^{m+k} \epsilon_t - \sigma W_{m,1}(k) \right| + \frac{1}{\sqrt{m}\sigma} \max_{j=0}^{k-1} \frac{m+k}{m+j} \left| \sum_{t=m+1}^{m+j} \epsilon_t - \sigma W_{m,1}(j) \right| \\
&+ \frac{1}{\sqrt{m}\sigma} \max_{j=0}^{k-1} \frac{k-j}{m+j} \left| \sum_{t=1}^{m} \epsilon_t - \sigma W_{m,2}(m) \right| \\
=& A_1 + A_2 + A_3.
\end{aligned}$$

接下来将分别处理最后一个不等式的三个子式。对第一个式子 A_1，

$$\begin{aligned}
&\sup_{k=1}^{\infty} \frac{\rho\left(k/m\right)}{\sqrt{m}\sigma} \left| \sum_{t=m+1}^{m+k} \epsilon_t - \sigma W_{m,1}(k) \right| \\
\le& \sup_{k=1}^{\infty} \frac{\rho\left(k/m\right) k^{\xi}}{\sqrt{m}\sigma} \sup_{k=1}^{\infty} \frac{1}{k^{\xi}} \left| \sum_{t=m+1}^{m+k} \epsilon_t - \sigma W_{m,1}(k) \right|,
\end{aligned}$$

其中 $0 < \xi < \frac{1}{2}$。对第一项，由于边界函数 $\rho(\cdot)$ 存在上界 U，那么

$$\sup_{k=1}^{m} \frac{w(k/m) k^{\xi}}{\sqrt{m}} \le \sup_{k=1} \frac{U k^{\xi}}{\sqrt{m}} = U m^{\xi - 1/2} = o(1).$$

另外，由假设3.1可知 $\sup_{k=1}^{\infty}\frac{1}{k^{\xi}}\left|\sum_{t=m+1}^{m+k}\epsilon_t-\sigma W_{m,1}(k)\right|=O_P(1)$。于是

$$\sup_{k=1}^{\infty}\frac{\rho\left(k/m\right)}{\sqrt{m}\sigma}|\sum_{t=m+1}^{m+k}\epsilon_t-\sigma W_{m,1}(k)|=o_P(1).$$

对于另外两项，可按照类似的放缩得到以下结果：

$$\sup_{k=1}^{\infty}\frac{\rho\left(k/m\right)}{\sqrt{m}\sigma}\max_{j=0}^{k-1}\frac{m+k}{m+j}\left|\sum_{t=m+1}^{m+j}\epsilon_t-\sigma W_{m,1}(j)\right|=o_P(1),$$

$$\sup_{k=1}^{\infty}\frac{\rho\left(k/m\right)}{\sqrt{m}\sigma}\max_{j=0}^{k-1}\frac{k-j}{m+j}\left|\sum_{t=1}^{m}\epsilon_t-\sigma W_{m,2}(m)\right|=o_P(1).$$

具体步骤可参见 Gösmann 等人[24] 的引理 A2 的证明。基于上述结果，随即可得引理3.2成立。

□

引理 3.3 当 $m\to\infty$ 时，以下弱收敛结果成立：

$$\sup_{k=1}^{\infty}\rho(k/m)B_m(k)\Longrightarrow\sup_{0\le t<\infty}\max_{0\le s\le t}\rho(t)\left|W_1(t)-\frac{1+t}{1+s}W_1(s)+\frac{t-s}{1+s}W_2(1)\right|,$$

其中 $W_{m,1}(\cdot)$ 和 $W_{m,2}(\cdot)$ 为两个独立的标准布朗运动。

证明 参见 Gösmann 等人[24] 的辅助材料中引理 A3 的证明过程。 □

结合引理3.1-3.1，可知当 $m\to\infty$ 时，以下弱收敛结果成立：

$$\sup_{k=1}^{\infty}\rho(k/m)\widetilde{E}_m(k)\Longrightarrow\sup_{0\le t<\infty}\max_{0\le s\le t}\rho(t)\left|W_1(t)-\frac{1+t}{1+s}W_1(s)+\frac{t-s}{1+s}W_2(1)\right|,$$

其中

$$\widetilde{E}_m(k)=\max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}\sigma}\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right|.$$

为得到 $E_m(k)$ 的渐近分布，还需研究方差估计量的影响。

引理 3.4 当 $m\to\infty$ 时，

$$\sup_{k=1}^{\infty}\rho(k/m)\widetilde{E}_m(k)-\sup_{k=1}^{\infty}\rho(k/m)E_m(k)=o_P(1).$$

证明

$$
\begin{aligned}
&\left|\sup_{k=1}^{\infty}\rho(k/m)\widetilde{E}_m(k)-\sup_{k=1}^{\infty}\rho(k/m)E_m(k)\right| \\
=&\left|\sup_{k=1}^{\infty}\rho(k/m)\left(\max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}\sigma}\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right|\right)\right. \\
&\left.-\sup_{k=1}^{\infty}\rho(k/m)\left(\max_{j=0}^{k-1}(\hat{\sigma}_m^2)^{-1/2}\frac{k-j}{\sqrt{m}}\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right|\right)\right| \\
\le&\sup_{k=1}^{\infty}\rho(k/m)\max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}}\left|\left((\hat{\sigma}_m^2)^{-1/2}-(\sigma^2)^{-1/2}\right)\left(\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right)\right| \\
\le&\left|(\hat{\sigma}_m^2)^{-1/2}-(\sigma^2)^{-1/2}\right|\sup_{k=1}^{\infty}\rho(k/m)\max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}}\left|\left(\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right)\right|.
\end{aligned}
$$

由于 $\hat{\sigma}_m^2$ 是 σ^2 的相合估计，结合连续映射定理可得 $\left|(\hat{\sigma}_m^2)^{-1/2}-(\sigma^2)^{-1/2}\right|=o_P(1)$。另外，

$$
\begin{aligned}
&\sup_{k=1}^{\infty}\rho(k/m)\max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}}\left|\left(\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right)\right| \\
=&\sigma\sup_{k=1}^{\infty}\rho(k/m)\max_{j=0}^{k-1}\frac{k-j}{\sqrt{m}\sigma}\left|\left(\frac{1}{m+j}\sum_{t=1}^{m+j}\hat{\epsilon}_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat{\epsilon}_t\right)\right| \\
=&\sigma\sup_{k=1}^{\infty}\rho(k/m)\widetilde{E}_m(k) \\
=&O_P(1).
\end{aligned}
$$

综上，引理3.4成立。结合引理3.1-3.4，当 $m\to\infty$ 时，以下弱收敛结果成立：

$$
\sup_{k=1}^{\infty}\rho(k/m)E_m(k)\Longrightarrow\sup_{0\le t<\infty}\max_{0\le s\le t}\rho(t)\left|W_1(t)-\frac{1+t}{1+s}W_1(s)+\frac{t-s}{1+s}W_2(1)\right|.
$$

另外，根据 Gösmann 等人[24] 的辅助材料中的引理 A5 可得

$$
\begin{aligned}
&\sup_{0\le t<\infty}\max_{0\le s\le t}\rho(t)\left|W_1(t)-\frac{1+t}{1+s}W_1(s)+\frac{t-s}{1+s}W_2(1)\right| \\
\overset{D}{=}&\sup_{0\le t<\infty}\max_{0\le s\le t}(1+t)\rho(t)\left|W\left(\frac{t}{1+t}\right)-W\left(\frac{s}{1+s}\right)\right|.
\end{aligned}
$$

此即定理3.1中开放式在线监测方法的渐近结果。

对于封闭式在线监测方法的渐近结果，可由假设3.1中的不变原理导出。由于边界函数 $\rho(\cdot)$ 为正连续函数，其在 $(0,L)$ 上一致连续。结合假设3.3，易得

$$
\sup_{k=1}^{Lm}\rho(k/m)E_m(k)\Longrightarrow\sup_{0\le t\le L}\max_{0\le s\le t}(t+1)\rho(t)\left|W\left(\frac{s}{1+s}\right)-W\left(\frac{t}{1+t}\right)\right|.
$$

□

另外，对于给定的边界函数 $\rho_\gamma(t) = (1+t)^{-1}\left(\frac{t}{1+t}\right)^{-\gamma}$，$\gamma \in [0, 1/2)$，根据推论3.1，定理3.1中的渐近分布可简化为

$$\begin{aligned}&\sup_{0\le t\le L}\max_{0\le s\le t}(t+1)\rho_\gamma(t)\left|W\left(\frac{s}{1+s}\right)-W\left(\frac{t}{1+t}\right)\right|\\&\qquad\overset{D}{=}\sup_{0\le t<L/(1+L)}\max_{0\le s\le t}\frac{1}{t^\gamma}\left|W(t)-W(s)\right|,\end{aligned}\tag{3-23}$$

$$\begin{aligned}&\sup_{0\le t<\infty}\max_{0\le s\le t}(t+1)\rho_\gamma(t)\left|W\left(\frac{s}{1+s}\right)-W\left(\frac{t}{1+t}\right)\right|\\&\qquad\overset{D}{=}\sup_{0\le t<1}\max_{0\le s\le t}\frac{1}{t^\gamma}\left|W(t)-W(s)\right|.\end{aligned}\tag{3-24}$$

式 (3-23) 由一个简单的变量替换得到

$$\begin{aligned}&\sup_{0\le t\le L}\max_{0\le s\le t}(t+1)\rho_\gamma(t)\left|W\left(\frac{s}{1+s}\right)-W\left(\frac{t}{1+t}\right)\right|\\&\qquad=\sup_{0\le t\le L}\max_{0\le s\le t}\left(\frac{t}{1+t}\right)^{-\gamma}\left|W\left(\frac{s}{1+s}\right)-W\left(\frac{t}{1+t}\right)\right|\\&\qquad\overset{D}{=}\sup_{0\le u<L/(1+L)}\max_{0\le v\le u}\frac{1}{u^\gamma}\left|W(u)-W(v)\right|.\end{aligned}\tag{3-25}$$

其中最后一行进行了变量替换。其中映射 $t \mapsto u = \frac{t}{1+t}$ 为区间 $[0, \infty)$ 上的递增单射。以类似方式可得到式 (3-24) 的结果。

接下来证明定理3.2。当备择假设成立时，如假设3.4所示，

$$\theta_t = \theta_0, m+1 \le t \le m+k^*; \theta_t = \theta^*, m+k^*+1 \le t \le m+Lm,$$

其中 $k^* = k_m^* \in \mathbb{N}$ 为变点，$\theta_0 \ne \theta^*$ 表示变点前后的模型参数。

证明 首先证明封闭式在线监测方法（$L < \infty$）的渐近结果。由假设3.4，变点 $k_m^* = \lfloor ms^* \rfloor$，$s^* \in (0, L)$。令 $\epsilon_t^* = Y_t - \lambda_t(\theta^*)$ 为变点后的真实残差序列。

$$\begin{aligned}&\sup_{k=1}^{Lm}\rho(k/m)E_m(k)\\&=\sup_{k=1}^{Lm}\rho(k/m)\max_{j=0}^{k-1}(\hat\sigma_m^2)^{-1/2}\frac{k-j}{\sqrt m}\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat\epsilon_t-\frac{1}{k-j}\sum_{t=m+j+1}^{m+k}\hat\epsilon_t\right|\\&\overset{k=mc_a+k_m^*}{\ge}\frac{\rho\left(\frac{k_m^*}{m}+c_a\right)}{\sqrt m(\hat\sigma_m^2)^{1/2}}\max_{j=0}^{mc_a+k_m^*}\left(mc_a+k_m^*-j\right)\left|\frac{1}{m+j}\sum_{t=1}^{m+j}\hat\epsilon_t-\frac{1}{mc_a+k_m^*-j}\sum_{t=m+j+1}^{m+mc_a+k_m^*}\hat\epsilon_t\right|\\&\overset{j=k_m^*}{\ge}\frac{(mc_a)\,\rho\left(\frac{k_m^*}{m}+c_a\right)}{\sqrt m(\hat\sigma_m^2)^{1/2}}\left|\frac{1}{m+k_m^*}\sum_{t=1}^{m+k_m^*}\hat\epsilon_t-\frac{1}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}\hat\epsilon_t\right|.\end{aligned}\tag{3-26}$$

由逆三角不等式可得

$$
\begin{aligned}
&\frac{(mc_a)\,\rho\left(\frac{k_m^*}{m}+c_a\right)}{\sqrt{m}}\left|\frac{1}{m+k_m^*}\sum_{t=1}^{m+k_m^*}\hat{\epsilon}_t-\frac{1}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}\hat{\epsilon}_t\right| \\
\geq & c_a\rho\left(\frac{k_m^*}{m}+c_a\right)\sqrt{m}\left\{\left|\frac{1}{m+k_m^*}\sum_{t=1}^{m+k_m^*}\hat{\epsilon}_t\right|+\left|\frac{1}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}\hat{\epsilon}_t\right|\right\} \\
= & c_a\rho\left(\frac{k_m^*}{m}+c_a\right)\sqrt{m}\left|\frac{1}{m+k_m^*}\sum_{t=1}^{m+k_m^*}\hat{\epsilon}_t\right|+c_a\rho\left(\frac{k_m^*}{m}+c_a\right)\sqrt{m}\left|\frac{1}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}\hat{\epsilon}_t\right| \\
= & I_1+I_2.
\end{aligned}
\tag{3-27}
$$

首先，由于边界函数 $\rho(\cdot)$ 在 $[0,L]$ 上连续且恒为正，易知 $0<c_a\rho\left(\frac{k_m^*}{m}+c_a\right)<\infty$。由假设3.4对变点前的假设可得 $I_1=O_P(1)$。对于 I_2，只需要研究 $\sqrt{m}\left|\frac{1}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}\hat{\epsilon}_t\right|$ 的渐近性质。注意到，对 $t\geq m+k_m^*+1$，

$$
\begin{aligned}
\hat{\epsilon}_t =&(\hat{\epsilon}_t-\epsilon_t)+(\epsilon_t-\epsilon_t^*)+\epsilon_t^* \\
=&(\lambda_t(\theta_0)-\lambda_t(\hat{\theta}_{1:m}))+(\lambda_t(\theta^*)-\lambda_t(\theta_0))+\epsilon_t^*.
\end{aligned}
\tag{3-28}
$$

进一步可得

$$
\begin{aligned}
&\frac{\sqrt{m}}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}\hat{\epsilon}_t \\
=&\frac{\sqrt{m}}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}(\lambda_t(\theta_0)-\lambda_t(\hat{\theta}_{1:m}))+\frac{\sqrt{m}}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}(\lambda_t(\theta^*)-\lambda_t(\theta_0)) \\
&+\frac{\sqrt{m}}{mc_a}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}\epsilon_t^* \\
=&B_1+B_2+B_3.
\end{aligned}
\tag{3-29}
$$

对于 B_1，结合 PQMLE 的渐近正态性和连续映射定理（由假设$\mathrm{A_i}(\Theta)$ (i=0,1,2)，$\lambda(\theta)$ 为 θ 的连续泛函），可知 B_1 中的部分和 $\frac{1}{\sqrt{mc_a}}\sum_{t=m+k_m^*+1}^{m+mc_a+k_m^*}(\lambda_t(\theta_0)-\lambda_t(\hat{\theta}_{1:m}))$ 满足中心极限定理。于是有 $B_1=O_P(1)$。对于 B_2，易知 $B_2=\sqrt{m}(\lambda_t(\theta^*)-\lambda_t(\theta_0))\to\infty$。对于 B_3，由假设3.4可知 $B_3=O_P(1)$。

于是当 $m\to\infty$ 时，$I_2\to\infty$。综上所述，定理3.2中关于封闭式在线监测方法（$L<\infty$）的渐近结果成立。对于开放式在线监测方法（$L=\infty$）的对应结果，依据类似的方法可得，可参考 Gösmann 等人[24] 的证明过程。 □

3.5 本章小节

本章研究了整数值时间序列模型的参数变点监测问题。现有研究通常基于确定的概率分布假设，但这一假设在实际应用中较为严格。为此，本文在半参数框架下探讨这一问题，以放宽对概率分布的假定。本文提出了一种基于 PQMLE 的在线监测方法，该方法利用模型残差构造修正 CUSUM 监测统计量。与现有的基于参数估计量的 CUSUM 在线监测方法相比，该方法在大多数整数值时间序列模型中表现优异，有效控制了第一类错误率。本文还研究了残差构造的修正 CUSUM 监测统计量在原假设和备择假设下的渐近性质，并通过大量数值模拟验证了该方法的有效性。模拟结果表明，当变点位置靠后时，该修正型 CUSUM 统计量的检测能力优于现有的 CUSUM 方法。

值得注意的是，在 $r = 1$ 的负二项 INGARCH(1,1) 模型下，基于 PQMLE 的 CUSUM 在线监测方法表现不佳。这可能是因为 PQMLE 在该模型中的适用性较差。未来的研究将重点解决这一问题，例如采用负二项拟极大似然估计[65] 或其他更为通用的参数方法[66,67]，以进一步拓展本文方法的适用范围。

第 4 章　总结与展望

4.1　主要研究结论

近几十年来，时间序列的变点监测问题引起了广泛关注。本文主要研究了连续值和整值时间序列中，无分布假定的稳健在线监测方法。第二章研究了连续值时间序列中的分布变点监测问题。第三章则在半参数框架下研究了整值时间序列模型的参数变点监测问题。主要研究内容总结如下：

第一章首先介绍了变点监测问题的理论意义和现实意义，随后讨论了连续值和整值时间序列中在线监测方法的研究现状。

第二章研究了连续值时间序列中的分布变点监测问题。当观测值之间存在较强的时间依赖性时，现有非参数方法难以有效控制第一类错误率。为解决这一问题，本文提出了一个基于经验特征函数的自正则在线监测方法。在原假设下证明了自正则监测统计量的渐近分布，并在在备择假设下证明了其一致性。通过广泛的数值模拟，比较了比所提方法和现有非参数在线监测方法的有限样本表现。模拟结果表明，自正则方法显著缓解了经验水平的扭曲问题。此外，通过对两台风机的叶片振动数据进行监测，展示了该方法的实际应用潜力。

第三章首先介绍了半参数框架下的整值时间序列模型及其泊松拟极大似然估计（PQMLE）方法。该框架放宽了对概率分布的假设，具有更广泛的应用范围。针对整值时间序列模型的参数变点监测问题，本文提出了一种基于 PQMLE 的在线监测方法。具体而言，首先在训练样本中采用 PQMLE 方法进行参数估计；然后计算模型残差，并利用残差构造修正 CUSUM 监测统计量。本文从理论上研究了所提在线监测方法的渐近性质，并通过数值模拟验证了其有效性。在合适的边界函数（$\rho_\gamma(t), \gamma = 0$）下，所提方法在大多数整值时间序列模型中表现良好，能够有效控制第一类错误率，并展现出良好的检测能力。

4.2　研究展望

关于连续值和整值时间序列中无分布假定的稳健在线监测方法，下一步将研究的问题如下：

（1）基于自正则概念，本文构造了基于经验特征函数的标准 CUSUM 统计量。该方法有效解决了第一类错误率的扭曲问题，但仍有改进空间。当变点位置相对靠后时，标准 CUSUM 统计量的检测能力不足。这是因为此类型的统计量主要用于检测早期变点，仅比较了训练样本与新到达样本之间的分布差异。为提高检测

能力，可以构造修正型 CUSUM 统计量[3,23,24]。修正型 CUSUM 统计量将变点位置纳入考虑，逐步比较潜在变点前后的分布差异，能够增强对后期变点的检测能力。

（2）针对整值时间序列的参数变点监测问题，基于泊松拟极大似然估计，本文利用模型残差构造了修正型 CUSUM 监测统计量。数值模拟结果表明，该方法在大多数模型中表现良好。然而，在 $r = 1$ 的负二项 INGARCH(1,1) 模型下，该方法难以有效控制第一类错误率。这一问题的可能原因是 PQMLE 在该模型中难以达到完全的渐近效率[65]。未来的研究将重点解决这一问题，探索一些更为通用的参数估计方法在整值时间序列模型参数变点监测问题中的应用。例如，负二项拟极大似然估计[65] 和指数族拟极大似然估计[66] 等方法。

致　谢

时光荏苒，三年的研究生学习生涯即将画上句号。回望这段求学旅程，满是成长与收获。

首先，向我的导师杨宝莹老师致以最诚挚的谢意。本论文的顺利完成，离不开您的悉心指导与耐心教诲。过去的三年里，您以严谨的治学态度和细致入微的教导，为我指引学术研究的方向。您的言传身教让我学会了独立思考、脚踏实地做事，并培养了我严谨的工作态度。这些宝贵的经验将让我终生受益。

我要特别感谢我的家人。你们是我坚强的后盾，给予我源源不断的支持。你们的期望与鼓励，是我在求学路上不断前行的动力。

在此，我向所有曾给予我关心与鼓励的人致以衷心的感谢。

参考文献

[1] Hlávka Z, Hušková M, Meintanis S G. Change-point methods for multivariate time-series: paired vectorial observations[J]. Statistical Papers, 2020, 61: 1351-1383.

[2] 陈希孺. 变点统计分析简介[J]. 数理统计与管理, 1991(02): 52-59.

[3] Dette H, Gösmann J. A likelihood ratio approach to sequential change point detection for a general class of parameters[J]. Journal of the American Statistical Association, 2020, 115(531): 1361-1377.

[4] Csörgö M, Horváth L. Limit theorems in change-point analysis[M]. Wiley, 1997.

[5] Aue A, Horváth L. Structural breaks in time series[J]. Journal of Time Series Analysis, 2013, 34(1): 1-16.

[6] Chu C S J, Stinchcombe M, White H. Monitoring structural change[J]. Econometrica: Journal of the Econometric Society, 1996: 1045-1065.

[7] Fried R, Imhoff M. On the online detection of monotonic trends in time series[J]. Biometrical Journal: Journal of Mathematical Methods in Biosciences, 2004, 46(1): 90-102.

[8] Guo L, Modarres R. Two multivariate online change detection models[J]. Journal of Applied Statistics, 2022, 49(2): 427-448.

[9] Na O, Lee Y, Lee S. Monitoring parameter change in time series models[J]. Statistical Methods & Applications, 2011, 20: 171-199.

[10] Hušková M, Hlávka Z. Nonparametric sequential monitoring[J]. Sequential Analysis, 2012, 31 (3): 278-296.

[11] Kojadinovic I, Verdier G. Nonparametric sequential change-point detection for multivariate time series based on empirical distribution functions[J]. Electronic Journal of Statistics, 2021, 15(1).

[12] Lee S, Meintanis S G, Pretorius C. Monitoring procedures for strict stationarity based on the multivariate characteristic function[J]. Journal of Multivariate Analysis, 2022, 189: 104892.

[13] McKenzie E. Some simple models for discrete variate time series[J]. JAWRA Journal of the American Water Resources Association, 1985, 21(4): 645-650.

[14] Alzaid A A, Al-Osh M. An integer-valued pth-order autoregressive structure (INAR(p)) process [J]. Journal of Applied Probability, 1990, 27(2): 314-324.

[15] Ferland R, Latour A, Oraichi D. Integer-valued GARCH process[J]. Journal of time series analysis, 2006, 27(6): 923-942.

[16] Hudecová Š, Hušková M, Meintanis S G. Tests for structural changes in time series of counts[J]. Scandinavian Journal of Statistics, 2017, 44(4): 843-865.

[17] Kirch C, Kamgaing J T. On the use of estimating functions in monitoring time series for change points[J]. Journal of Statistical Planning and Inference, 2015, 161: 25-49.

[18] Lee S, Lee Y. Sequential online monitoring for autoregressive time series of counts[J]. Journal of the Korean Statistical Society, 2024, 53(2): 307-327.

[19] Lee S, Lee S. Exponential family QMLE-based CUSUM test for integer-valued time series[J]. Communications in Statistics-Simulation and Computation, 2023, 52(5): 2022-2043.

[20] Diop M L, Kengne W. Poisson QMLE for change-point detection in general integer-valued time series models[J]. Metrika, 2022, 85(3): 373-403.

[21] Ahmad A, Francq C. Poisson QMLE of count time series models[J]. Journal of Time Series Analysis, 2016, 37(3): 291-314.

[22] Lee S, Kim B. Recent progress in parameter change test for integer-valued time series models [J]. Journal of the Korean Statistical Society, 2021, 50: 730-755.

[23] Kirch C, Weber S. Modified sequential change point procedures based on estimating functions [J]. Electronic Journal of Statistics, 2018, 12(1): 1579 - 1613.

[24] Gösmann J, Kley T, Dette H. A new approach for open-end sequential change point monitoring [J]. Journal of Time Series Analysis, 2021, 42(1): 63-84.

[25] Page E S. A test for a change in a parameter occurring at an unknown point[J]. Biometrika, 1955, 42(3/4): 523-527.

[26] Aue A, Kirch C. The state of cumulative sum sequential changepoint testing 70 years after Page [J]. Biometrika, 2024, 111(2): 367-391.

[27] Horváth L, Hušková M, Kokoszka P, et al. Monitoring changes in linear models[J]. Journal of statistical Planning and Inference, 2004, 126(1): 225-251.

[28] Aue A, Horváth L, Kokoszka P, et al. Monitoring shifts in mean: Asymptotic normality of stopping times[J]. Test, 2008, 17(3): 515-530.

[29] Horváth L, Kokoszka P, Zhang A. Monitoring constancy of variance in conditionally heteroskedastic time series[J]. Econometric Theory, 2006, 22(3): 373-402.

[30] Berkes I, Gombay E, Horváth L, et al. Sequential change-point detection in GARCH (p,q) models [J]. Econometric theory, 2004, 20(6): 1140-1167.

[31] Sundararajan R R, Pourahmadi M. Nonparametric change point detection in multivariate piecewise stationary time series[J]. Journal of Nonparametric Statistics, 2018, 30(4): 926-956.

[32] Pein F, Sieling H, Munk A. Heterogeneous change point inference[J]. Journal of the Royal Statistical Society Series B: Statistical Methodology, 2017, 79(4): 1207-1227.

[33] Hong Y, Wang X, Wang S. Testing strict stationarity with applications to macroeconomic time series[J]. International Economic Review, 2017, 58(4): 1227-1277.

[34] Shao X, Zhang X. Testing for change points in time series[J]. Journal of the American Statistical Association, 2010, 105(491): 1228-1240.

[35] Hoga Y. Monitoring multivariate time series[J]. Journal of Multivariate Analysis, 2017, 155: 105-121.

[36] Chan N H, Ng W L, Yau C Y. A self-normalized approach to sequential change-point detection for time series[J]. Statistica Sinica, 2021, 31(1): 491-517.

[37] Du J, Li Y. The integer-valued autoregressive (INAR(p)) model[J]. Journal of time series analysis, 1991, 12(2): 129-142.

[38] Al-Osh M A, Aly E E A. First order autoregressive time series with negative binomial and geometric marginals[J]. Communications in Statistics-Theory and Methods, 1992, 21(9): 2483-2492.

[39] Fokianos K, Rahbek A, Tjøstheim D. Poisson autoregression[J]. Journal of the American Statistical Association, 2009, 104(488): 1430-1439.

[40] Schmidt A M, Pereira J B M. Modelling time series of counts in epidemiology[J]. International Statistical Review, 2011, 79(1): 48-69.

[41] Wang C, Liu H, Yao J F, et al. Self-excited threshold Poisson autoregression[J]. Journal of the American Statistical Association, 2014, 109(506): 777-787.

[42] Tjøstheim D. Some recent theory for autoregressive count time series[J]. Test, 2012, 21(3): 413-438.

[43] Weiß C H. An introduction to discrete-valued time series[M]. John Wiley & Sons, 2018.

[44] Zhu F. A negative binomial integer-valued GARCH model[J]. Journal of Time Series Analysis, 2011, 32(1): 54-67.

[45] Neumann M H. Absolute regularity and ergodicity of poisson count processes[J]. Bernoulli, 2011, 17(4): 1268-1284.

[46] Freeland R K, McCabe B. Asymptotic properties of CLS estimators in the Poisson AR (1) model [J]. Statistics & probability letters, 2005, 73(2): 147-153.

[47] Ristić M M, Nastić A S, Bakouch H S. Estimation in an integer-valued autoregressive process with negative binomial marginals (NBINAR(1))[J]. Communications in Statistics-Theory and Methods, 2012, 41(4): 606-618.

[48] Davis R A, Liu H. Theory and inference for a class of nonlinear models with application to time series of counts[J]. Statistica Sinica, 2016: 1673-1707.

[49] Kirch C, Weber S. Modified sequential change point procedures based on estimating functions [J]. Electronic Journal of Statistics, 2018, 12(1): 1579 - 1613.

[50] Fan Y, de Micheaux P L, Penev S, et al. Multivariate nonparametric test of independence[J]. Journal of Multivariate Analysis, 2017, 153: 189-210.

[51] Kirch C, Stoehr C. Sequential change point tests based on U-statistics[J]. Scandinavian Journal of Statistics, 2022, 49(3): 1184-1214.

[52] Weber S M. Change-point procedures for multivariate dependent data[D]. Dissertation, Karlsruhe, Karlsruher Institut für Technologie (KIT), 2017.

[53] Politis D N, Romano J P. The stationary bootstrap[J]. Journal of the American Statistical association, 1994, 89(428): 1303-1313.

[54] Politis D N, White H. Automatic block-length selection for the dependent bootstrap[J]. Econometric Reviews, 2004, 23(1): 53 - 70.

[55] Jentsch C, Rao S S. A test for second order stationarity of a multivariate time series[J]. Journal of Econometrics, 2015, 185(1): 124-161.

[56] Giacomini R, Politis D N, White H. A warp-speed method for conducting monte carlo experiments involving bootstrap estimators[J]. Econometric theory, 2013, 29(3): 567-589.

[57] Zhou Z. Measuring nonlinear dependence in time-series, a distance correlation approach[J]. Journal of Time Series Analysis, 2012, 33(3): 438-457.

[58] Yokoyama R. Moment bounds for stationary mixing sequences[J]. Zeitschrift für Wahrscheinlichkeitstheorie und verwandte Gebiete, 1980, 52(1): 45-57.

[59] Ibragimov I A, Hasminskii R Z. Statistical estimation : asymptotic theory[M]. Springer Science & Business Media, 1981.

[60] Hlávka Z, Hušková M, Kirch C, et al. Fourier–type tests involving martingale difference processes[J]. Econometric Reviews, 2017, 36(4): 468-492.

[61] Billingsley P. Convergence of probability measures[M]. John Wiley & Sons, 1968.

[62] Fremdt S. Page's sequential procedure for change-point detection in time series regression[J]. Statistics, 2015, 49(1): 128-155.

[63] Eberlein E. On strong invariance principles under dependence assumptions[J]. The Annals of Probability, 1986: 260-270.

[64] Kang J, Lee S. Parameter change test for Poisson autoregressive models[J]. Scandinavian Journal of Statistics, 2014, 41(4): 1136-1152.

[65] Aknouche A, Bendjeddou S, Touche N. Negative binomial quasi-likelihood inference for general integer-valued time series models[J]. Journal of Time Series Analysis, 2018, 39(2): 192-211.

[66] Aknouche A, Francq C. Count and duration time series with equal conditional stochastic and mean orders[J]. Econometric Theory, 2021, 37(2): 248-280.

[67] Goto Y, Fujimori K. Test for conditional variance of integer-valued time series[J]. Statistica Sinica, 2022, 32(4): 2241-2263.

攻读硕士学位期间取得的研究成果

[1] **Wang Y**, Yang B. A Self-Normalized Online Monitoring Method Based on the Characteristic Function[J]. Mathematics, 2025, 13(5): 710.